ТУСУР
TUSUR UNIVERSITY

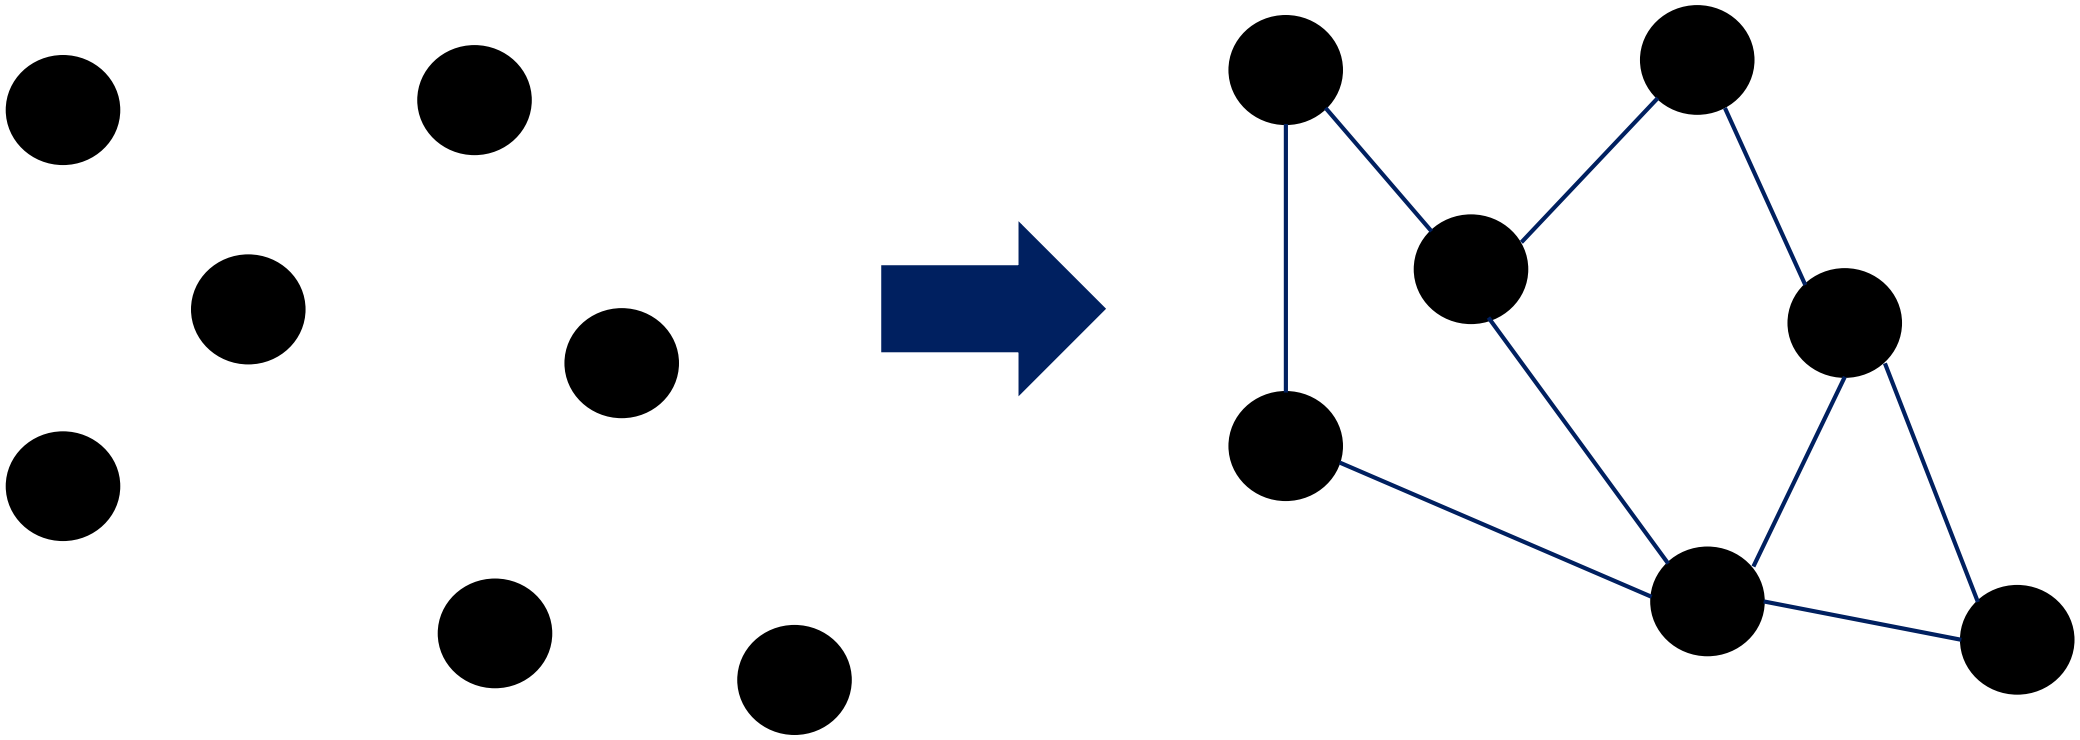
2.1 Предобработка структурированных данных

Введение в графы, сети и задачи машинного обучения на графах

05.10.2022

Введение

Граф является универсальной моделью, которая позволяет описывать и анализировать сущности с учетом связей и взаимодействий между ними.



Данные, различных предметных областей представленные в виде графов



Метрополитен

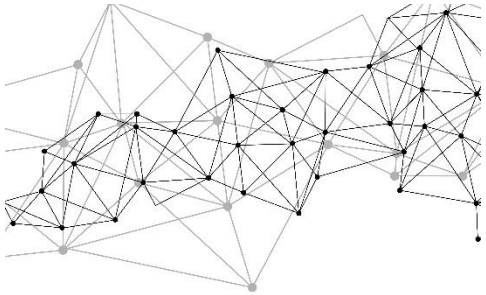


Компьютерные сети

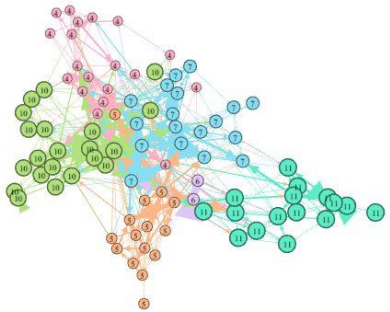


Молекулярные сети

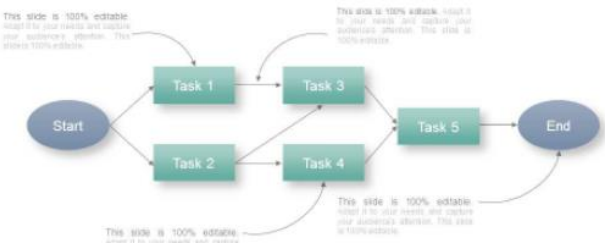
Сети распространения инфекционных заболеваний



Данные социальных сетей



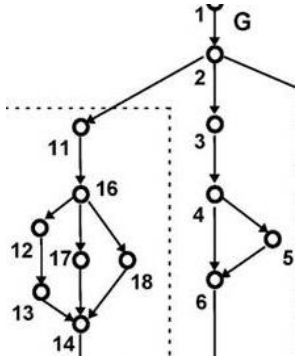
Сети выполнения работ



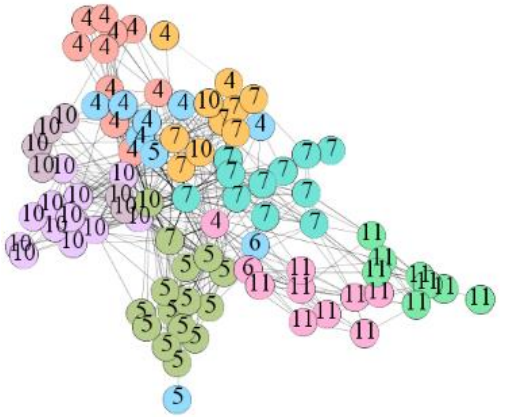
Использование графов в различных предметных областях



Граф знаний



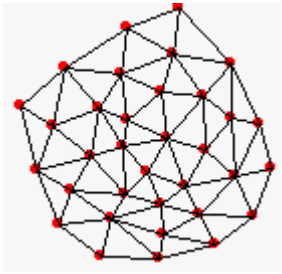
Программный код
в виде графа



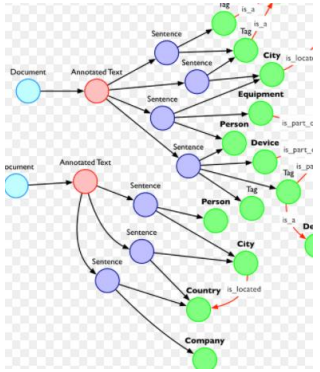
Экономическая сеть



Нормативные документы



Геометрические фигуры в
задачах визуализации их на плоскости



Граф распространения
новостей

В чем преимущество использования графов

При анализе множества сложных объектов в рамках некоторой предметной области может быть использован граф, когда данные об отношениях между объектами также учитывается в графе.



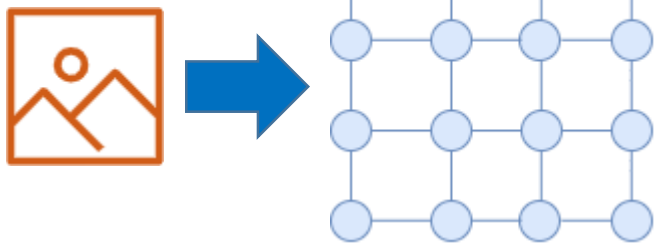
Чем более подробно и точно мы моделируем отношения, тем большую точность мы достигаем в задачах прогнозирования.

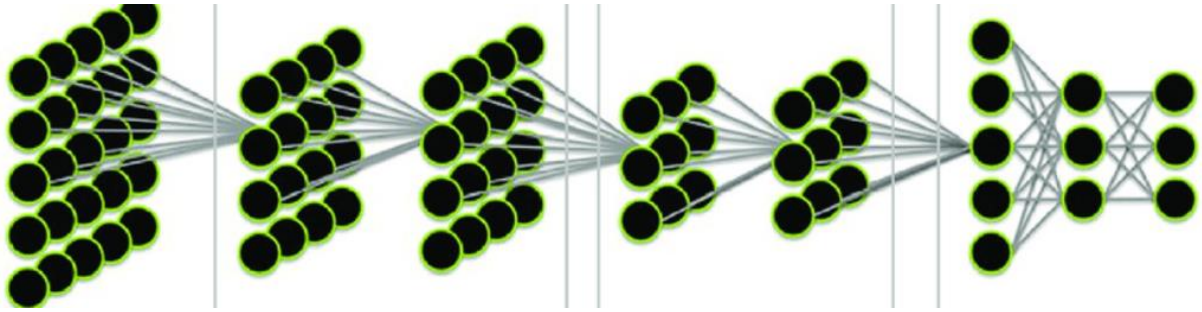


И это особенно важно применительно к задачам машинного обучения

Инструменты машинного обучения

Изображение

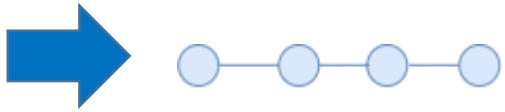




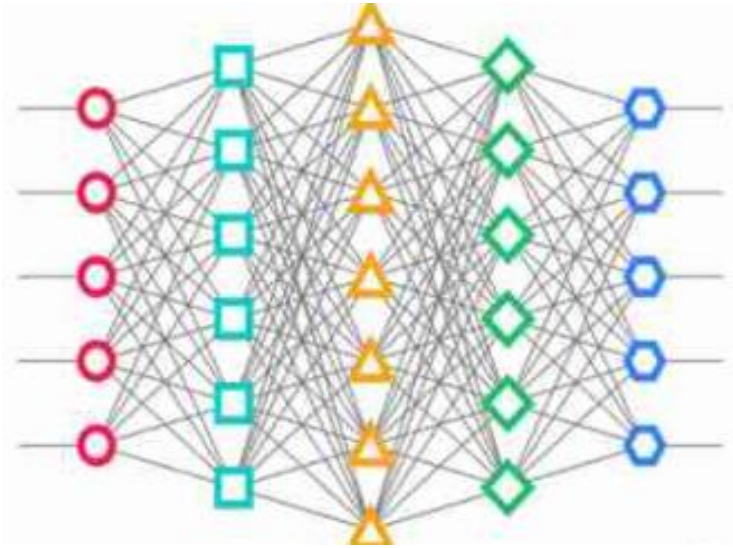
Речь



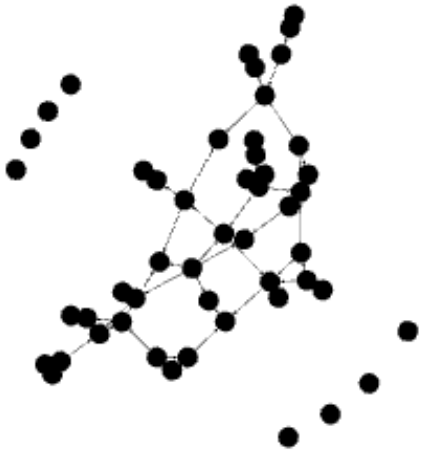
Текст



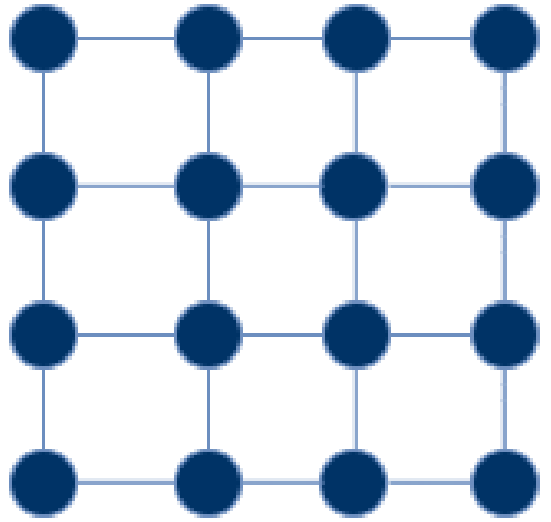




Почему данные, представленные в виде графа сложно использовать в машинном обучении?

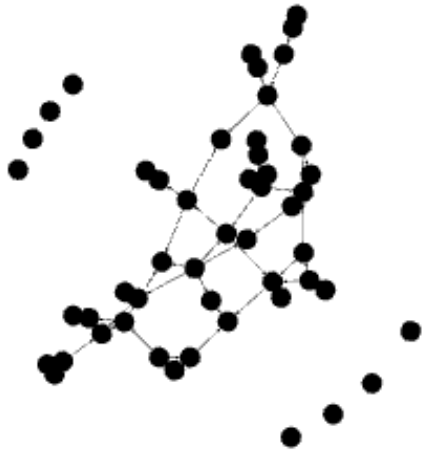


- ✓ Какой узел посчитать начальным? Нельзя использовать пространственную локализацию вверх, низ, лево, право.
- ✓ В какой последовательности тогда обрабатывать узлы? Отсутствует правило по которому бы можно было их упорядочить.
- ✓ Как обрабатывать граф, в случае мультимодальности, то есть если граф содержит связи разного типа (разная смысловая нагрузка)?
- ✓ Если граф динамический, то есть возможно добавление узлов, например и связей. Как строить прогнозы?



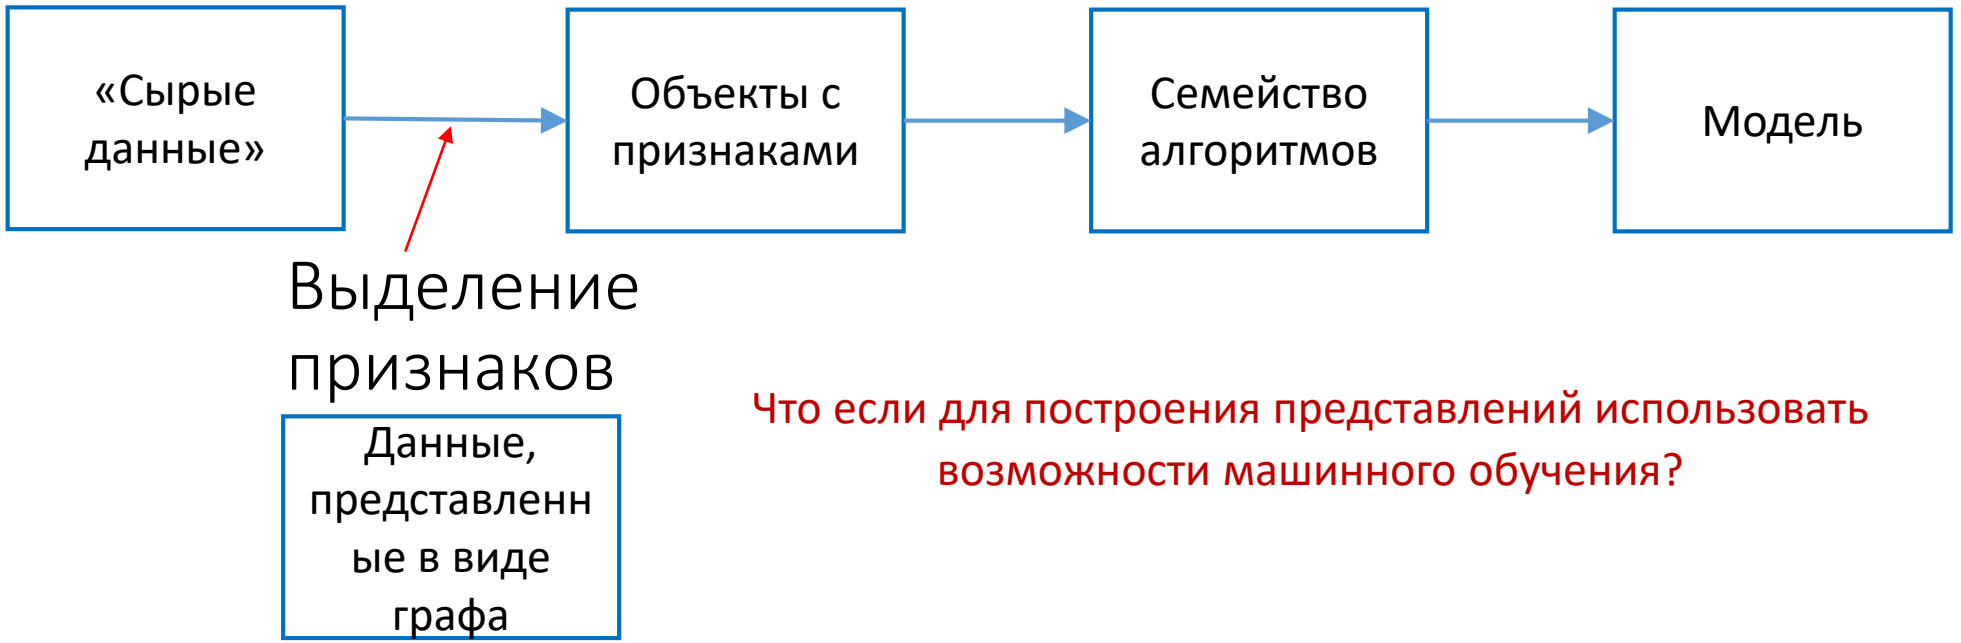


Как применять нейронные сети, когда исходные данные представлены графом



Данные, представленные в виде графов является новой интересной возможностью использовать по-другому инструменты машинного обучения, и добиваться более точного решения широкого класса задач.

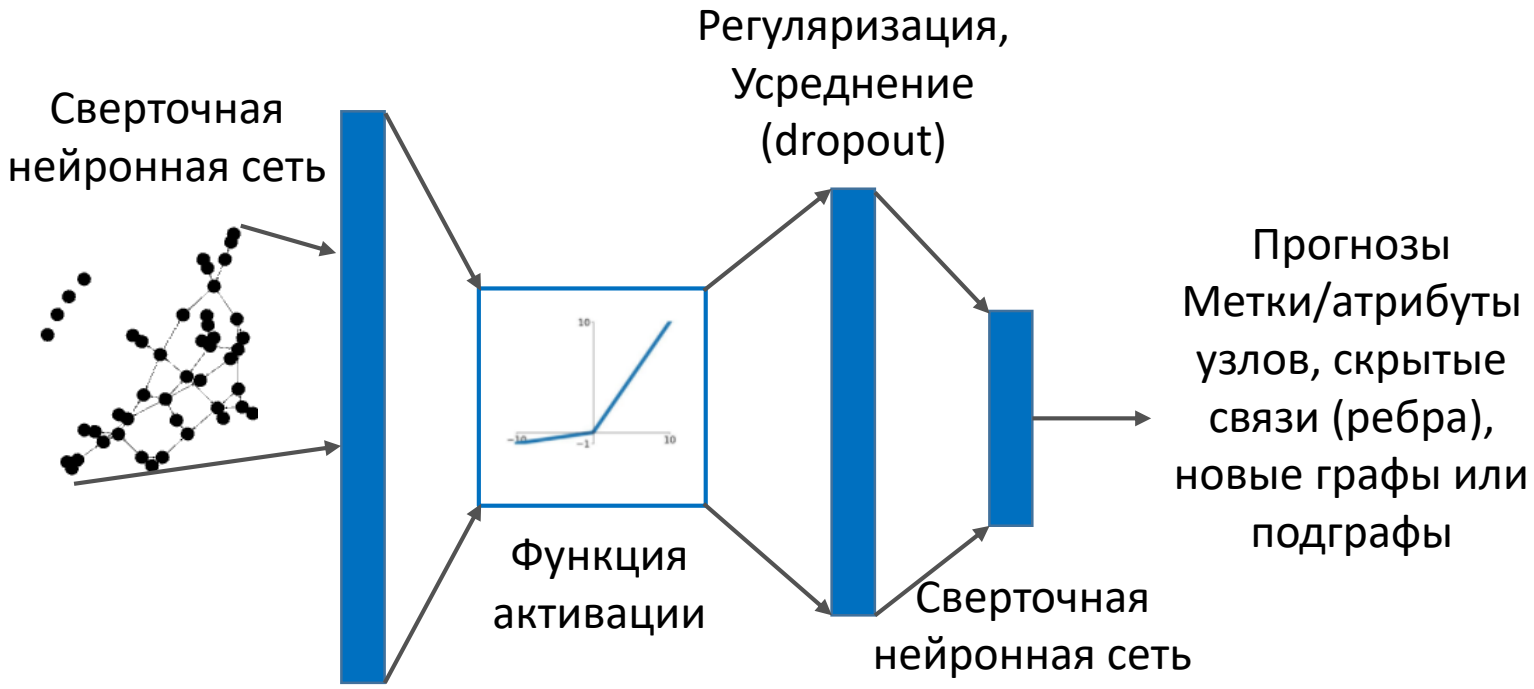
Типовой жизненный цикл решения задачи в рамках машинного обучения с учителем



Что если для построения представлений использовать возможности машинного обучения?

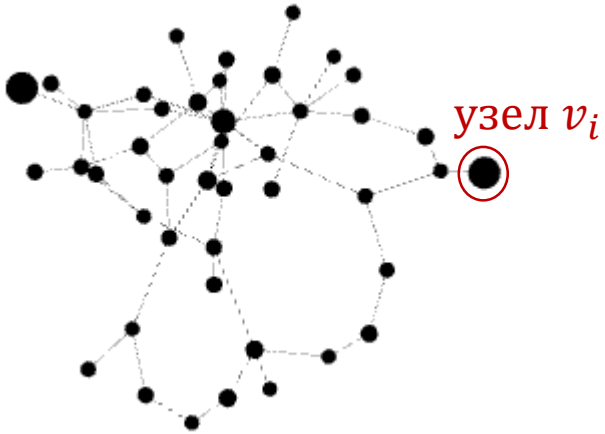
Обучение представлениям (Representation learning/Feature learning) – это область науки о машинном обучении на базе определенного представления (кодирования, хранения) данных для выделения определенных признаков.

Общая схема обработки графа инструментами машинного обучения



Можно ли работать с графом так, чтобы не нужно было вручную выделять признаки, то есть можно ли обрабатывать граф без участия человека?

Задача эмбеддинга узлов графа (graph node embedding task)



$$f: v_i \rightarrow \mathbb{R}^d$$

$$i = 1 \ldots m,$$

Эмбеддинг/репрезентация

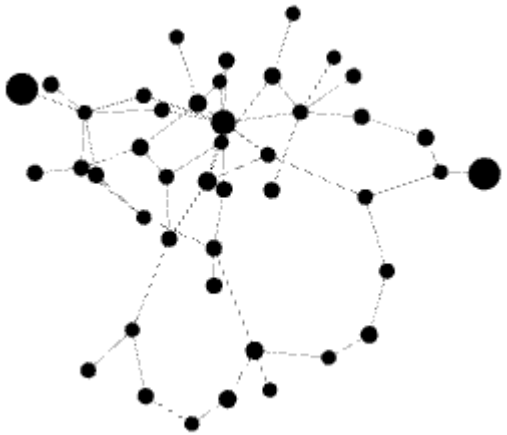


$\mathbb{R}^d$

Каждый узел графа представляется вектором действительных чисел длины d

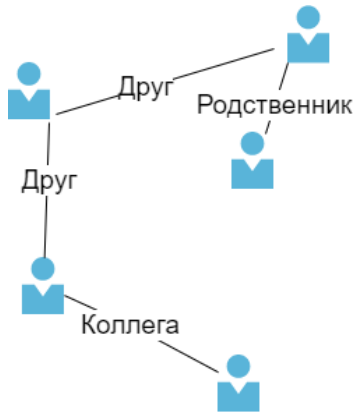
Цель – найти такую функцию f, которая бы позволяла бы получить эмбеддинг любого узла в графе

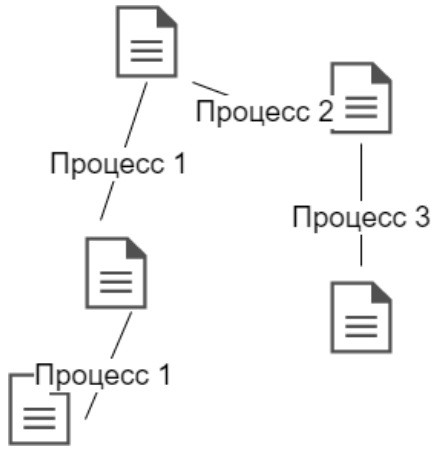
Граф

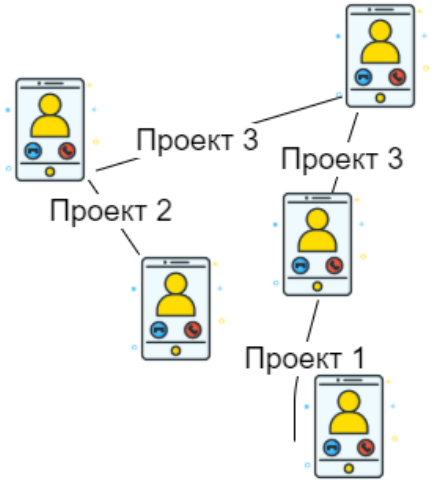


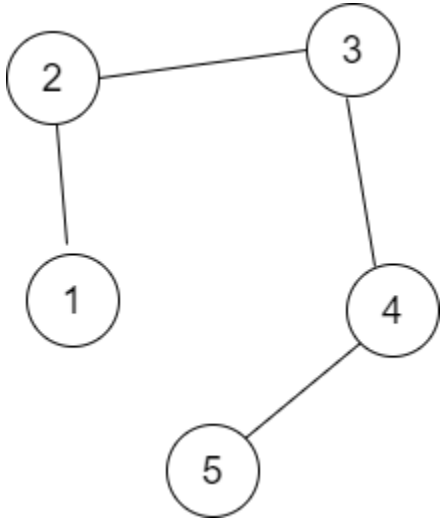
Графом G называется упорядоченная пара двух множеств $G = (V(G), E(G))$, где $V(G)$ — множество вершин графа G, а $E(G)$ — множество ребер графа G.

Систему объектов описываемую в рамках некоторой предметной области обычно называют сетью.







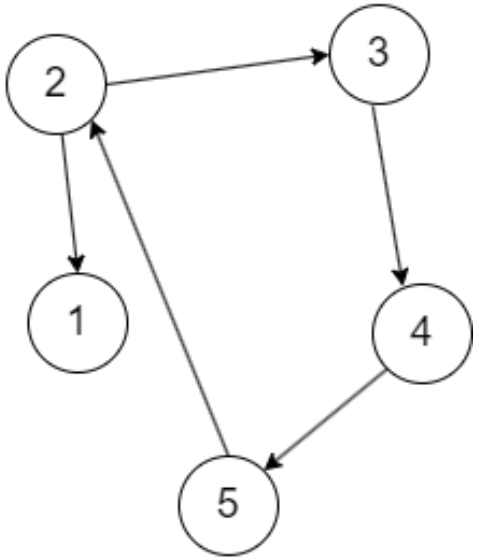


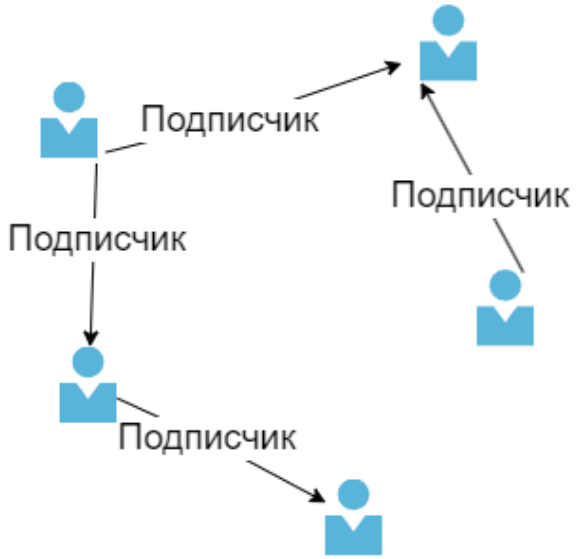
$|V| = 5 \quad |E| = 4$

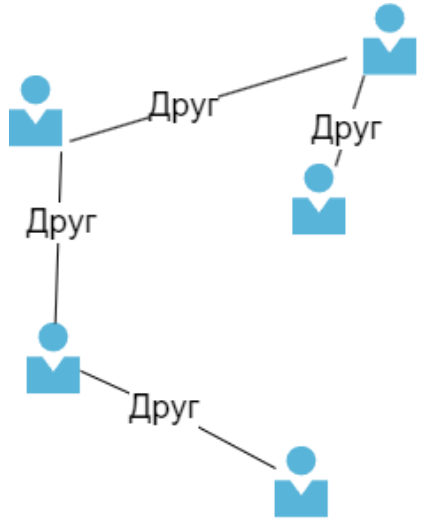
Ориентированный и неориентированный графы

Если элементами множества ***E*** являются упорядоченные пары (т.е. пары, в которых фиксирован порядок элементов), то граф называется ориентированным (или орграфом). В этом случае элементы множества *V* называются узлами, а элементы множества ***E*** – дугами или направленными ребрами. Первую вершину упорядоченной пары называют началом дуги, вторую – концом.

Если с каждом ребром из множества ***E*** т.е. $\boldsymbol{e} \in \boldsymbol{E}$ сопоставлена неупорядоченная пара вершин, т.е. $e = (v, w)$, где $v, w \in V$, то такой граф называется неориентированным.







Графы. Определения

Определение. Пусть $v1, v2$ – вершины, $e = (v1, v2)$ – соединяющее их ребро. Тогда вершина $v1$ и ребро e инцидентны, вершина $v2$ и ребро e также инцидентны.

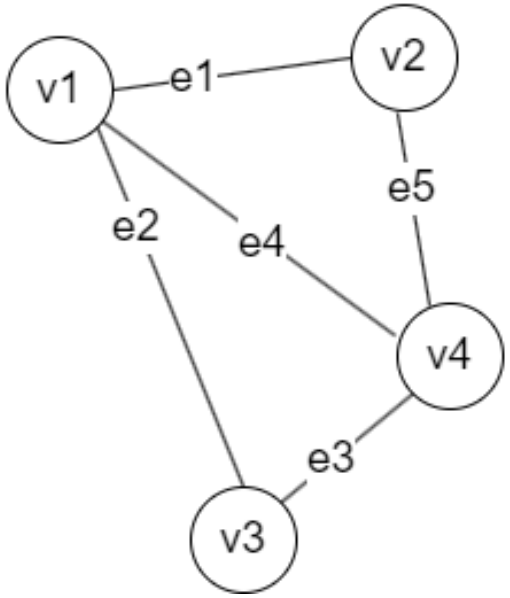
Определение. Два ребра, инцидентные одной вершине, называются смежными.

Определение. Вершина u смежна с вершиной v, если $(v, u) \in E$

Определения, касающиеся смежности вершин, подходят также и для орграфа.

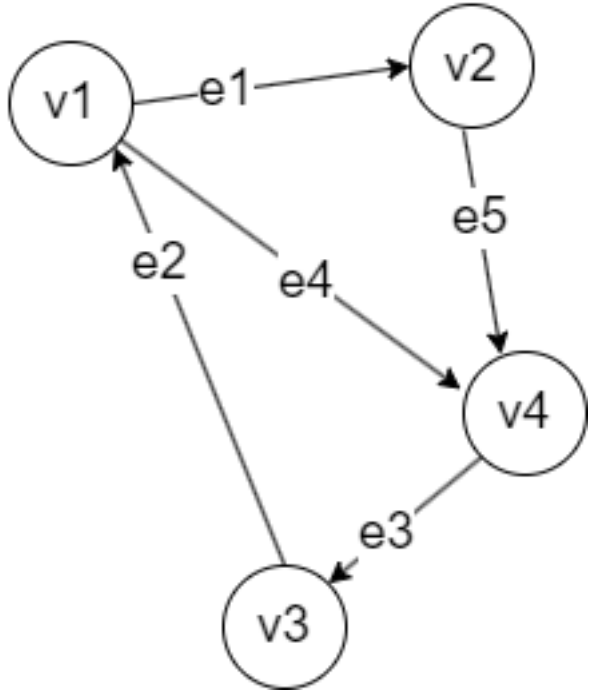
Определение. Количество ребер, инцидентных вершине v, называется степенью вершины v и обозначается $d(v)$

Определение. Для орграфа число дуг, исходящих из вершины v, называется полустепенью исхода $d^+(v)$, а входящих – полустепенью захода $d^-(v)$.



В НЕориентированном графе

- ✓ смежные вершины $v1$ и $v2$ $v2$ и $v4$, $v4$ и $v3$, $v3$ и $v1$, $v1$ и $v4$, а вершины $v3$ и $v2$ не смежные.
- ✓ Ребра e1 и e2, e2 и e3, e3 и e4, e1 и e4, e1 и e5, e2 и e4, e3 и e5, e4 и e5 смежные, e1 и e3, e2 и e5 не смежные
- ✓ $d(v1) = d(v4) = 3$, $d(v2) = d(v3) = 2$

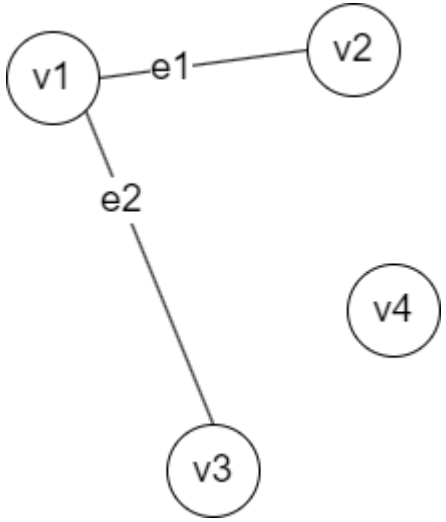


В ориентированном графе

- ✓ смежные вершины $v1$ и $v2$ $v2$ и $v4$, $v4$ и $v3$, $v3$ и $v1$, $v1$ и $v4$, а вершины $v3$ и $v2$, $v1$ и $v3$, $v4$ и $v4$, $v4$ и $v2$ не смежные.
- ✓ $d^+(v1) = 2$, $d^-(v1)$=1

Графы. Определения

Определение. Если степень вершины равна 0, то вершина называется изолированной. Если степень вершины равна 1, то вершина называется висячей.



Вершина $v4$ изолированная.
Вершины $v2$ и $v3$ висячие.

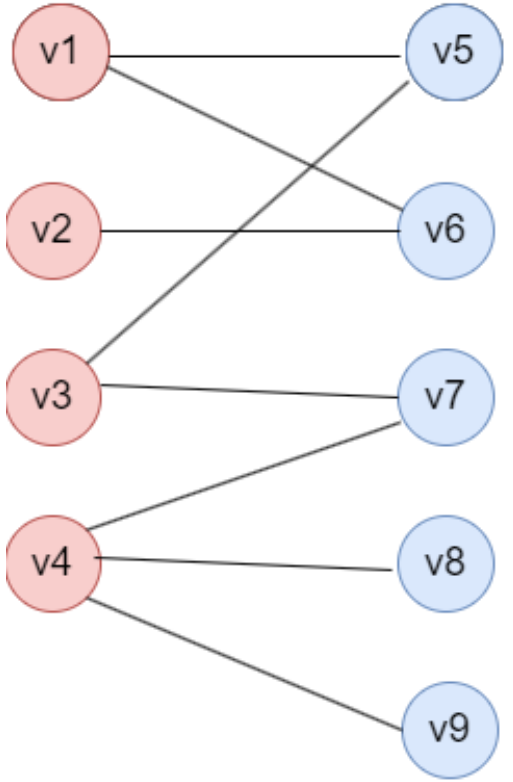
Определение. Граф G(V, E) называется пустым, если E = $\emptyset$.
Определение. Граф G(V, E) называется полным, если в нем любые две вершины смежные, то есть $\forall u, v \in V (u, v) \in E$.
Полный неориентированный граф *n* вершинами имеет n(n-1)/2 рёбер

Графы. Двудольный граф

Определение. Граф $G(V, E)$ называется двудольным, если множество V можно разбить на два непересекающихся подмножества $V1$ и $V2$: $V1 \cap V2 = \emptyset$, $V1 \cup V2 = V$ таким образом, что любое ребро из E соединяет вершину из $V1$ с вершиной из $V2$. Множества $V1$ и $V2$ называются долями двудольного графа.

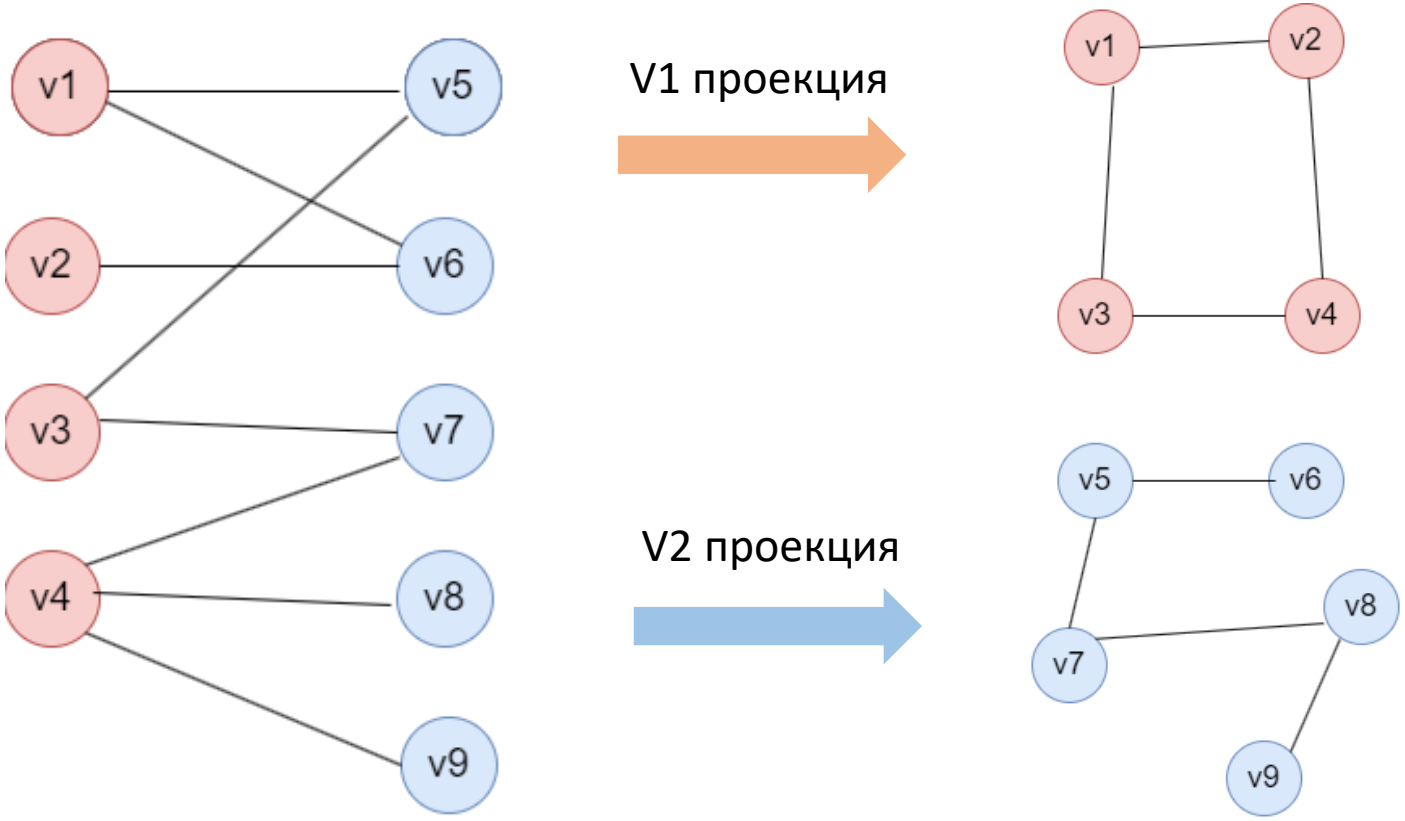
Примеры

- *Авторы публикаций и сами публикации*
- *Пользователи, которые дали оценку публикациям*
- *Рецепты и ингредиенты к ним*
- *Покупатели и товары*



Графы. Проекции двудольного графа

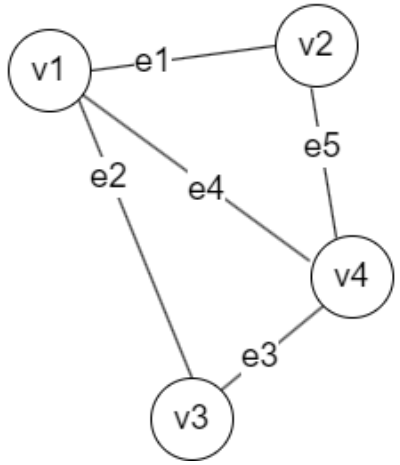
Для удобного представления взаимосвязи между вершинами в наборе (V1 или V2) в двудольном графе метод «одномодовой проекции» часто используется для обработки двудольного графа. Простое представление одномодовой проекции выглядит следующим образом:



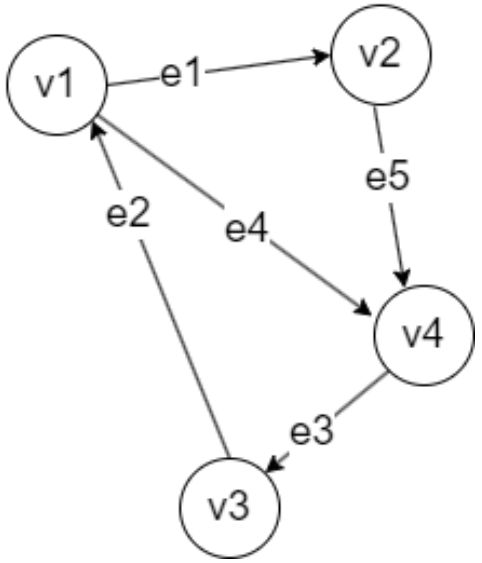
Представление графов

Для представления графов используются следующие структуры:

✓ ***Матрица смежности***



$$A = \begin{array}{c} \\ v1 \\ v2 \\ v3 \\ v4 \end{array} \begin{array}{c} v1\,v2\,v3\,v4 \\ 0\;\;1\;\;1\;\;1 \\ 1\;\;0\;\;0\;\;1 \\ 1\;\;0\;\;0\;\;1 \\ 1\;\;1\;\;1\;\;0 \end{array}$$



$$A = \begin{matrix} 0101 \\ 0001 \\ 1000 \\ 0010 \end{matrix}$$

✓ ***Матрица инцидентности***

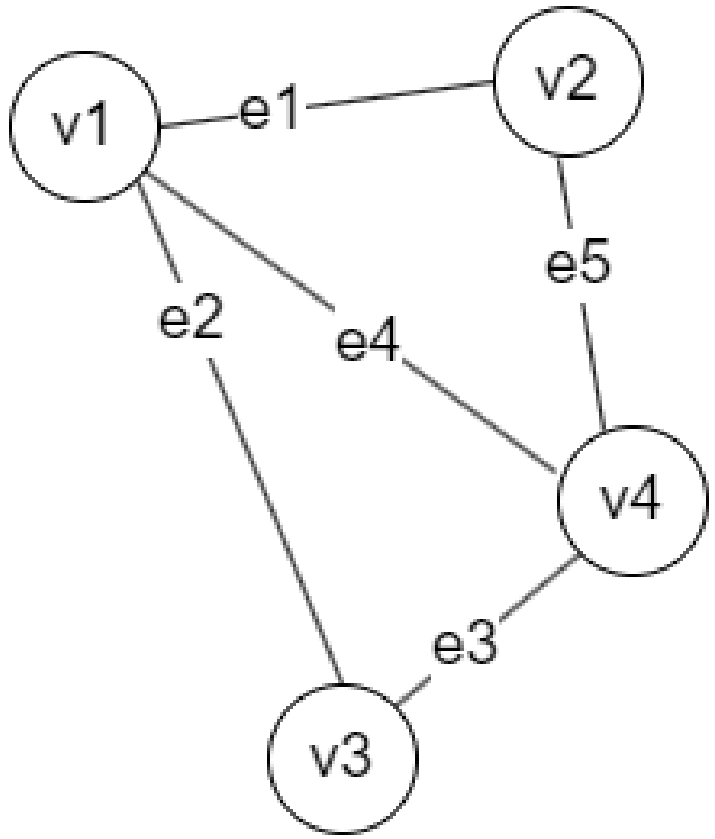
Пример для ориентированного графа (+1 входящее в вершину ребро, -1 исходящее, 0 – ребро отсутствует)

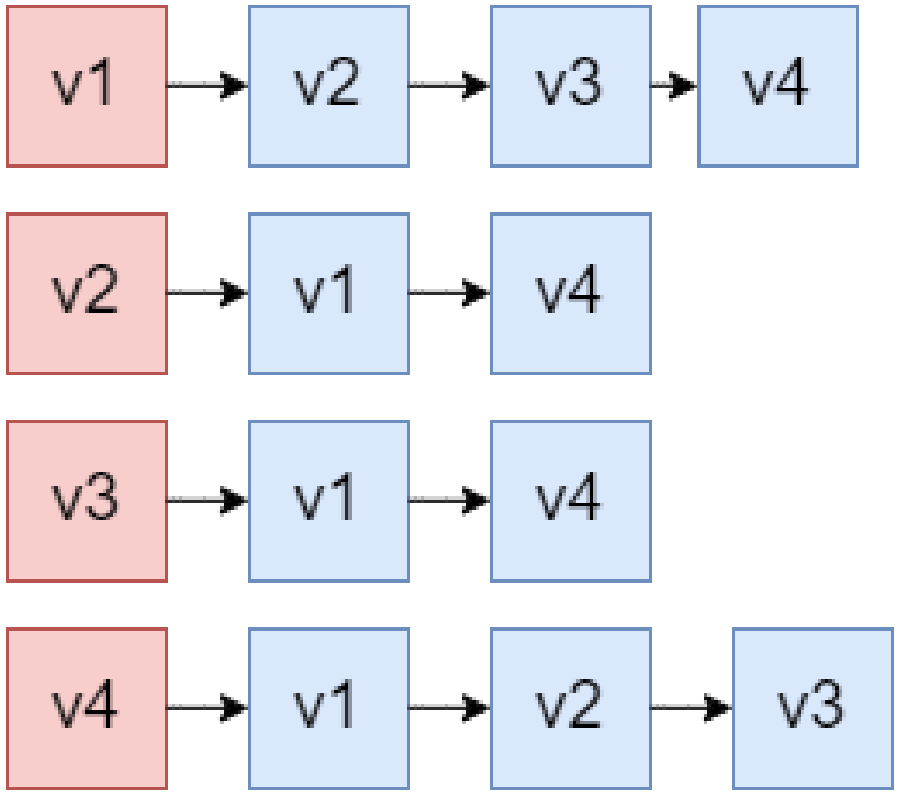
$$M = \begin{array}{c} \\ v1 \\ v2 \\ v3 \\ v4 \end{array} \begin{array}{c} e1,e2,e3,e4,e5 \\ -1\;\;1\;\;0\;\;-1\;\;0 \\ 1\;\;0\;\;0\;\;0\;\;-1 \\ 0\;\;-1\;\;1\;\;0\;\;0 \\ 0\;\;0\;\;-1\;\;1\;\;1 \end{array}$$

Представление графов

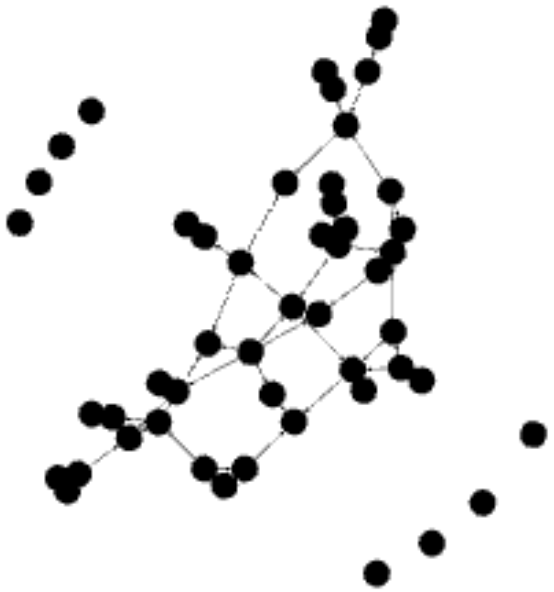
Для представления графов используются следующие структуры:

✓ ***Список смежности***





Разреженные графы

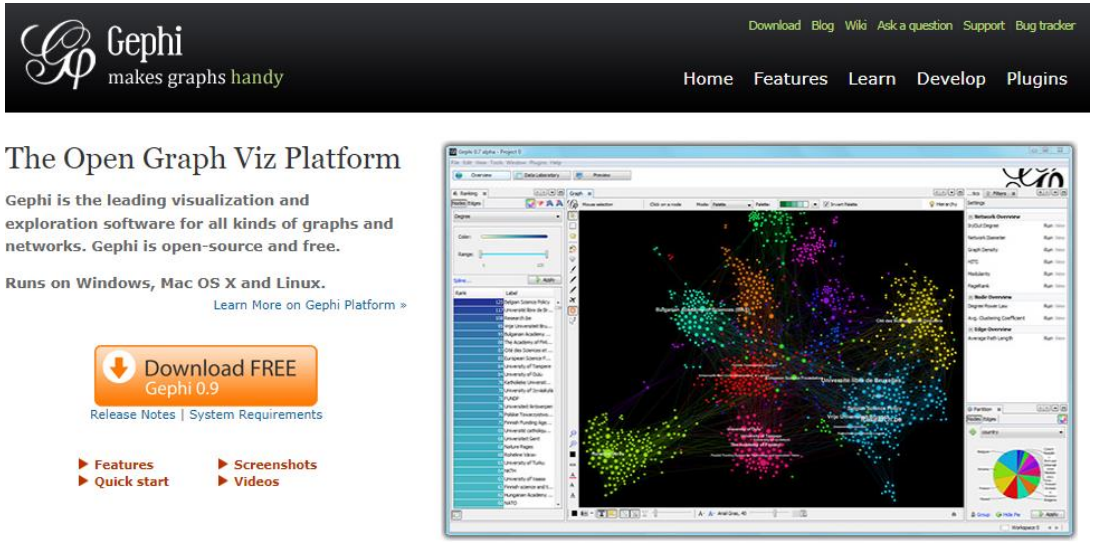


Граф, имеющий малое число рёбер, называют **разреженным графом**.

Матрица смежности разреженного графа будет заполнена преимущественно нулями.

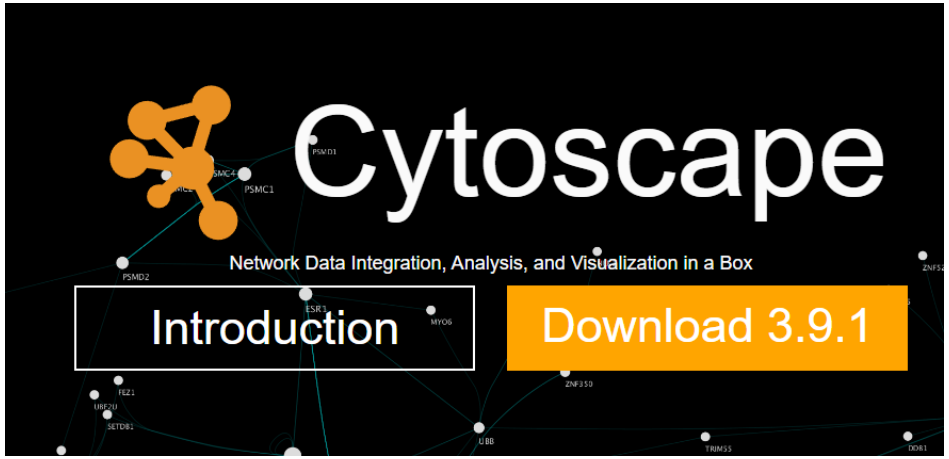
Для хранения разреженного графа используются специальные структуры и алгоритмы, позволяющие более эффективно обрабатывать небольшое число ребер.

Программные пакеты для анализа данных, представленных в виде графа



https://gephi.org/

Gephi— ведущее программное обеспечение для визуализации и исследования всех видов графиков и сетей. Gephi является бесплатным и открытым исходным кодом.



https://cytoscape.org/

Cytoscape — это программная платформа с открытым исходным кодом для визуализации сетей молекулярного взаимодействия и биологических путей и интеграции этих сетей с аннотациями, профилями экспрессии генов и другими данными.

TYCYP
TUSUR UNIVERSITY