ТУСУР
TUSUR UNIVERSITY

2.1 Предобработка структурированных данных

Векторное представление узлов графа (Обзор методов эмбеддинга графов (deepwalk, node2vec и т.п.).

05.10.2022

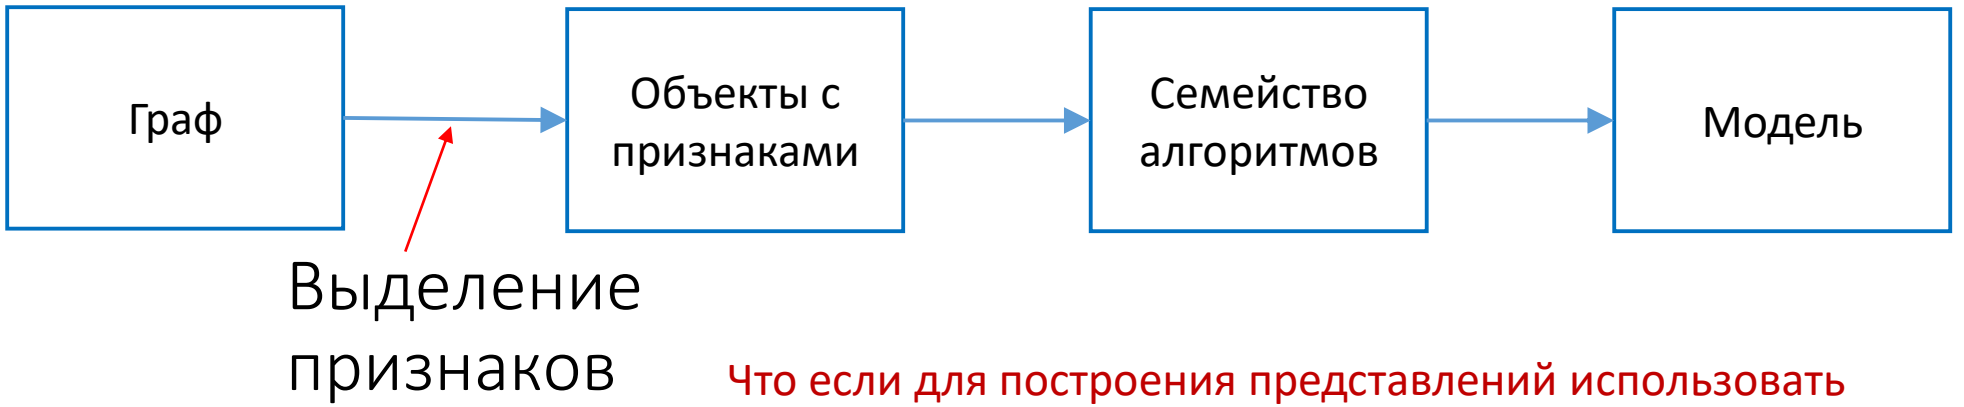
2.1 Предобработка структурированных данных

2. Векторное представление узлов графа (Обзор методов эмбеддинга графов (deepwalk, node2vec и т.п.).

Векторное представление узлов графа (эмбеддинг узлов графа)

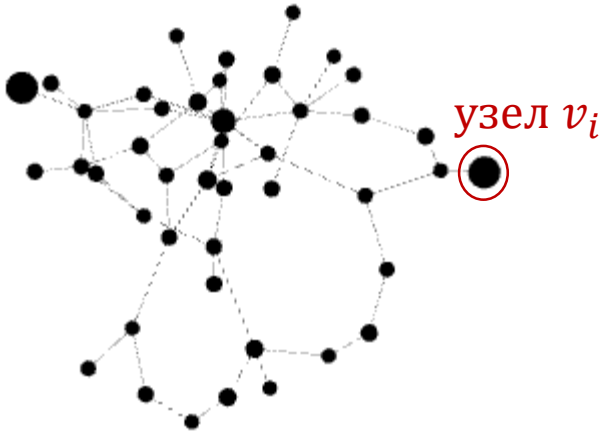
Пусть в качестве входных данных имеется граф *G*.

Классические методы машинного обучения направлены на то, что из графа извлекаются некоторые свойства узлов, связей, либо свойства, которые относятся в целом к графу и затем строятся объекты и определяются их свойства и далее формируются прогнозы, например, посредством решения задачи регрессии или классификации.



Что если для построения представлений использовать возможности машинного обучения?

Задача эмбеддинга узлов графа (graph node embedding task)



Эмбеддинг узла графа – это процесс замены узла графа вектором, так чтобы учесть в векторе информацию о положении вершины в графе.

$$f: v_i \rightarrow \mathbb{R}^d$$
$$i = 1 \ldots m,$$

Эмбеддинг/репрезентация



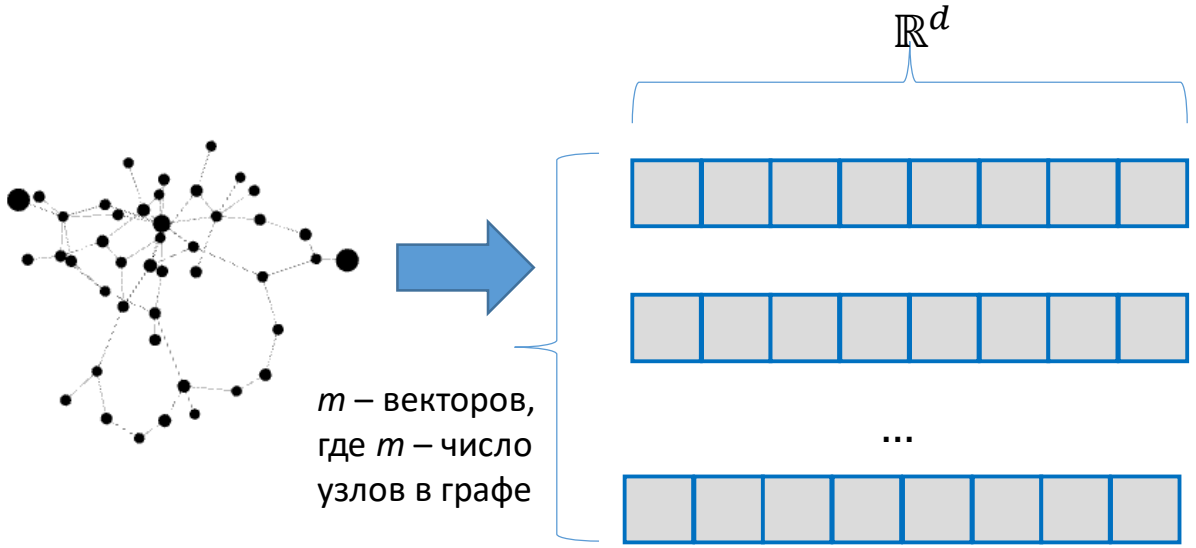
$\mathbb{R}^d$

Каждый узел графа представляется вектором действительных чисел длины *d*

Цель – найти такую функцию *f*, которая бы позволяла бы получить эмбеддинг любого узла в графе

Зачем переходить от графа к векторному представлению?

- ✓Схожие вектора означают, что и объекты схожи в рамках анализируемой сети.
- ✓Это способ кодирования графа.
- ✓Возможность решать задачи, работая с более простыми структурами, т.е. со списком объектов.



Задачи, которые могут решаться:

1. Классификация узлов графа

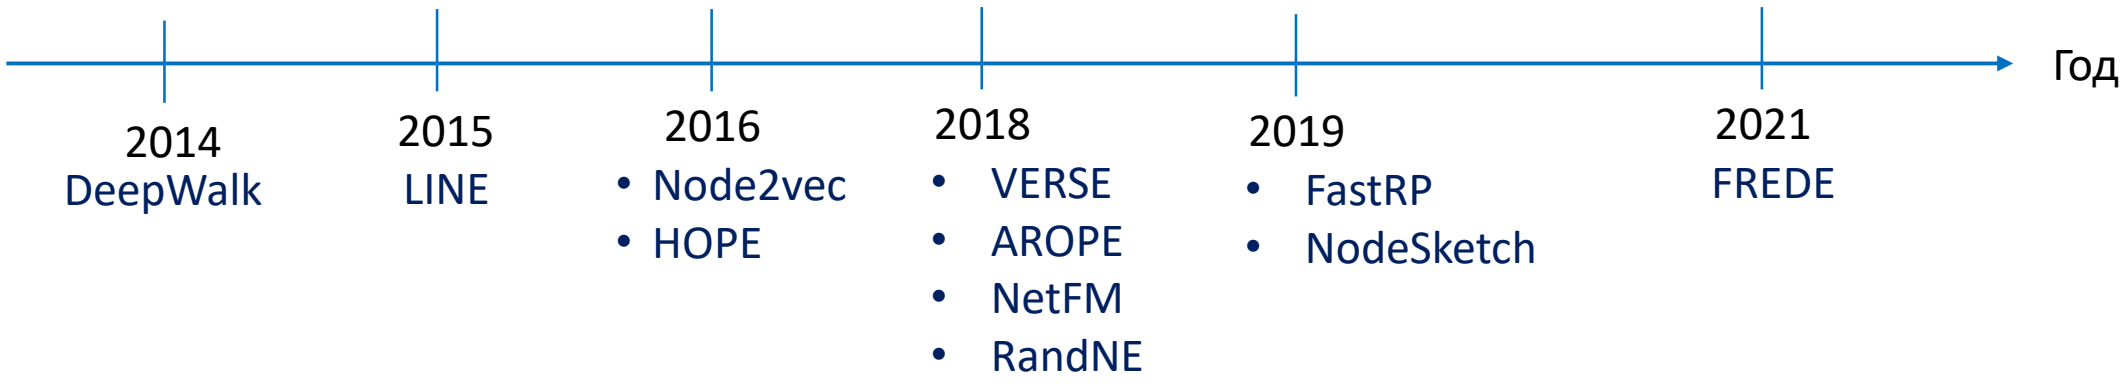
Например, если рассматривается социальный граф, то по политической принадлежности, геолокации и т.п.

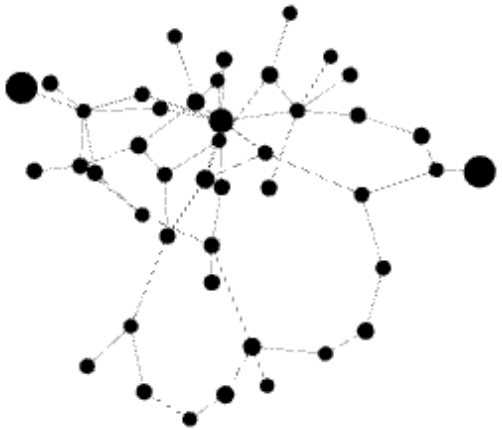
2. Прогноз связей между узлами

Например, если рассматривается социальный граф, то кого можно рекомендовать в друзья.

3. Классификация графов
4. Выявление аномалий
5. Разделение узлов на группы по схожести

Методы эмбеддинга узлов графа на временной оси





Сравнение методов эмбединга графов
URL: https://www.arxiv-vanity.com/papers/1705.02801/

Видео. Антон Цицулин. Эмбединги вершин без учителя URL:
https://www.youtube.com/watch?v=SQoAMMJ-uKc&list=PLYeFZ_T6PUrLmS3dE-8iYv9_tlseBvhxx&index=19

Ссылки на статьи с описанием методов эмбеддинга узлов графа

2014. PEROZZI, B., AL-RFOU, R. and SKIENA, S., 2014. DeepWalk: Online learning of social representations, *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* 2014, pp. 701-710. URL: https://arxiv.org/abs/1403.6652

2015. TANG, J., QU, M., WANG, M., ZHANG, M., YAN, J. and MEI, Q., 2015. LINE: Large-scale information network embedding, *WWW 2015 - Proceedings of the 24th International Conference on World Wide Web* 2015, pp. 1067-1077. URL: https://arxiv.org/abs/1503.03578

2016. GROVER, A. and LESKOVEC, J., 2016. Node2vec: Scalable feature learning for networks, *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* 2016, pp. 855-864. URL: https://arxiv.org/abs/1607.00653

2016. OU, M., CUI, P., PEI, J., ZHANG, Z. and ZHU, W., 2016. Asymmetric transitivity preserving graph embedding, *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* 2016, pp. 1105-1114. URL: https://www.kdd.org/kdd2016/papers/files/rfp0184-ouA.pdf

2018. TSITSULIN, A., MOTTIN, D., KARRAS, P. and MÜLLER, E., 2018. VERSE: Versatile graph embeddings from similarity measures, *The Web Conference 2018 - Proceedings of the World Wide Web Conference, WWW 2018* 2018, pp. 539-548. URL: https://arxiv.org/abs/1803.04742

2018**.** ZHANG, Z., PEI, J., CUI, P., YAO, X., WANG, X. and ZHU, W., 2018. Arbitrary-order proximity preserved network embedding, *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* 2018, pp. 2778-2786. URL: http://pengcui.thumedialab.com/papers/NE-ArbitraryProximity.pdf

2018. QIU, J., DONG, Y., MA, H., LI, J., WANG, K. and TANG, J., 2018. Network embedding as matrix factorization: Unifying DeepWalk, LINE, PTE, and node2vec, *WSDM 2018 - Proceedings of the 11th ACM International Conference on Web Search and Data Mining* 2018, pp. 459-467. URL: https://arxiv.org/abs/1710.02971

2018. ZHANG, Z., CUI, P., LI, H., WANG, X. and ZHU, W., 2018. Billion-Scale Network Embedding with Iterative Random Projection, *Proceedings - IEEE International Conference on Data Mining, ICDM* 2018, pp. 787-796. URL: https://arxiv.org/abs/1805.02396

2019. CHEN, H., SULTAN, S.F., TIAN, Y., CHEN, M. and SKIENA, S., 2019. Fast and accurate network embeddings via very sparse random projection, *International Conference on Information and Knowledge Management, Proceedings* 2019, pp. 399-408. URL: https://arxiv.org/abs/1908.11512

2019. YANG, D., ROSSO, P., LI, B. and CUDRE-MAUROUX, P., 2019. Nodesketch: Highly-efficient graph embeddings via recursive sketching, *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* 2019, pp. 1162-1172. URL: https://exascale.info/assets/pdf/yang2019nodesketch.pdf

2021. TSITSULIN, A., MUNKHOEVA, M., MOTTIN, D., KARRAS, P., OSELEDETS, I. and MÜLLER, E., 2021. FREDE: Anytime graph embeddings. *Proceedings of the VLDB Endowment,* **14**(6), pp. 1102-1110. URL: http://www.vldb.org/pvldb/vol14/p1102-mottin.pdf

Работа с векторными представлениями узлов графа

Пусть *ENC* – функция, которая позволяет получить векторной представление некоторой вершины *v* графа *G* т.е.

$$ENC(v) = z_v = Z \cdot v$$

$Z \in \mathbb{R}^{d \times |V|}$, *V* – множество вершин графа G, *d* – заранее заданная длина вектора

Z – матрица, в которой каждый столбец – это векторное представление соответствующей вершины

$$v \in I^{|V|}$$

I – вектор для индикации нужного столбца в матрице Z

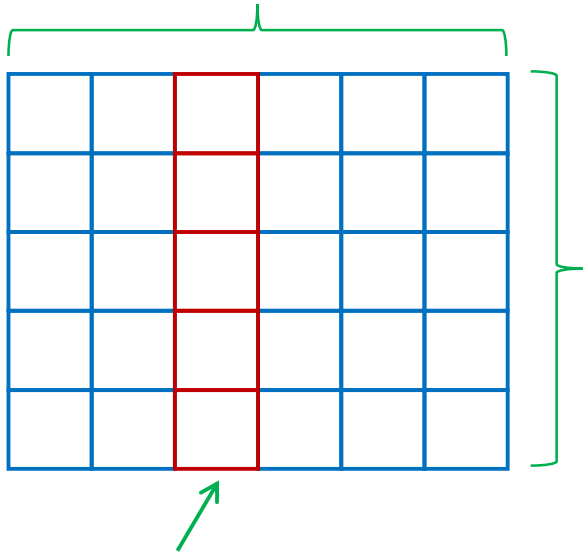
Таким образом, требуется получить матрицу *Z* для того чтобы выполнять эмбеддинг узлов графа

Работа с векторными представлениями узлов графа

Количество столбцов = $|V|$
т.е. числу узлов в графе

Матрица векторных представлений

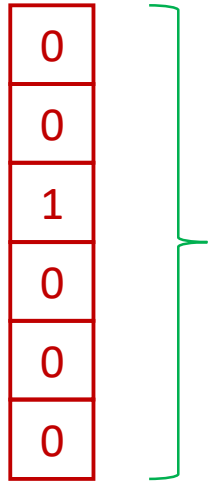
$Z =$



Количество строк = d
(dimensional size)
выбирается заранее как гиперпараметр алгоритма

Столбец j – это векторное представление узла v_j

Вектор для индикации нужного столбца в матрице Z



Количество строк = $|V|$

Случайные блуждания и Word2Vec

Томаш Миколов в 2013г. предложил использовать модель дистрибутивной семантики для получения векторного представления слов текста [Mikolov T. et al. Efficient estimation of word representations in vector space URL: https://arxiv.org/abs/1301.3781]

- ✓ Идея – моделировать распределение вероятности соседних слов в тексте
- ✓ Использовать локальный контекст - окно небольшой длины



В начале мы пошли в магазин, а затем в парк.

Word2Vec. модель SkipGram

Прогноз контекста по центральному слову

$$\sum_{CenterWi} P(CtxW_{-2}, CtxW_{-1}, CtxW_{+1}, CtxW_{+2} | CenterW_i; W, D) \rightarrow \max_{W,D}$$

W – матрица центральных слов;

D – матрица контекстных слов.

$CtxW_{-2}$ – контекстное слово в окне отстоящие на 2 позиции от центрального

Предполагается, что соседние слова условно независимы друг от друга:

$$P(CtxW_{-2}, CtxW_{-1}, CtxW_{+1}, CtxW_{+2} | CenterW_i; W, D) = \prod_j P(CtxW_j | CenterW_i; W, D)$$

Softmax используется для моделирования условной вероятности встретить контекстное слово при условии центрального

$$P(CtxW_j | CenterW_i; W, D) = \frac{e^{w_i d_j}}{\sum_{m=1}^{|V|} e^{w_i d_m}}$$ $|V|$ - размер словаря слов

Аппроксимация Softmax – отрицательное сэмплирование(Negative sampling)

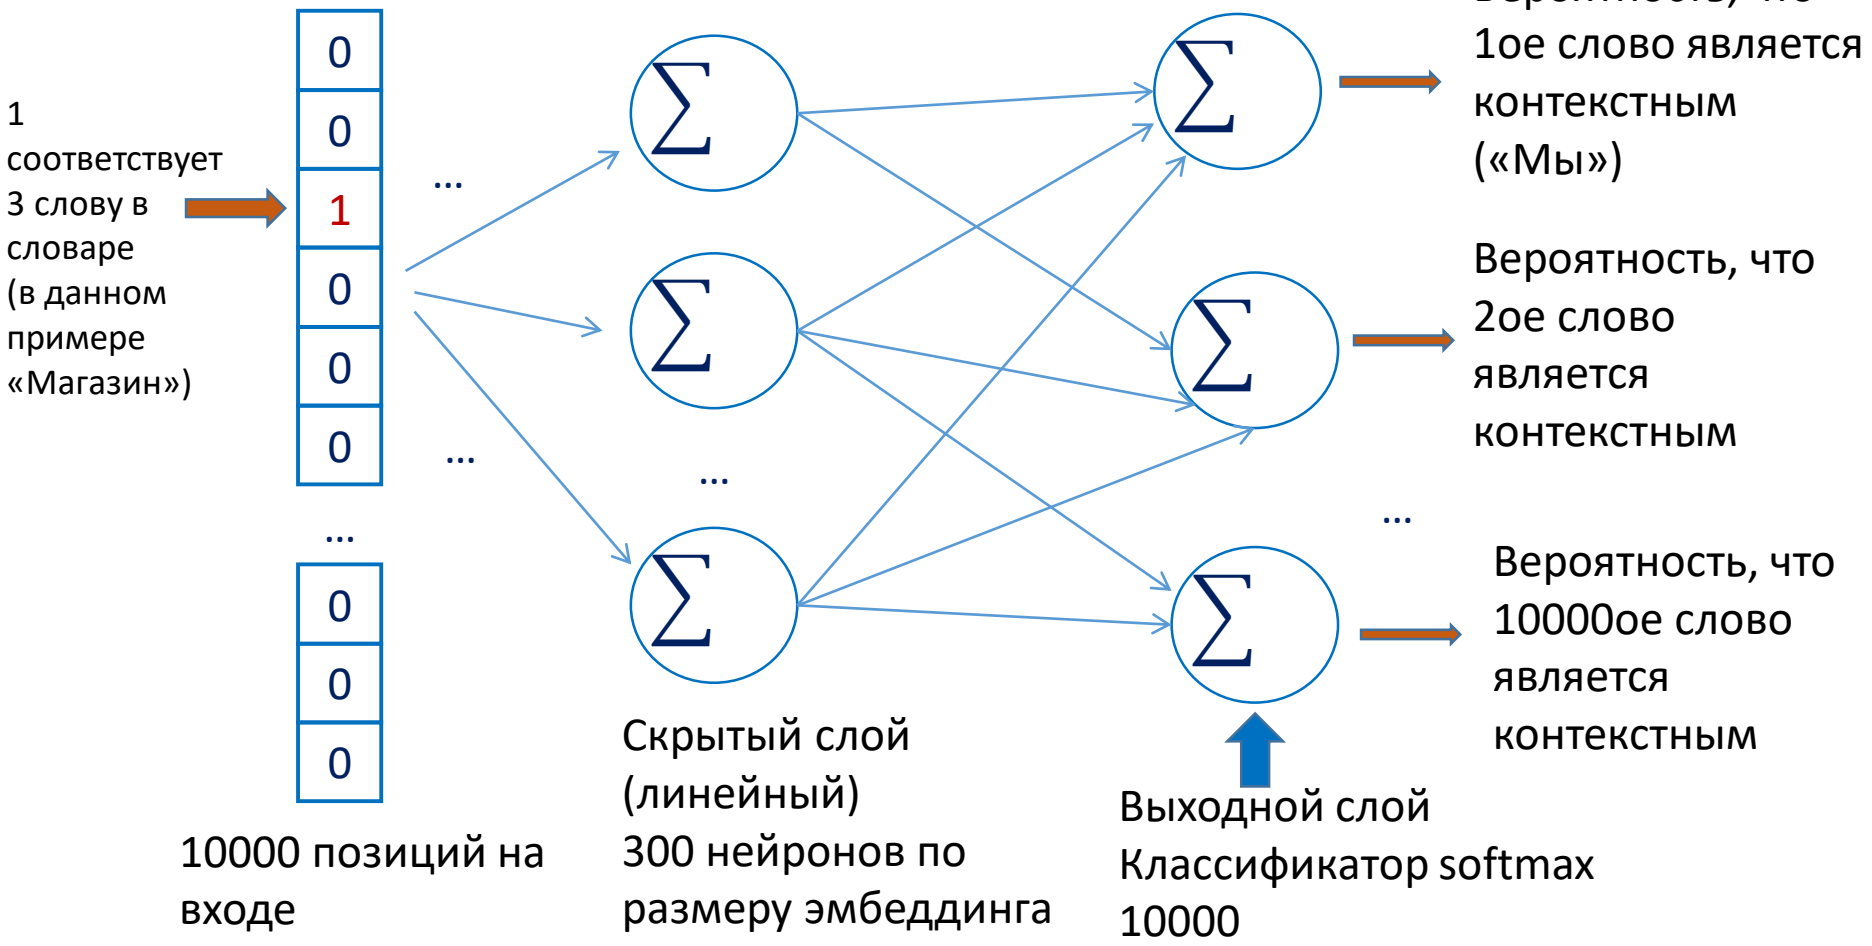
$$P(CtxW_j | CenterW_i; W, D) \cong \frac{e^{w_i d_j}}{\sum_{m=1}^{k} e^{w_i d_m}} \quad k \ll |V|$$

Word2Vec. SkipGram архитектура

Пусть необходимо каждое слово представить вектором длиной 300. Т.е. Embeding size = 300. На входе имеется словарь из 10 тыс. слов. Т.е. $|V|$=10000

V={
Мы,
Пошли,
Магазин,
Парк,
Лес,
…
}

Словарь, составленный по тексту.



Word2Vec. модель модель Cbow

Прогноз центрального слова по контекстным словам

$$\sum_{CenterWi} P(CenterW_i|CtxW_{-2}, CtxW_{-1}, CtxW_{+1}, CtxW_{+2}; W, D) \rightarrow \max_{W,D}$$

W – центральных слов; D – матрица контекстных слов.

Обозначим за контекст $Ci = (CtxW_{-2}, CtxW_{-1}CtxW_{+1}, CtxW_{+2})$

$$\sum_{CenterWi} P(CenterW_i|C_i ; W, D) \rightarrow \max_{W,D}$$

Для того, чтобы промоделировать данные вероятности, используется средний вектор слов из контекста:

$$d^{-i} = \frac{1}{2k} \sum_{w \in V \text{ (словарь)}} d_w$$

$$P(CenterW_i|C_i; W, D) = \underset{w \in V}{Softmax(W_w, d^{-i})}$$

DeepWalk. Описание метода

Алгоритм DeepWalk (G, *w*, *d*, ϒ, *t*)

На входе:

- ✓ Граф *G*(*V*,*E*)
- ✓ Размер окна *w*
- ✓ Количество измерений *d*
- ✓ Число случайных блужданий, приходящихся на каждый вектор ϒ
- ✓ Длина случайных блужданий *t*

На выходе:

Матрица векторных представлений $\Phi \in \mathbb{R}^{|V| \times d}$

1. Инициалиция Φ
2 Построить бинарное дерево *T* из *V*
3. Цикл i=0 до ϒ
4. *O* = Перемешиваем (*V*)
5. Для Каждой вершины v_i из O
6. Wv_i =RandomWalk(*G*, v_i , *t*)
7. SkipGram(**Φ**, Wv_i , *w*)
8. КонецЦикла
9. КонецЦикла

Algorithm 1 DeepWalk(G, w, d, γ, t)

Input: graph $G(V, E)$
window size w
embedding size d
walks per vertex γ
walk length t
Output: matrix of vertex representations $\Phi \in \mathbb{R}^{|V| \times d}$

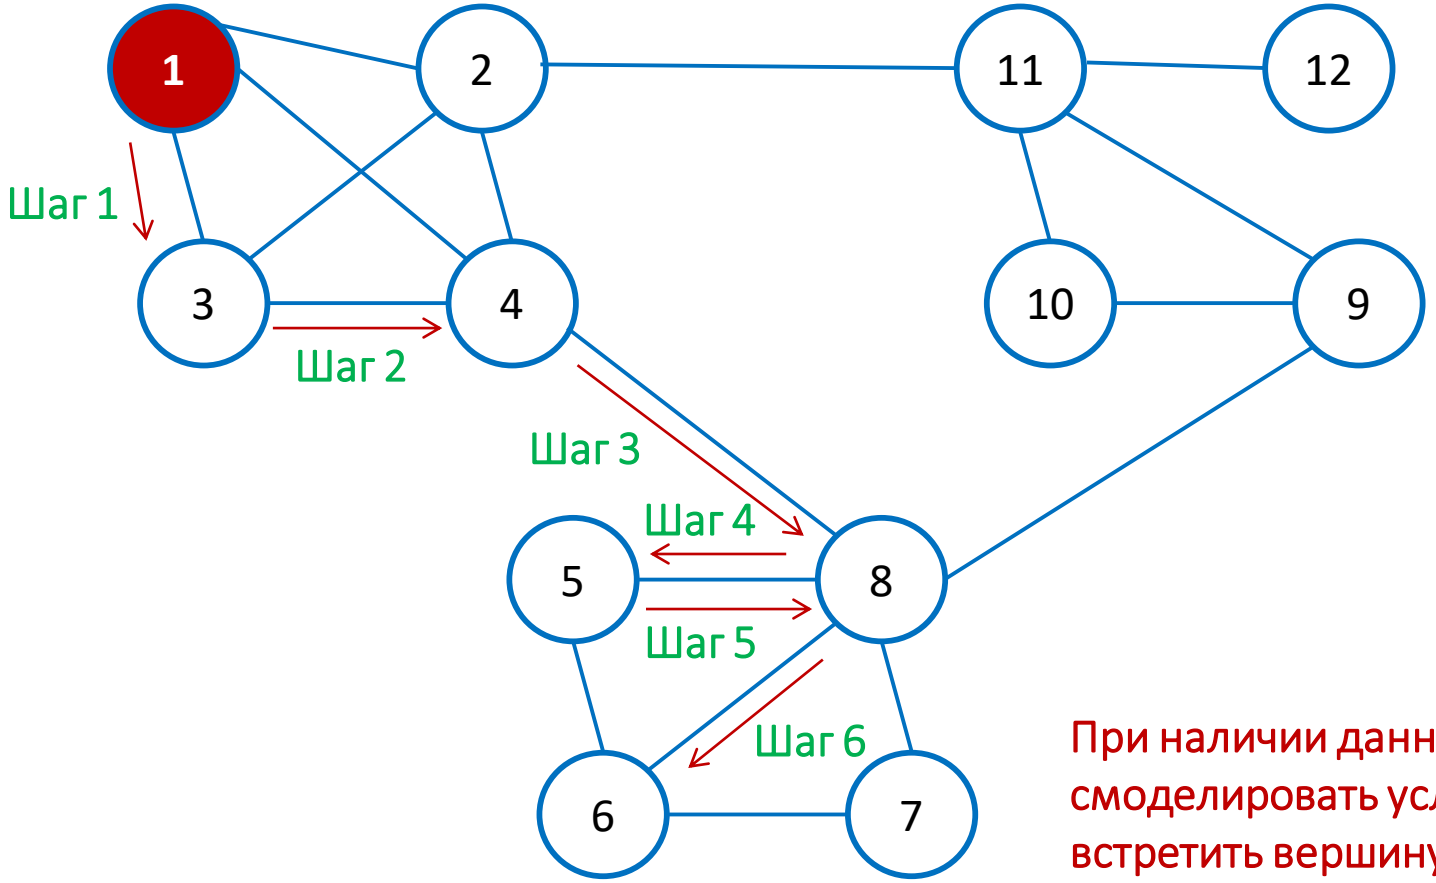
```
Initialization: Sample Φ from U^{|V|×d}
Build a binary Tree T from V
for i = 0 to γ do
    O = Shuffle(V)
    for each v_i ∈ O do
        W_{v_i} = RandomWalk(G, v_i, t)
        SkipGram(Φ, W_{v_i}, w)
    end for
end for
```

В оригинальной работе SoftMax аппроксимируется иерархическим софтмаксом [PEROZZI, B., AL-RFOU, R. and SKIENA, S., 2014. DeepWalk: Online learning of social representations].

Рекомендации:

- ✓ Используйте рекомендуемые практические значения гиперпараметров: ϒ=80, *t*=80, *w* = 10.
- ✓ По возможности не меняйте размер окна.
- ✓ Если размер окна уменьшаете, увеличивайте значения параметров ϒ и *t*.

Случайные блуждания



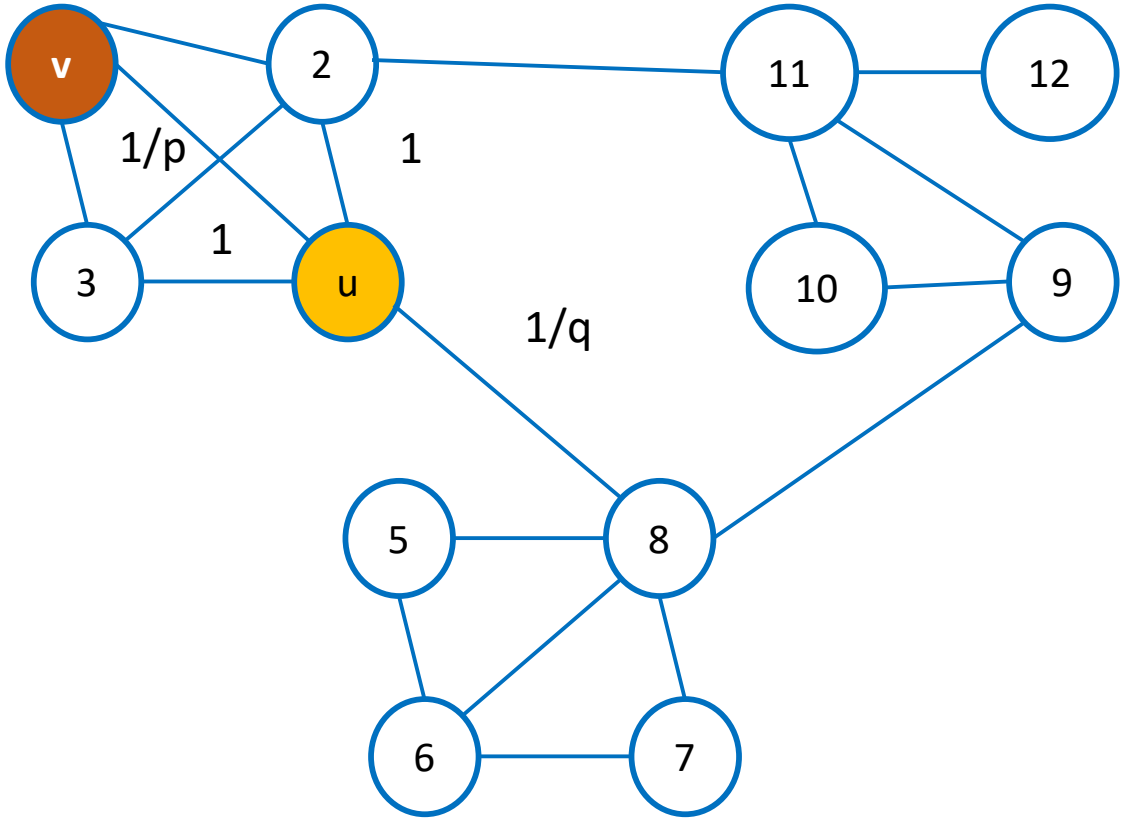
Выбирается случайным образом узел (узел 1, например), далее случайным образом выбирается следующий (узел 3, например) ,
из списка инцидентных {3,2,4} и выполняется шаг 1, и далее повторяем процедуру k раз.
Полученный список узлов, является случайным блужданием.
1 3 4 8 5 8 6

При наличии данных о случайных блужданиях можно смоделировать условное распределение вероятности встретить вершину в контексте другой вершины.

Node2Vec. Случайные блуждания 2 порядка

В отличие от DeepWalk :

- ✓ добавляется 2 дополнительных параметра ***p*** и ***q***, которые используются для обеспечения случайных блужданий 2ого порядка
- ✓ в качестве аппроксимации Softmax – используется негативный сэмплинг (negative sampling).

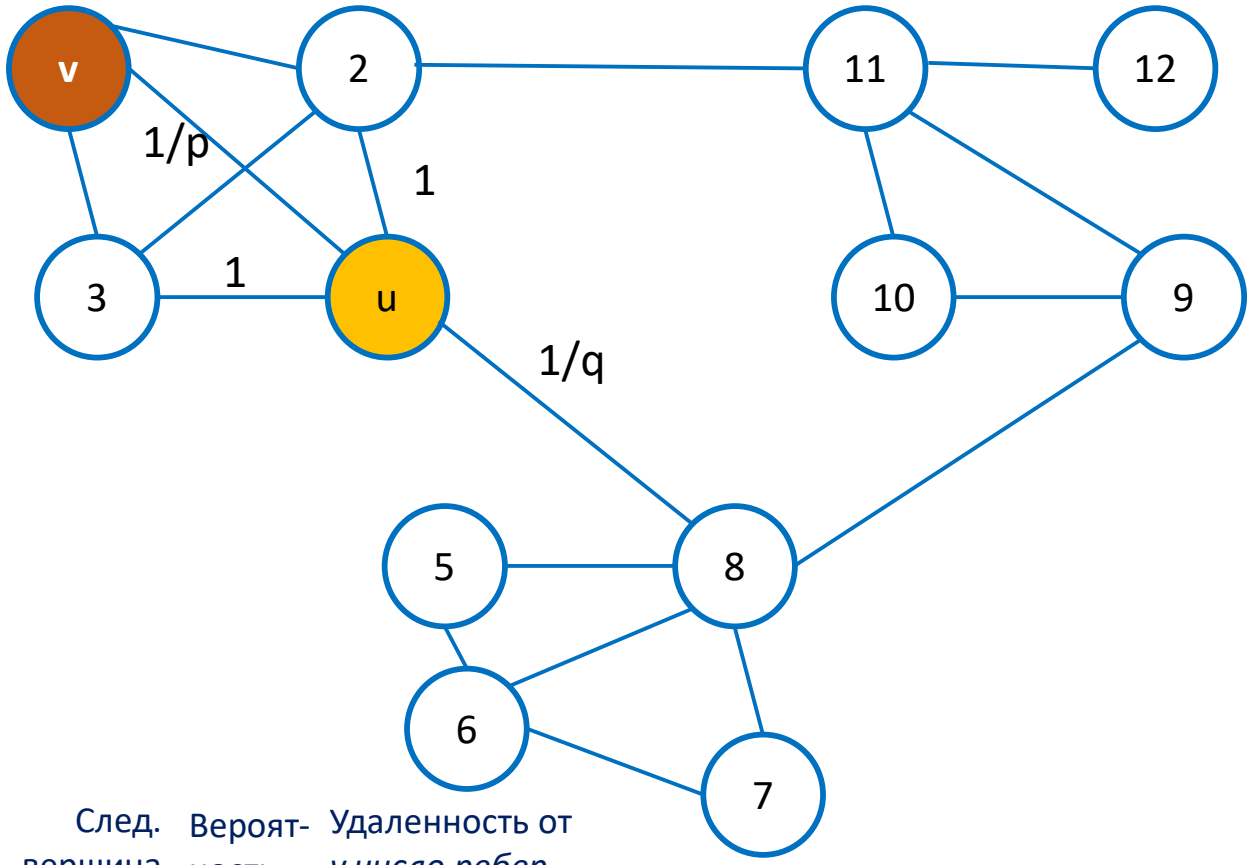


Высокий q – изучаем данные структуру внутри кластера.
Низкий q – изучаем структуру за пределами кластера.
Параметры p и q связаны с треугольниками – кластерами на графах.

Пример блуждания в рамках кластера:
v-3-2-u

Пример блуждания за пределами кластера:
v-2-11-9

Node2Vec. Случайные блуждания 2 порядка

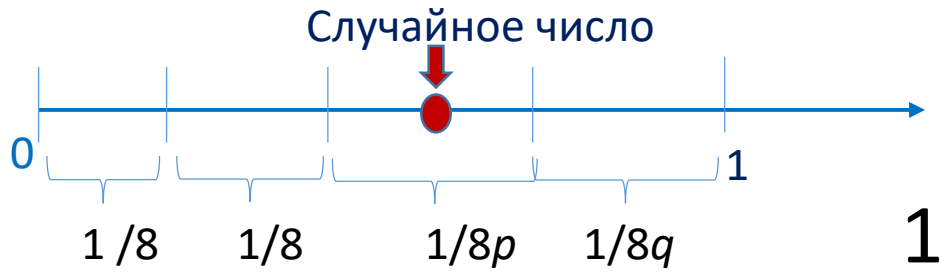


	След. вершина	Вероятность	Удаленность от *v* число ребер
	v	1/*p*	0
u→	2	1	1
	3	1	1
	8	1/*q*	2

Ненормализованная вероятность

Порядок блуждания:

- ✓ Начинаем с вершины *v*. Далее случайным образом выбираем вершину, пусть это будет вершина *u* для примера.
- ✓ Затем, выполняем блуждание 2 порядка из вершины u. Для этого необходимо выбрать следующую вершину, опираясь на веса:
  {1 , 1, 1/p 1/q} → Нормализация вероятностей (т.е. так, чтобы сумма вероятностей =1)
  Например, если p = 0,5, q = 0,25
  1+1+1/0,5 + 1/0,25 = 8
  Разделим на 8 все веса и получим нормализованные вероятности.
  {1 /8, 1/8, 1/8p 1/8q}
  Разыгрываем вероятности путем генерации случайного числа от 0 до 1.



Автокодировщик. Применение данных эмбединга в обучении с учителем

Если данные эмбединга будут применяться в задачах обучения с учителем, то можно выделить следующие стратегии решения конечной задачи

Стратегия 1.

1. Решить задачу эмбединга
2. Решить задачу классификации/регрессии (т.е. задачу машинного обучения с учителем)

Задача 1 и 2 решаются независимо

Стратегия 2.

Решать задачи 1 и 2 совместно, формулируя совместную оптимизационную задачу.
Таким образом, векторное представление будет таким, чтобы оно максимально хорошо подходило бы для конечной задачи классификации.

Подробнее смотреть литературу:

1. Bank D., Koenigstein N., Giryes R. Autoencoders // Computer Science. 2021.
2. Векторные представления текстов и графов. Машинное обучение (курс лекций, К.В.Воронцов) // http://www.machinelearning.ru/ URL: http://www.machinelearning.ru/wiki/images/9/98/Voron-ML-Embeddings-slides.pdf (дата обращения: 03.09.2022).

Автокодировщик. Применение данных эмбединга в обучении с учителем

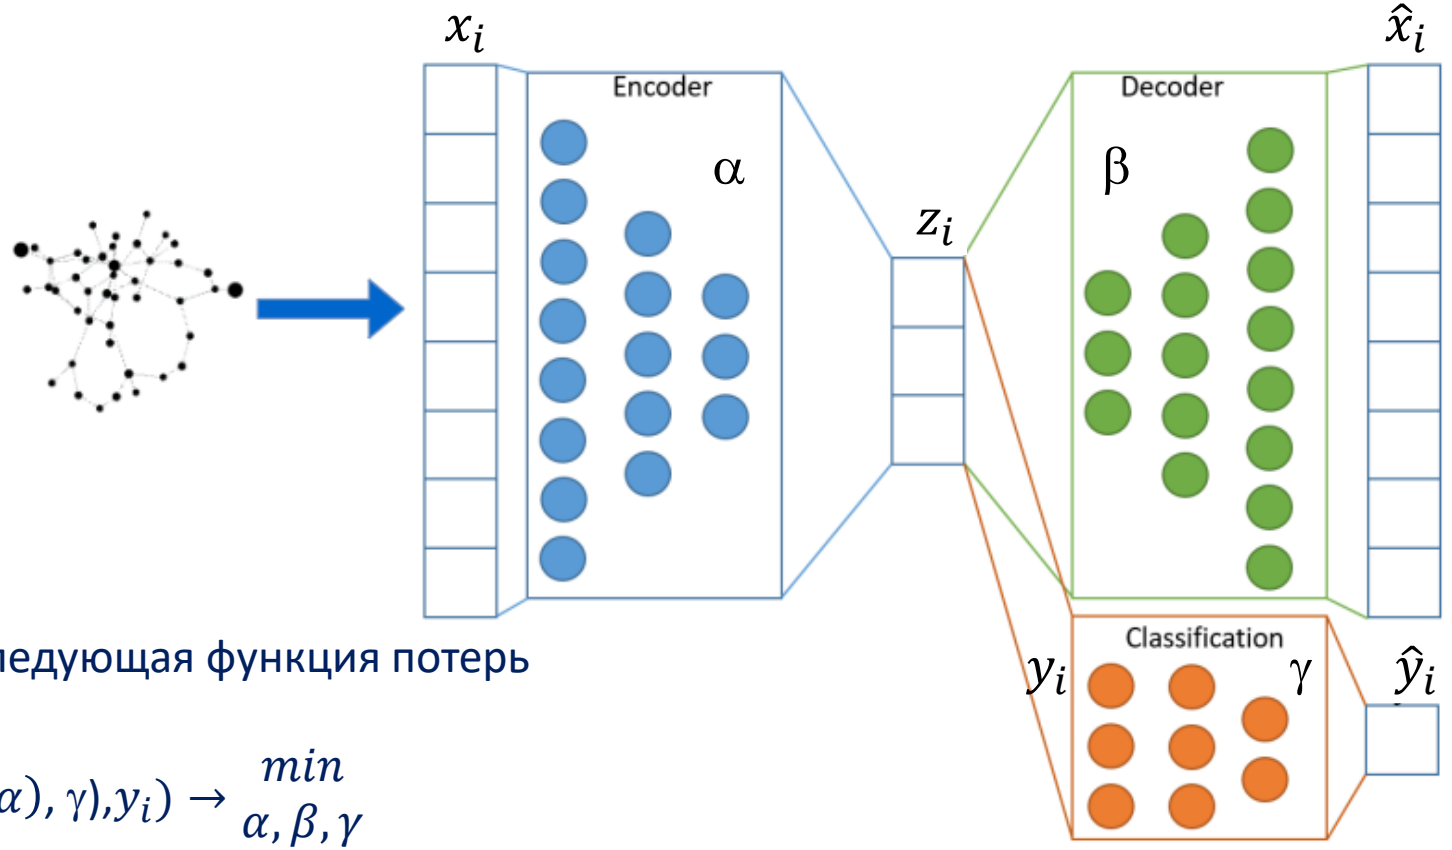
Дано: неразмеченные данные $X^l = \{x_1, x_2, \dots x_l\}$

размеченные данные $X^k = \{x_{l+1}, x_{l+2}, \dots x_{l+k}\}$, $Y^k = \{y_{l+1}, y_{l+2}, \dots y_{l+k}\}$

Кодировщик - $z_i = f(x_i, \alpha)$

Декодировщик - $\hat{x}_i = g(z_i, \beta)$

Классификатор - $\hat{y}_i = \hat{y}(z_i, \gamma)$



Функции потерь:

$L(\hat{x}_i, x_i)$ – реконструкция

$\hat{L}(\hat{y}_i, y_i)$ – предсказание

Для совместного обучения кодировщика, декодировщика и предсказательной модели (т.е. Классификация/регрессия) используется следующая функция потерь

$$\sum_{i=1}^{l} L(g(f(x_i, \alpha), \beta), x_i) + \lambda \sum_{j=l+1}^{l+k} L(\hat{y}(f(x_i, \alpha), \gamma), y_i) \to \min_{\alpha, \beta, \gamma}$$

TYCYP
TUSUR UNIVERSITY