ТУСУР
TUSUR UNIVERSITY

2.2 Методы обучения без учителя

Обучение без учителя. Кластеризация. Меры сходства, используемые в кластерном анализе. Методы кластеризации, иерархическая кластеризация, кластеризация, основанная на плотности на примере DBSCAN. Affinity propagation, Метод k-средних kmeans. Выбор оптимального числа кластеров, для методов, требующих данный гиперпараметр. Модельные методы на примере EM метода, сеточная кластеризация.

28.09.2022

2.2 Методы обучения без учителя

План:

1. Типы задач обучения без учителя
2. Кластерный анализ. Постановка задачи
3. Формы кластерных структур
4. Методы кластеризации. K-means (метод к-средних)
5. Методы кластеризации. EM-алгоритм (Expectation-Maximizatio...
6. Иерархическая кластеризация
7. Алгоритм кластеризации DBScan (Density-based spatial clus...
8. Affinity propagation Метод распространения близости
9. Сеточные методы кластеризации
10. CLIQUE. Описание метода

Обучение без учителя

Обучение без учителя – это раздел машинного обучения, изучающий широкий класс задач обработки данных, в которых известны только описания множества объектов (обучающей выборки).

Входные данные представлены:

- ✓Признаковым описанием объектов X т.е. $f_j: X \to D_j, j = 1, \dots n$ – признаки объектов
- ✓Матрицей расстояний между объектами X т.е. $\mathrm{P} = \left\| \rho(x_i, x_j) \right\|_{l \times l}$

X – пространство объектов

$X^l = \{x_1, x_2, \dots x_l\}$ - обучающая выборка

$\rho: X \times X \to [0, +\infty)$ - функция расстояния между объектами

Типы задач обучения без учителя

✓ Кластерный анализ (кластеризация)

Понимание данных, вспомогательный инструмент при решении задач классификации и регрессии.

Социология – разбиение респондентов на однородные группы, маркетинговые исследования - сегментация рынка по группам товаров или потребителей, определение потенциального потребителя;

✓ Задача обнаружения аномалий

Обнаружение подозрительных банковских операций, Обнаружение нестандартных игроков на бирже (инсайдеров), Обнаружение неполадок в механизмах по показаниям датчиков

✓ Задачи визуализации

✓ Задачи сокращения размерности

✓ Задачи поиска ассоциативных правил

Анализ рыночных корзин: выявление сочетаний товаров, часто встречающихся вместе в покупках клиентов.

Кластерный анализ. Постановка задачи

Дано:

X – пространство объектов

$X^l = \{x_1, x_2, \dots x_l\}$ - обучающая выборка

$\rho: X \times X \to [0, +\infty)$ - функция расстояния между объектами

Требуется найти:

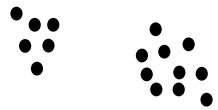
$y_i \in Y$ – метки кластеров объектов

Y – множество меток кластеров

Каждый кластер составляется из близких объектов, т.е. объекты из разных кластеров должны имеют значительные отличия друг от друга.

Формы кластерных структур

✓Разбиения



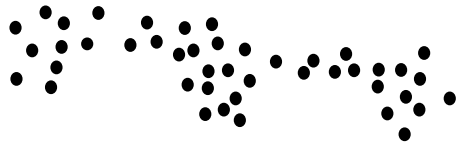
Внутрикластерные расстояния
обычно меньше межкластерных.

✓Множество центройдов



Каждый объект можно приписать одному из центроидов согласно так называемому принципу минимального расстояния – ближайшему в рассматриваемой метрике.

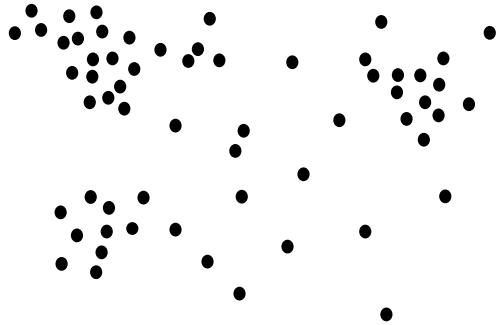
✓Разбиения с перемычками



Кластеры дополнительно могут соединяться перемычками.

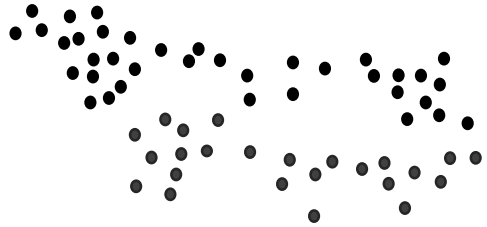
Формы кластерных структур

✓Отдельные кластеры

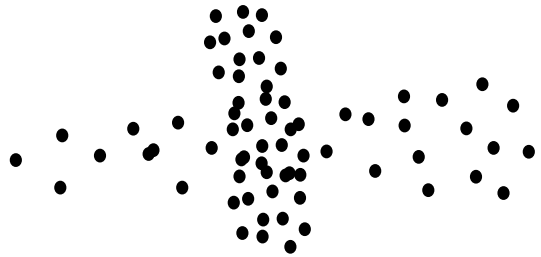


Кластеры могут «накладываться» на
фон из редко расположенных объектов

✓Ленточные кластеры



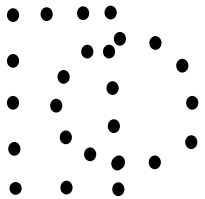
✓Аддитивные кластеры



Совокупность отдельных кластеров, обычно
пересекающихся, в которой каждый кластер ассоциирован
с положительной величиной – плотностью объектов
(интенсивностью кластера)

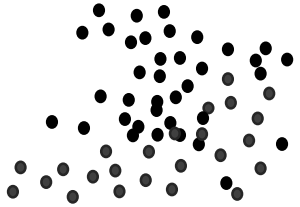
Формы кластерных структур

✓Кластеры с другим типом регулярности



Интуитивно можно увидеть два кластера, однако такой и подобные примеры представляют трудность для алгоритмов, основанных на попарной близости точек.

✓Отсутствие кластеров



Трудно выделить компактные области объектов в едином облаке точек, густота которых произвольно меняется.

Меры сходства

✓**Меры расстояния**

Неотрицательная вещественная функция $\rho(x_i, x_j)$ называется функцией расстояния или метрикой, если выполняются следующие условия:

- $\rho(x_i, x_j) > 0$ для всех $x_i \neq x_j$ из Евклидова пространства. Чем более непохожи объекты, тем больше значение функции расстояния. Различимость нетождественных объектов
- $\rho(x_i, x_j) = 0$ тогда и только тогда, когда $x_i = x_j$ Неразличимость идентичных объектов
- $\rho(x_i, x_j) = \rho(x_j, x_i)$ Свойство симметрии
- $\rho(x_i, x_j) \leq \rho(x_i, x_k) + \rho(x_k, x_j)$, где x_i, x_j, x_k любые объекты из Евклидова пространства Свойство неравенства треугольника

✓**Коэффициенты корреляции**

✓**Коэффициенты ассоциативности**

Известные меры расстояния

Дано:

X – пространство объектов

$X^l = \{x_1, x_2, \dots x_l\}$ - обучающая выборка

Каждый объект $x_i, i = [1 \dots l]$, задан при помощи признакового описания т.е. $f_j: X \to D_j, j = 1, \dots m$ – признаки объектов. D_j - количественный признак.

- ✓ **Евклидово расстояние** – геометрическое расстояние между точками в многомерном пространстве.

$$\rho = \sqrt{\sum_{k=1}^{m} (f_k(x_i) - f_k(x_j))^2}$$

Требуется нормализация, для того, чтобы вклад каждого признака в меру расстояния был одинаков.

Известные меры расстояния

- ✓ **Квадрат Евклидова расстояния** – используется, в случае, если необходимо придать большие веса более отдаленным друг от друга объектам.

$$\rho = \sum_{k=1}^{m} (f_k(x_i) - f_k(x_j))^2$$

- ✓ **Расстояние городских кварталов (манхэттенское расстояние).**

$$\rho = \sum_{k=1}^{m} \left| f_k(x_i) - f_k(x_j) \right|$$

Одно из достоинств - с способность уменьшить влияние «выбросов» по отдельным признакам на величину расстояния, по причине того, что разница по признакам не возводится в квадрат. В остальном, мера схожа с Евклидовым расстоянием.

Известные меры расстояния

- ✓ **Расстояние Чебышева** – используется при необходимости определить два объекта в разные классы в зависимости от различий между ними по одному наиболее значимому признаку.

$$\rho = \max_k \left| f_k(x_i) - f_k(x_j) \right|, \mathrm{k} = 1 \dots m$$

- ✓ **Степенное расстояние (обобщенный вариант расстояния, предложенный Г. Минковским) – используется при необходимости прогрессивно увеличить или уменьшить вес, относящийся к определенной размерности, для которой соответствующие объекты сильно отличаются.**

$$\rho = \left(\sum_{k=1}^{m} \left| f_k(x_i) - f_k(x_j) \right|^p \right)^{1/p}$$

Если $p \geq 1$ расстояние Минковского является метрикой.

Если $p < 1$ расстояние не является метрикой, т.к. нарушается неравенство треугольника.

Если $p \to \infty$ метрика обращается в расстояние Чебышёва

Коэффициенты корреляции как меры сходства

✓**Коэффициенты корреляции могут использоваться в качестве меры сходства, однако следует учитывать особенности:**

- Диапазон значений коэффициента корреляции $r = [-1 \dots 1]$, где ± 1 сильная связь, значение 0 – связь отсутствует. На практике можно использовать меру $1 - |r|$
- Возможность наличия скрытого фактора (ложная корреляция)
- Коэффициент корреляции не является метрикой расстояния, т.е. не удовлетворяет 4ом условиям. На практике можно использовать меру на основе коэффициента корреляции, либо выбирать методы кластеризации, которые могут использовать не только меры расстояний.

Например, коэффициент корреляции Пирсона может быть использован как мера сходства:

$$r(x_i, x_j) = \frac{\frac{1}{m-1}\sum_{k=1}^{m}(f_k(x_i)-\bar{f}(x_i))(f_k(x_j)-\bar{f}(x_j))}{\sqrt{\frac{1}{m-1}\sum_{k=1}^{m}\left(f_k(x_i)-\overline{f(x_i)}\right)^2}\sqrt{\frac{1}{m-1}\sum_{k=1}^{m}\left(f_k(x_j)-\overline{f(x_j)}\right)^2}}$$

Коэффициенты корреляции как меры сходства

- ✓Расстояние Махаланобиса представляет собой обобщение Евклидова расстояния, которое также учитывает корреляцию между наблюдениями. Расстояние Махаланобиса является метрикой.

$$\rho(x_i, x_j) = \sqrt{(x_i - x_j)^T \Sigma^{-1} (x_i - x_j)}$$

Σ^{-1} –ковариационная матрица двух объектов

$x_i - x_j$ – расстояние между объектами (Евклидово расстояние)

Если корреляция между объектами отсутствует, то расстояние Махаланобиса сводится к обычному Евклидову расстоянию.

Коэффициенты корреляции как меры сходства

Ковариация — это численное выражение свойства ковариантности двух признаков точек. Свойство ковариантности означает, что признаки имеют тенденцию изменяться совместно (ковариантно).

Ковариационная матрица состоит из ковариаций между всеми парами признаков. Если количество признаков равно m, то ковариационная матрица — матрица размерности $m \times m$ имеет вид:

$$\Sigma = \begin{bmatrix} cov_{1,1} & \dots & cov_{1,m} \\ \dots & \dots & \dots \\ cov_{m,1} & \dots & cov_{m,m} \end{bmatrix}$$

$$cov_{i,j} = \frac{1}{m-1} \sum_{k=1}^{m} (f_k(x_i) - \overline{f_k}(x_i))(f_k(x_j) - \overline{f_k}(x_j))$$

Коэффициенты ассоциативности как меры сходства

Если объекты заданы бинарными признаками, то в качестве мер сходства могут быть использованы коэффициенты ассоциативности.

Для расчета коэффициента ассоциативности строится матрица сопряженности или таблица ассоциативности размера 2x2:

$f_1(x_i) \backslash f_2(x_j)$	0	1	Итог
0	a	b	a+b
1	c	d	c+d
Итог	a+c	b+d	a+c+b+d

φ – коэффициент сопряженности.

$$\varphi = \frac{ad - bc}{\sqrt{(a+b)(c+d)(a+c)(b+d)}}$$

Если число признаков более 2x, то используются другие ассоциативные коэффициенты, например, коэффициент Крамера.

Качество кластеризации в метрическом пространстве

Пусть можно рассчитать попарные расстояния между объектами выборки:

✓Среднее внутри кластерное расстояние:

$$F_0 = \frac{\sum_{i<j}[y_i=y_j]\rho(x_i,x_j)}{\sum_{i<j}[y_i=y_j]} \to min$$

$i, j = 1 \dots l, y \in Y$ (Y – множество меток кластеров)

✓Среднее межкластерное расстояние

$$F_1 = \frac{\sum_{i<j}[y_i \neq y_j]\rho(x_i,x_j)}{\sum_{i<j}[y_i \neq y_j]} \to max$$

$i, j = 1 \dots l,\ y \in Y$ (Y – множество меток кластеров)

✓Отношение внутрикластерного и межкластерного расстояния

$$F_3 = \frac{F_0}{F_1} \to min$$

Сложность вычисления этих функционалов состоит в том, что требуется сделать вычисления между всеми парами объектов.

Например, если объектов 10^4, то нужно вычислить $10^4 * 10^4/2$ расстояний

Качество кластеризации в линейном векторном пространстве

Дано: $X^l = \{x_1, x_2, \dots x_l\}$ - обучающая выборка

Каждый объект $x_i, i = [1 \dots l]$, задан при помощи признакового описания т.е. $f_j: X \to D_j, j = 1, \dots m$ – признаки объектов

✓Сумма средних внутри кластерных расстояний

$$\Phi_0 = \sum_{y \in Y} \frac{1}{|X_y|} \sum_{i: y_i = y} \rho(x_i, \mu_{yi}) \to min$$

в каждом кластере рассчитывается расстояние между объектами и центром

$X_y = \{x_i \in X^l | y_i = y\}$ – кластер y

μ_{yi} - *центр масс кластера* y_i

✓Сумма межкластерных расстояний

$$\Phi_1 = \sum_{a,b \in Y} \rho(\mu_a, \mu_b) \to max$$

Рассчитываются расстояния между центрами кластеров

✓Отношение функционалов Φ_0 и Φ_1:

$$\Phi_0 / \Phi_1 \to min$$

Методы кластеризации. K-means (метод к-средних)

Условия применения:

Объекты задаются признаковыми описаниями т.е. для $x_i - (f_1(x_i), f_2(x_i), \dots, f_k(x_i))$, где k – количество признаков, $i \in [1 \dots l]$, l – число объектов

На входе: $X^l = \{x_1, x_2, \dots x_l\}$ - обучающая выборка

На выходе: центры $c_y, y \in Y$ (Y – множество меток кластеров)

объекты $x_i, i \in [1 \dots l]$, получают метки исходя из самых близких центров кластеров

1: Задать начальное приближение центров c_y

2: повторять пока центры кластеров c_y не перестанут обновляться (меняться)

2.1: отнести каждый объект $x_i \in X^l$ к ближайшему центру и таким образом определить принадлежность его к определенному кластеру: т.е.

$$y_i = \arg\min_{y \in Y} \rho(x_i, c_y),\ i \in [1 \dots l]$$

2.2: : вычислить новые положения центров кластеров (среднее значение по каждому признаку в рамках объектов кластера),

$$c_{yj} = \frac{\sum_{i=1}^{l} [y_i = y] f_j(x_i)}{\sum_{i=1}^{l} [y_i = y] \text{ a}},\ y \in Y,\ j \in [1 \dots k]$$

Методы кластеризации. EM-алгоритм (Expectation-Maximization) Мягкий k-means

Объекты задаются признаковыми описаниями т.е. для $x_i - (f_1(x_i), f_2(x_i), \dots, f_k(x_i))$, где k – количество признаков, $i \in [1 \dots l]$, l – число объектов

На входе: $X^l = \{x_1, x_2, \dots x_l\}$ - обучающая выборка

На выходе: центры $c_y, y \in Y$ (Y – множество меток кластеров)

объекты $x_i, i \in [1 \dots l]$, получают метки исходя из самых близких центров кластеров

1: Задать начальное приближение центров c_y - как случайные объекты выборки X^l

2: $w_y = \frac{1}{|Y|}$ - мощность кластеров относительной всей выборки

3: повторять пока метрики принадлежности объектов к кластерам g_{iy} $i \in [1 \dots l], y \in Y$ не перестанут изменяться.

Е-шаг

3.1: Определить близость каждого объекта x_i ко всем центрам: $g_{iy} = w_y e^{-\frac{1}{2}\rho^2(x_i, c_y)}$, $i \in [1 \dots l], y \in Y$

3.2: Пронормировать рассчитанные оценки близости: $g_{iy} = \frac{g_{iy}}{\sum_{y \in Y} g_{iy}}$

3.3: Отнести каждый объект $x_i \in X^l$ к ближайшему центру опираясь, на максимальную оценку близости: $y_i = \arg\max_{y \in Y} g_{iy}$, $i \in [1 \dots l]$

М-шаг

3.4: вычислить новые положения центров кластеров (средне-взвешенное значение по каждому признаку в рамках все объектов выборки X^l):

$$c_{yj} = \frac{1}{l w_y} \sum_{i=1}^{l} g_{iy} f_j(x_i) \ , y \in Y \ , j \in [1 \dots k]$$

3.5 Обновить мощности кластеров $w_y = \frac{1}{l} \sum_{i=1}^{l} g_{iy}$

K-means. Как выбрать начальные приближения (центры кластеров)

- ✓ Объекты выбираются случайно
- ✓ Выбор наиболее удаленных друг от друга объектов:

  Шаг 1. выбирается пара наиболее удаленных объектов $C = \arg \max_{x_i, x_j \in X^l} \rho(x_i, x_j),\ i \neq j$

  Шаг 2. Последовательно добавляются объекты наиболее удаленные от уже выбранных в множество С объектов.

  $$C = C \cup \arg \max_{x_i \in X^l,\, c \in C} min\, \rho(x_i, c)$$

- ✓ Выбор наиболее удаленных объектов с отсечением шумовых объектов

Рассчитать среднее расстояние до m ближайших соседей $x'_j\ (j = 1, \dots, m)$ по каждому объекту x_i

$$R_i = \frac{1}{m} \sum_{j=1}^{m} \rho(x_i, x'_j),\ i = 1, \dots, l$$

Отбросить шумовые объекты $X'' = \{x_i \in X^l \big| R_i \leq \delta\}$, при δ выбирается так, чтобы оставить определенный процент объектов т.е. $|X''| = (1 - \tau)l$, где τ – доля отбрасываемых объектов.

Далее выполняются шаг 1 и шаг 2 как из пред. Пункта

$C = \arg \max_{x_i, x_j \in X''} \rho(x_i, x_j),\ i \neq j$

$C = C \cup \arg \max_{x_i \in X'',\, c \in C} min\, \rho(x_i, c)$

- ✓ Мультистарт

  Многократный запуск алгоритма со случайными центрами и далее выбирается лучшее разбиение опираясь на какой-либо функционал качества кластеризации

K-means. Недостатки

✓Чувствительность к выбору начального приближения

✓Необходимость задавать число кластеров

Как устраняются эти недостатки:

- Используются специальные эвристики для начального приближения
- Используется «мягкая» кластеризации
- Применяются быстрые алгоритмы (k-means++)
- Число кластеров меняется в ходе итераций/алгоритм запускается с разным числом кластером с выбором лучшего результата

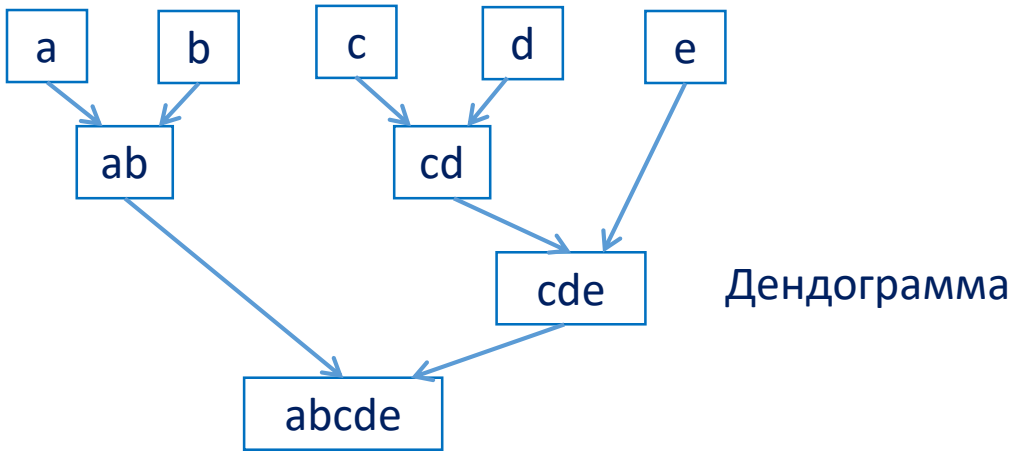
Иерархическая кластеризация

Позволяет не задавать число кластеров заранее

Находят внутреннюю иерархическую структуру

Иерархические методы кластеризации делятся на 2 группы:

- ✓ **Агломеративные –** объединяют мелкие кластеры в более крупные и отображают историю этих объединений графически в виде дендограммы.
- ✓ **Дивизионные** – конечная выборка объектов последовательно дробится на более мелкие кластеры.



Дендограмма

Агломеративная иерархическая кластеризация

Автор алгоритма: Ланс-Уильямс 1967 г.

1: Формируются кластеры из одного элемента по числу объектов
$t = 1, C = \{c_1, \dots c_l\}, c_i = \{x_i\}, i = 1 \dots l$
$R(\{x_i\}, \{x_j\}) = \rho(x_i, x_j)$

2: Повторять для t=2 до l

2.1: Найти 2 самых близких кластера в C_{t-1}
$(U, V) = \arg \min_{\substack{U \neq V \\ U,V \in C}} R(U, V)$

2.2 Объединить найденные кластеры в один новый $W = U \cup V$

2.3 Сохранить расстояние между этими кластерами $R_t = R(U, V)$

2.4 Обновить состав множества кластеров $C_t = (C_{t-1} \backslash \{U, V\}) \cup W$

2.5 Для всех $K \in C_t$ вычислить расстояние до нового кластера $R(K, W)$ по формуле Ланса-Уильямса

Формула Ланса-Уильямса

Известны следующие расстояния между кластерами: $R(U,K), R(V,K), R\ (U,V)$

Найти расстояние от $W = U \cup V$ и K

Формула Ланса-Ульямса позволяет обобщить различные способы определить расстояния между кластерами:

$$R(W,K) = \alpha_U R(U,K) + \alpha_V R(V,K) + \beta R(U,V) + \gamma |R(U,K) - R(V,K)|$$

$\alpha_U, \alpha_V, \beta, \gamma$ – задаваемые числовые параметры.

Как их определить?

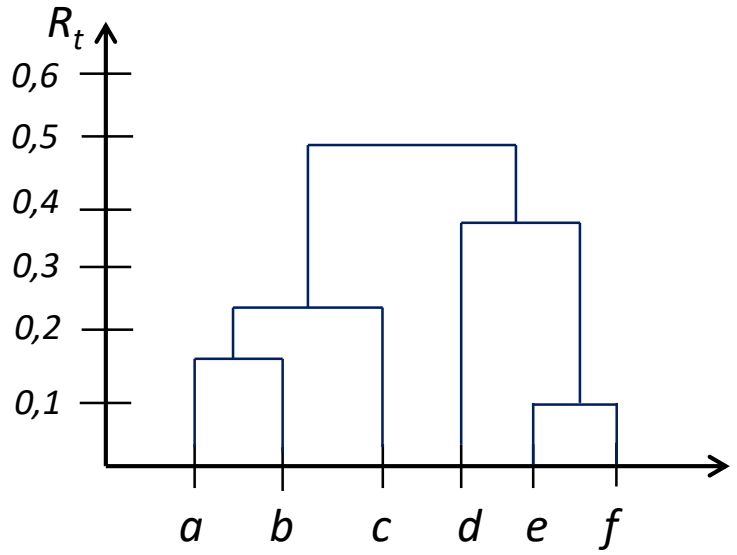
Рекомендуется использовать расстояние Уорда – нормированное расстояние между центрами масс кластеров:

$$R^{\text{У}}(W,K) = \frac{|K||W|}{|K|+|W|}\rho^2\left(\sum_{w\in W}\frac{w}{|W|}, \sum_{k\in K}\frac{k}{|K|}\right)$$

$$\alpha_U = \frac{|K|+|U|}{|K|+|W|}, \alpha_V = \frac{|K|+|V|}{|K|+|W|}, \beta = \frac{-|K|}{|K|+|W|},\ \gamma=0$$

Рекомендации при применении иерархических методов кластеризации

- ✓ Рекомендуется использовать расстояние Уорда
- ✓ Можно использовать и другие расстояния визуально оценивая по дендограмме и выбирая лучший результат (во визуальной оценке)
- ✓ Число кластеров определяется по дендограмме по максимуму $|R_t - R_{t+1}|$, $t = 1 \dots l - 1$, тогда используется число кластеров t



Алгоритм кластеризации DBScan (Density-based spatial clustering of application with noise)

- ✓ Не чувствителен к форме кластера
- ✓ Не требуется задавать число кластеров
- ✓ Автоматически определяет множество шумовых объектов в выборке

Найдем объект x в выборке, который плотно окружен другими объектами:

$x \in U$, и его ε окрестность определяется как $U_\varepsilon(x) = \{u \in U\colon \rho(x,u) \leq \varepsilon\}$

Каждый объект выборки $x_i \in X^l, i \in [1 \dots l]$ можно отнести к одному из трех типов:

- ✓ Корневой → объект x_i имеет плотную окрестность т.е. $|U_\varepsilon(x)| \geq m$
- ✓ Граничный → объект x_i не является корневым, но находится в окрестности другого корневого объекта
- ✓ Шумовой → объект x_i не является коневым и не является граничным.

Алгоритм кластеризации DBScan. Описание

На входе: выборка X^l, гиперпараметры m и ε

На выходе: объекты выборки, разбитые на кластеры; шумовые объекты.

1: $U = X^l$

2: $a=0$ количество кластеров

2: Пока выборка содержит непомеченные объекты $U \neq \emptyset$

- 2:1 случайно выбрать объект x из U
- 2.2: Если $|U_\varepsilon(x)| < m$, то отметить объект как предположительно шумовой
  - Иначе *(т.е. объект оказался корневым)*
    - создать новый кластер $C = U_\varepsilon(x), a = a + 1$ (увеличить кол-во кластеров) $Y = Y \cup \{a\}$
    - Для всех объектов $x' \in C$ являющимися непомеченными или шумовыми Цикл
    - Если $|U_\varepsilon(x')| \geq m$, то $C = C \cup U_\varepsilon(x')$
    - Иначе отметить x' как граничный объект кластера C
- 2.3: Для всех объектов $x' \in C$ проставить метки кластера а т.е. $y_i = a$
- 2.4: Удалить объекты, попавшие в кластер из списка необработанных объектов $U = U \backslash C$

Достоинства алгоритма DBScan

- ✓ Быстрый алгоритм $O(l^2)$ в худшем случае, $O(l \cdot ln(l))$ при использовании эффективных реализаций шага с построением $U_\varepsilon(x)$
- ✓ Не чувствителен к форме кластера, т.е. обнаруживает кластеры любой формы
- ✓ Выделяет как шумовые объекты, так корневые и граничные объекты в рамках кластера.

.

Affinity propagation
Метод распространения близости

- ✓ Не требует задавать число кластеров
- ✓ Позволяет выделять сложно разделимые кластеры
- ✓ Работает с произвольной формой кластеров (
- ✓ Может работать в не метрическом пространстве (свойство симметричности не выполняется, правило треугольника не выполняется)
- ✓ Работает долго. Оценка алгоритмической сложности оригинального алгоритма $O(N^2T)$, где T –число итераций (max_iteration)

Применение:

- ✓ Компьютерное зрение (распознавание лиц)
- ✓ Биоинформатика (Выделение групп в геноме)
- ✓ Обработка данных (задача разбиения городов на группы по доступности)
- ✓ Геология (разделение образцов гранита)

Affinity propagation.Описание

На входе: выборка X^l,

гиперпараметры: $\alpha \in [0, 1]$ - параметр самоподобия, max_iteration – число итераций.

<u>В алгоритме используются матрицы:</u>

- ✓ *R* – матрица ответственности, *A* – матрица доступности
- ✓ Значение R_{ij} отвечает за то, насколько объект x_i хочет видеть объект x_j своим лидером. Ответственность возлагается каждым объектом на кандидата в лидеры группы.
- ✓ Значение A_{ij} является ответом потенциального лидера x_j , насколько он готов представлять интересы объекта x_i . Ответственность и доступность объектов вычисляют и для самих себя.

Affinity propagation.Описание

На входе: выборка X^l,

гиперпараметры: $\alpha \in [0,1]$ - параметр самоподобия, max_iteration – число итераций.

1: Сформировать матрицу схожести S

$\forall i,k = 1 \dots l\colon\ i \neq k\ S_{ik} = -\rho(x_i, x_k)$

$\forall i,k \in [1,l]\ \ S_{ii} = \alpha \cdot mean(S_{jk})$ j, k $= 1 \dots$ l, чем меньше S_{ii} - тем меньше число кластеров, т.е. каждый кластер крупнее по числу объектов. Кроме медианы, можно использовать процентили 25, 30 и т.п, min(S_{jk}) или произвольно выбранное число, подобранное экспериментально.

2: Матрицы R И A зануляются

3: Цикл повторяющийся max_iteration

3.1: $\forall i,k \in [1,l]$вычислить $R_{ik} = S_{ik} - \max\limits_{\substack{\forall j: \\ j \neq k}}(A_{ij} + S_{ij})$

3.2: $\forall i,k \in [1,l], i \neq k$ вычислить $A_{ik} = \min(0,\quad R_{kk} + \sum\limits_{\substack{\forall j: \\ j \neq i \\ j \neq k}} \max(0, R_{jk})\ )$

3.3:$\forall k \in [1,l]$вычислить $A_{kk} = \sum\limits_{\substack{\forall j \\ j \neq k}} \max(0, R_{jk})$

Собираем кластеры по их лидерам

4: $\forall i\ c_i = \arg\max\limits_{\forall k \in [1,l]} (A_{ik} + R_{ik})$

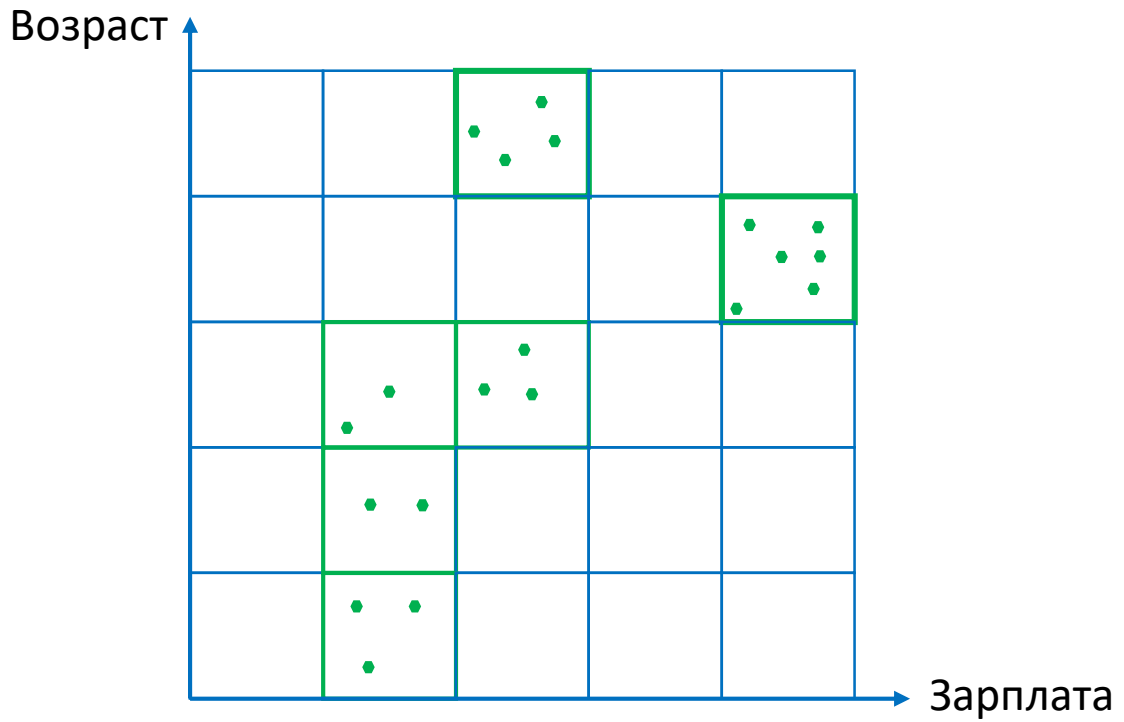
Матрицы *A* и *R* суммируются, соответствующее значение является лидером кластера. Для будет обозначен лидер. Объекты в кластер собираются по номеру лидера.

Сеточные методы кластеризации

- ✓ Сеточные методы кластеризации рассматривают множество объектов в рамках блоков – сетки.
- ✓ Элементы данных, попавшие в одну ячейку сетки, с высокой вероятностью принадлежат одному кластеру.
- ✓ Вычислительная сложность определяется числом элементов сеточной структуры и практически не зависит от количества классифицируемых объектов.
- ✓ Методы позволяют выделять кластеры сложной формы без каких-либо предположений о структуре данных.
- ✓ Применяются для обработки потоковых данных в режиме онлайн, данных, характеризующейся большим числом измерений, в частности при сегментации спутниковых изображений, при решении задач, связанных с мониторингом окружающей среды

Базовый подход многих сеточных методов

- ✓ Каждая ячейка сетки (клетка) характеризуется объемом и количеством попавших в нее элементов данных.
- ✓ Клетки разделяются по порогу на плотные и неплотные (пустые)
- ✓ Соседние плотные клетки связываются в кластеры, которые отделяются неплотными областями.



Известные методы сеточной кластеризации

- ✓ NRI

Tsai,C.F. An effective and efficient grid-based data clustering algorithm using intuitive neighbor relationship for data mining / C.F.Tsai, S.C.Huang //Proc. InternationalConferenceon Machine Learning and Cybernetics (ICMLC). –IEEE, 2015. –Vol.2. –P.478-483.

- ✓ CLIQUE

Agrawal,R. Automatic subspace clustering of high dimensional data for data mining applications/ R.Agrawal, J.Gehrke, D.Gunopulos, P.Raghavan// Proc. ACM SIGMODInternationalConferenceon Management of Data–ACM, 1998. –Vol.27. –No.2. –P.94-105.

- ✓ STING

Wang,W.STING: A statistical information grid approach to spatial data mining /W.Wang,J.Yang, M.Muntz // Proc. Int. Conf. on Very Large Data Bases (VLDB).–1997. –P.186-195.

- ✓ WaveCluster.

Sheikholeslami,G.Wavecluster: A multi-resolution clustering approach for very large spatial databases / G.Sheikholeslami,S.Chatterjee, A.Zhang //Proc. 24th International Conference on Very Large Data Bases(VLDB). –1998.–P.428-439.

- ✓ GDCLU

Esfandani,G.GDCLU: a new Grid-Density based CLUstring algorithm /G.Esfandani,M.Sayyadi, A.Namadchian //Proc. 13th ACIS International Conference on Software Engineering, Artificial Intelligence, Networking and Parallel& Distributed Computing (SNPD). –IEEE, 2012. –P.102-107.

CLIQUE. Описание метода

Объекты задаются признаковыми описаниями т.е. для $x_i - (f_1(x_i), f_2(x_i), \dots, f_k(x_i))$, где k – количество признаков, $i \in [1 \dots l]$, l – число объектов

На входе: $X^l = \{x_1, x_2, \dots x_l\}$ - обучающая выборка

гиперпараметры: ξ – количество блоков внутри каждого измерения, τ – Минимальная необходимая доля объектов, для того, чтобы считать ячейку сетки плотной.

Шаг 1. Определение плотных ячеек сетки (блоков) в рамках одного измерения.

Цикл по каждому признаку $f_i, i \in 1 \dots k$

  Цикл по каждому объекту обучающей выборки x_j $j \in 1 \dots l$

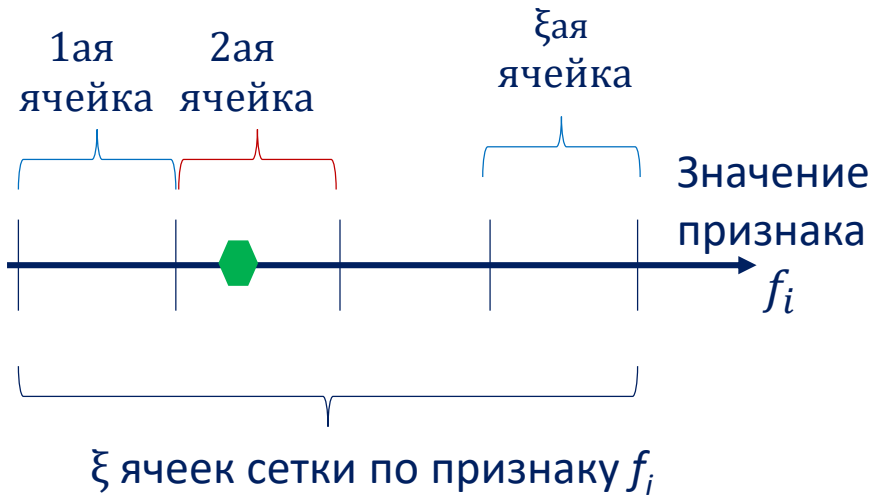
    Присвоить объект x_j к ячейки сетки $u_{i,m}$, $m \in [1 \dots \xi]$

    по значению признака f_i

Цикл по получившимся ячейкам сетки,

  Оставить только плотные ячейки $|u_{i,m}| > \tau \cdot l$

  Если ячейка плотная: добавить в массив словарей $f_i : u_{i,m}$



Результат шага 1 – список плотных ячеек по каждому признаку: $U_i = \{u_{i,m} \mid |u_{i,m}| > \tau \cdot l, i \in [1 \dots k], m \in [1 \dots . \xi]\}$

В качестве структуры при реализации можно использовать массив словарей, например, $\{[f_1 : u_{1,1}], \{[f_2 : u_{2,1}], \{[f_1 : u_{1,4}], \dots\}$

CLIQUE

Шаг 2. Определить кластеры размерности 1 (dim =1), на входе список плотных ячеек - результат шага 1.

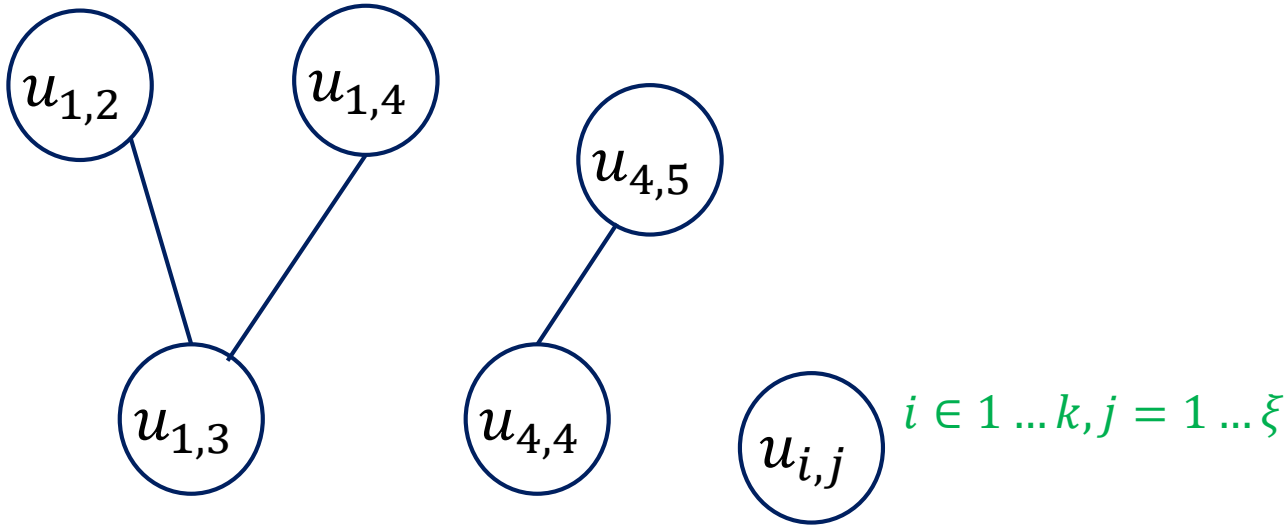
2.0. cluster = ∅

2.1 Построить граф *G* по следующему принципу:

Вершинами графа *V* = являются плотные ячейки сетки, добавленные в список, на шаге 1.

Между вершинами графа существует ребро в случае, если ячейки сети относятся к одному и тому же составу признаков и их номера по втором индексу отличаются не более чем на 1. То есть, плотные ячейки располагаются по соседству.

Плотная ячейка 2, признака 1



CLIQUE. Шаг 2.

Шаг 2. *(Продолжение)*

2.2 По графу G – определить число компонент. Каждый компонент – является кластером.

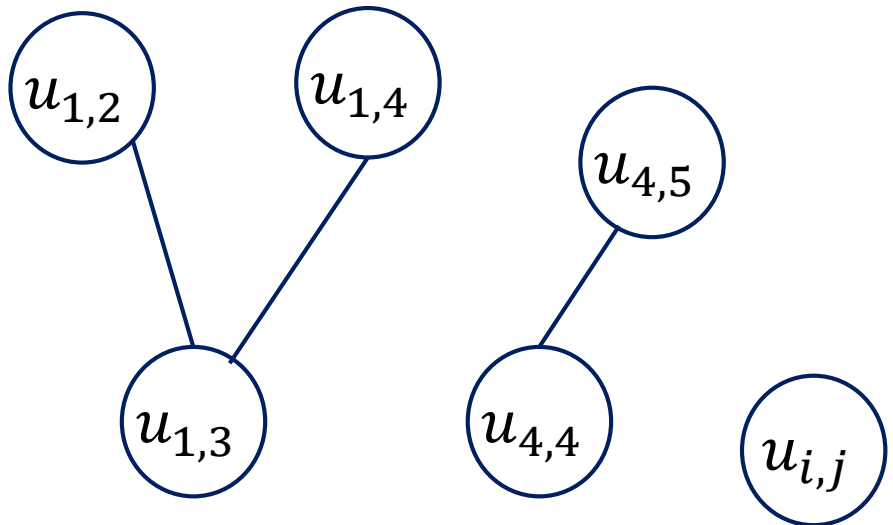
Пример 1. На рисунке ниже представлено 3 компонента.

Пример 2. Для следующего списка плотных ячеек – 13 компонент.

[{0: 0}, {0: 2}, {1: 0}, {2: 0}, {2: 2}, {3: 1}, {4: 0}, {5: 0}, {5: 2}, {6: 0}, {7: 1}, {7: 2}, {8: 1}, {8: 2}, {9: 2}]

2.3 Число кластеров соответствует числу компонент. В кластеры, попадают объекты, которые соответствуют плотной ячейке сетки.

Плотная ячейка 2, признака 1



CLIQUE. Кандидаты на список плотных ячеек

Шаг 3. Определить кластеры для размерности d ≥ 2

3.1 $d = 2$

3.1 Цикл пока $d \leq k$ И список плотных ячеек не пустой

Найти список плотных ячеек для размерности ≥ 2

3.1.1.1 Опираясь на данные плотных ячеек для размерности $d - 1$, определяются кандидаты в элементы списка плотных ячеек размерности *d*:

Список кандидатов = ∅

Цикл по списку плотных ячеек размерности $d - 1$ т.е. $i \in 1 \ldots$ число плотных ячеек в списке

Цикл по списку плотных ячеек размерности $d - 1$ т.е. j $\in$ $i \ldots$ число плотных ячеек в списке

Создать суперсет из *i*-ого и *j*-ого элементов списка плотных ячеек

Если размерность суперсета *(т.е. общее число признаков в результате их объединения)* = *d*, и такого суперсета нет в списке кандидатов, то в список кандидатов, добавляется этот суперсет.

Пример

i-ый элемент списка плотных ячеек {0: 0}, *j*-ый элемент списка плотных ячеек {0: 2} Суперсет {0: 0, 2} – размерность 1 – т.е. если d=2, не подходит в качестве кандидата

i-ый элемент списка плотных ячеек {0: 0}, *j*-ый элемент списка плотных ячеек {1: 2} Суперсет {0: 0, 1: 2} – размерность 2 - – т.е. если d=2, подходит в качестве кандидата

То есть *i*-ый и j-ый элементы должны совпадать по d-2 признакам.

CLIQUE. Прунинг списка кандидатов

Шаг 3. Определить кластеры для размерности d ≥ 2

3.1 $d = 2$

3.1 Цикл пока $d \leq k$ И список плотных ячеек не пустой

Выполнить прунинг (прореживание) списка кандидатов

3.1.1.2 Цикл по списку кандидатов размерности *d*

3.1.1.2.1 Текущий элемент из списка кандидатов обозначим за C_d

Например, {7: 1, 9: 2}

3.1.1.2.2 Обозначим за C_{d-1} соответствующий ему кандидат для предыдущего измерения

Если C_d={7: 1, 9: 2}, то C_{d-1}= {7: 1} и C_{d-1}= {9: 2}

3.1.1.2.3Удаляем из списка кандидатов те кандидаты C_d в случае если хотя бы один его C_{d-1} не содержится в списке плотных ячеек размерности *d-1*

Пояснение по процедуре прореживания: из каждого элемента списка кандидатов поочередно извлекается одна размерность (признак) и выполняется проверка находился ли без этой размерности этот кандидат (то что осталось), в списке плотных блоков размерности dim-1

CLIQUE. Число плотных блоков в прореженном списке кандидатов

Шаг 3. Определить кластеры для размерности d ≥ 2

3.1 $d = 2$

3.1 Цикл пока $d \leq k$ И список плотных ячеек не пустой

Определить какое число плотных ячеек оказалось в списке кандидатов.

3.1.1.3 Цикл по списку прореженных кандидатов размерности d

3.1.1.3.1 Цикл по каждому объекту обучающей выборки x_j $j \in 1 \ldots l$

3.1.1.3.2 Обозначим за C_{d-1} соответствующий ему кандидат для предыдущего измерения

Если C_d ={7: 1, 9: 2}, то C_{d-1}= {7: 1} и C_{d-1}= {9: 2}

3.1.1.3.3 Цикл по каждой размерности кандидата

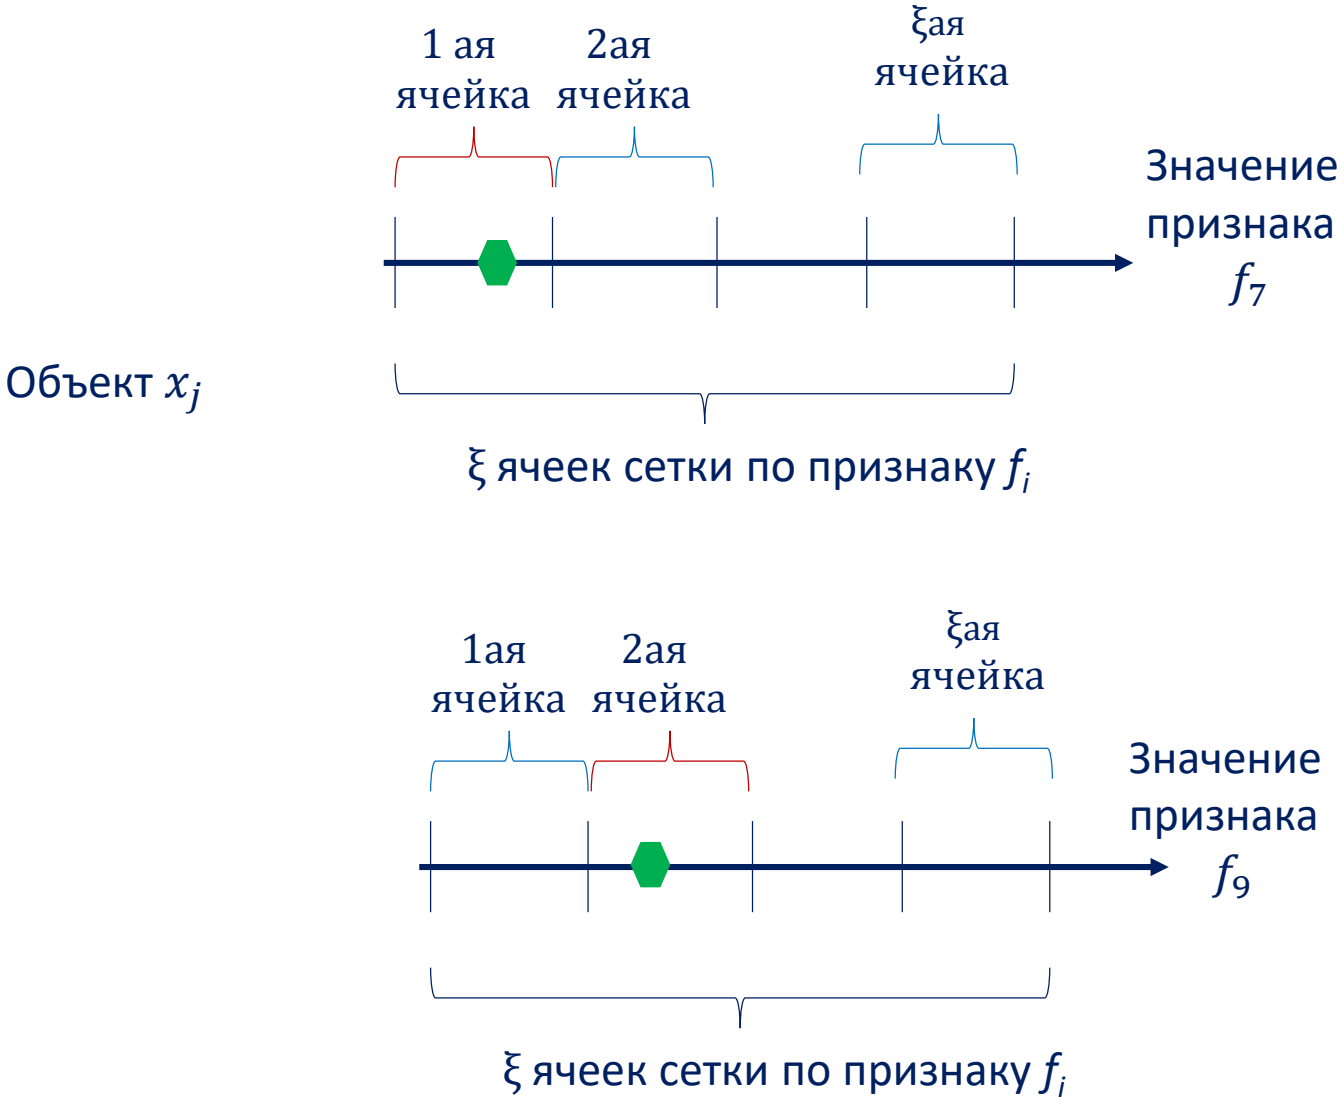
$f = C_{d-1}[0]$ *Если* C_{d-1}= {7: 1} , то f = 7 то есть 7 признак

$u = C_{d-1}[1]$ *Если* C_{d-1}= {7: 1} , то u = 1 то есть 1ая плотная ячейка

Если значение f-ого признака объекта x_j не попало в блок номер u, то данный объект x_j не учитывается при подсчете плотных блоков.

3.1.1.4 Прореженный кандидат размерности d считается плотной ячейкой, доля учтеных объектов для кандидата превышает значение $\tau \cdot l$

CLIQUE. Число плотных блоков в прореженном списке кандидатов



$C_d = \{7: 1, 9: 2\}$

Значение по 7ому признаку Попало в блок 1

Значение по 9ому признаку попало в 2 блок

Значит объект x_j учитывается при подсчете числа плотных ячеек размерости d

CLIQUE. Формирование кластеров размерность *d*

Шаг 3. Определить кластеры для размерности d ≥ 2

3.1 $d = 2$

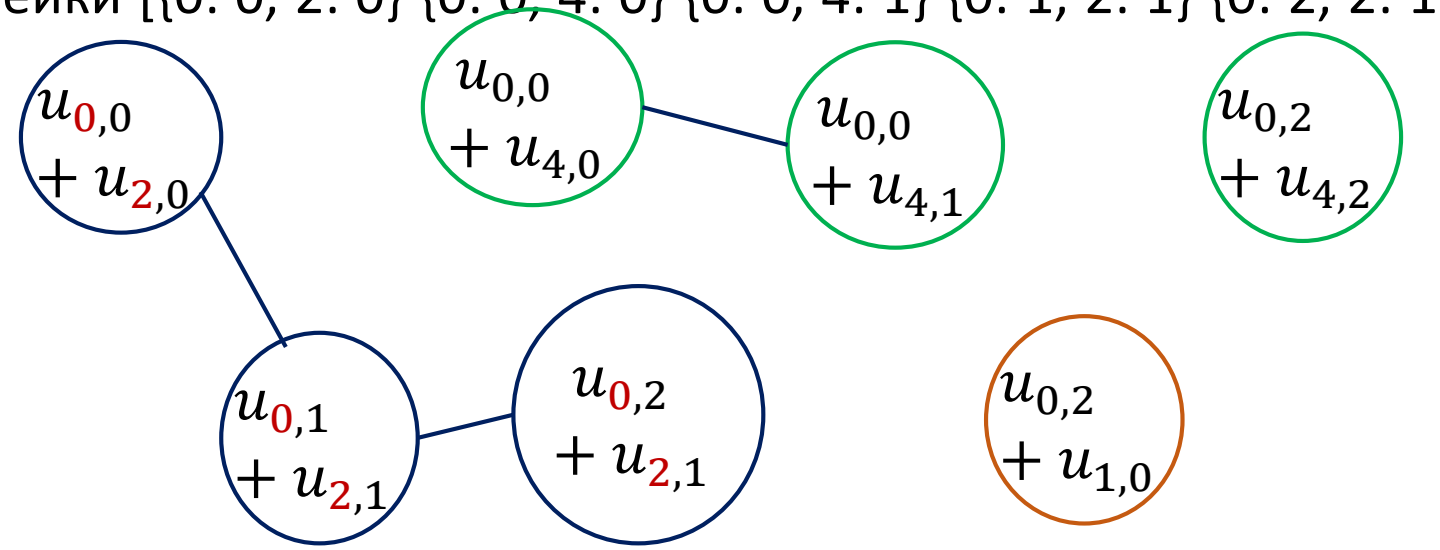
3.1 Цикл пока $d \leq k$ И список плотных ячеек не пустой

3.1.1.5 Построить граф *G* аналогично шаг 2.1 (слайд 26) :

3.1.1.6 Число кластеров cluster_dim соответствует числу компонент. В кластеры, попадают объекты, которые соответствуют плотной ячейке сетки.

3.1.1.7 cluster = cluster + cluster_dim

Например, dim = 2 Плотные ячейки [{0: 0, 2: 0} {0: 0, 4: 0} {0: 0, 4: 1} {0: 1, 2: 1} {0: 2, 2: 1} {0: 2, 1: 0} {0: 2, 4: 2}



CLIQUE. Формирование кластеров размерность *d*

Шаг 4. Определить эффективность разбивки по кластерам для каждой размерности при помощи показателей ARI, AMI и т.п.

Реализация алгоритма приведена по ссылке

Ссылка на литературу

1. Yao, Y. Y.. Information-theoretic measures for knowledge discovery and data mining. // Entropy Measures, Maximum Entropy Principle and Emerging Applications. Karmeshu (ed.), Springer. – 2003, . – 115–136. Karmeshu (ed.), Springer.

2. Kvalseth T. O. Entropy and correlation: Some comments. // Man and Cybernetics, IEEE transactions on. – 1987. – 17(3). – 17–519.

3. Strehl A., Ghosh, J. Cluster ensembles—a knowledge reuse framework for combining multiple partitions // The Journal of Machine Learning Research . – 2003 . – 3:583–617.

4. Vinh N. X., Epps J., Bailey, J. Information theoretic measures for clusterings comparison: Variants, properties, normalization and correction for chance // Journal of Machine Learning Research . – 2010. – 11:2837–2854.

5. Liu Z., Guo Z. , Tan M. Constructing tumor progression pathways and biomarker discovery with fuzzy kernel kmeans and dna methylation data // Cancer Inform.- 2008. – 6: 1–7.

6. Banerjee A., Dhillon I. S. , Ghosh J., Sra S. Clustering on the unit hypersphere using von mises-fisher distributions. J. Mach. Learn. Res., 2005. – 6: 1345–1382.

7. Romano S., Bailey J., Nguyen V., Verspoor K. Standardized mutual information for clustering comparisons: One step further in adjustment for chance. // Proceedings of the 31st International Conference on Machine Learning (ICML-14) . – 2014 . – 1143–1151

Ссылка на литературу

8. Rousseeuw P. J. Silhouettes: a Graphical Aid to the Interpretation and Validation of Cluster Analysis // . Computational and Applied Mathematics. – 1987 . – 20: 53-65.
9. Rosenberg A., Hirschberg J., V-Measure: A conditional entropy-based external cluster evaluation measure, // Proceedings of the 2007 Joint Conference on Empirical Methods in Natural Language Processing and Computational Natural Language Learning(EMNLP-CoNLL). – 2007. – 410-420.
10. Evaluation of Clusterings – Metrics and Visual Support. URL: https://imada.sdu.dk/~zimek/publications/ICDE2012/ICDE12_ELKI_0_5.pdf
11. Hierarchical Document Clustering Using Frequent Itemsets. URL: http://citeseerx.ist.psu.edu/viewdoc/download?doi=10.1.1.138.8984&rep=rep1&type=pdf

TYCYP
TUSUR UNIVERSITY