ТУСУР
TUSUR UNIVERSITY

2.3 Метрики качества кластерного анализа

Метрики качества кластерного анализа. Метрики, использующиеся для сравнения результатов кластеризации разными методами: гомогенность, полнота, adjusted rand index, adjusted mutual information и т.п

29.09.2022

Методы оценки качества кластеризации

Метод оценки качества кластеризации — инструментарий для количественной оценки результатов кластеризации:

✓Внешние меры – меры основаны на сравнении результатов кластеризации с заранее известными метками, разделяющие объекты на классы. Данные меры также можно использовать для сравнения двух методов кластеризации.

- Adjusted rand index
- Гомогенность
- F-мера
- Adjusted mutual information
- Normalized Mutual Information

✓Внутренние меры - опираются только на выборку кластеризуемых объектов.

- Силуэт

Adjusted rand index. Таблица сопряженности

Дана выборка из $X^l = \{x_1, x_2, \dots x_l\}$ из l элементов, разделение на классы $X=\{X_1,X_2,\dots,X_r\}$, и полученное разделение на кластеры $Y=\{Y_1,Y_2,\dots,Y_s\}$, совпадения между X и Y могут быть отражены в таблице сопряженности.

X \ **Y**	Y_1	Y_2	…	Y_s	Суммы
X_1	n_{11}	n_{12}	…	n_{1s}	a_1
X_2	n_{21}	n_{22}	…	n_{2s}	a_2
…	…	…	…	…	…
X_r	n_{r1}	n_{r2}	…	n_{rs}	a_r
Суммы	b_1	b_2	…	b_s	l

$$a_1 = n_{11} + n_{12} + \cdots + n_{1s}$$
$$b_1 = n_{11} + n_{21} + \cdots + n_{r1}$$

n_{11} - общее число объектов, которые попали и в кластер X_1 и в кластер Y_1

Adjusted rand index. Вычисление.

Дана выборка из $X^l = \{x_1, x_2, \dots x_l\}$ из l элементов, разделение на классы $X=\{X_1,X_2,\dots,X_r\}$, и полученное разделение на кластеры $Y=\{Y_1,Y_2,\dots,Y_s\}$, совпадения между X и Y могут быть отражены в таблице сопряженности.

$$s_0 = \sum_{i=1}^{r}\sum_{j=1}^{s} C_{n_{i,j'}}^2 \qquad s_1 = \sum_{i=1}^{r} C_{a_i}^2$$

$$s_2 = \sum_{j=1}^{s} C_{b_{j'}}^2 \qquad s_3 = \frac{2s_1s_2}{N(N-1)}$$

$$C_n^k = \frac{n!}{k!\,(n-k)!}$$

$$ARI = \frac{s_0 - s_3}{\frac{1}{2}(s_1+s_2) - s_3}$$

$$ARI \in [-1, 1]$$

Если $ARI = 1$, то кластерный анализ выполнен в точности в соответствии с истинными метками ответов.

Если $ARI = 0$, то такой результат соответствуют случайному разбиению, т.е. не нашлось ни одной совпадающей пары объектов.

$ARI < 0$,говорит о том, что полученный результат согласован еще меньше, чем это можно было бы ожидать от случайных результатов. То есть значения меньшие нуля не интерпретируются.

Взаимная информация (Mutual information)

Взаимная информация (MI) статистическая функция двух случайных величин X и Y, описывающая количество информации, содержащееся в одной случайной величине относительно другой.

Взаимная информация определяется через энтропию и условную энтропию двух случайных величин:

$$MI(X,Y) = H(Y) - H(Y|X)$$

Информационная энтропия Шенона. Эксперименты

Мысленный эксперимент 1.

Если бросать монету, имеющую с двух сторон только орла, то выпадение орла — достоверное событие, его вероятность равна 1.

Много ли информации можно сообщить, если сказать о выпавшем орле? Нет. Количество информации в таком сообщении мы будем считать равным 0.

В данном эксперименте нет неопределенности.

Мысленный эксперимент 2.

Если бросать обычную монету (с одной стороны орел, с другой решка) , то выпадение орла или решки будут двумя разными событиями, из которых состоит пространство случайных событий. Если сообщить об исходе одного бросания, то это можно считать новой информацией, о которой ранее не было известно.

Если при выпадении орла сообщать 0, а при решке 1, то для того, чтобы сообщить эту информацию, достаточно 1 бита.

В данном эксперименте (2ом) по сравнению с 1ым появилась неопределенность.

Информационная энтропия Шенона

Мысленный эксперимент 3.

Если независимо и одновременно бросать две монеты (с орлом и решкой на каждой стороне), то разных равновероятных результатов будет четыре:

орел-орел, орел-решка, решка-орел и решка-решка.

Чтобы передать информацию, понадобится 2 бита, и сообщения можно закодировать следующим образом: 00, 01, 10 и 11.

Неопределенность выросла, информации судя по числу бит, необходимых для ее хранения требуется в 2 раза больше.

Информационная энтропия Шенона

Предположим, мы наблюдаем машины из окна: серые, черные, белые, красные.

Если это равновероятные события, то вероятность встретить машину любого цвета 0,25. Тогда, чтобы при помощи бит закодировать эту информацию, будет достаточно 2 бита.

серый — 00, белый — 01, черный — 10, красные — 11.

Что если события имеют разную вероятность?

Серый – 0.5, белый 0,25, черный 0,125, красная 0,125

Можно закодировать также, а можно попробовать оптимизировать передаваемую информацию, опираясь на вероятности.

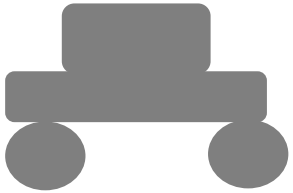
Больше всего серых автомобилей, поэтому обозначим серый — 0 — самый короткий код, а код всех остальных пусть начинается на 1.

Из оставшихся половина белые — 10, а оставшиеся цвета начинаются на 11. В заключение обозначим черный — 110, а красный — 111.

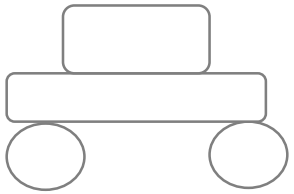
Информационная энтропия Шенона

Если события равновероятные

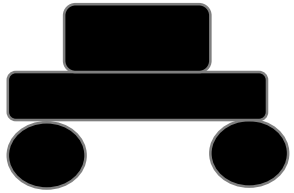
Код/Вероятность/Число бит под код



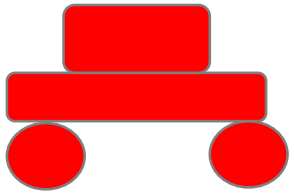
00 $0{,}25 \cdot 2\ \text{бит} = 0{,}5\ \text{бит}$



01 $0{,}25 \cdot 2\ \text{бит} = 0{,}5\ \text{бит}$



10 $0{,}25 \cdot 2\ \text{бит} = 0{,}5\ \text{бит}$

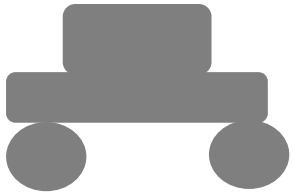


11 $0{,}25 \cdot 2\ \text{бит} = 0{,}5\ \text{бит}$

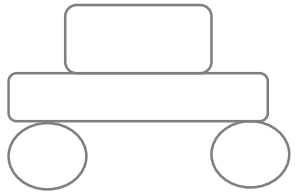
0,5+0,5+0,5+0,5 = 2 бит

Если события имеют разную вероятность

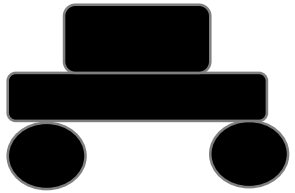
Код/Вероятность/Число бит под код



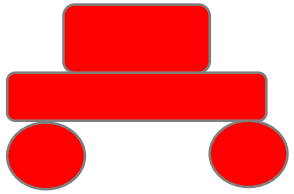
0 $0{,}5 \cdot 1\ \text{бит} = 0{,}5\ \text{бит}$



11 $0{,}25 \cdot 2\ \text{бит} = 0{,}5\ \text{бит}$



110 $0{,}125 \cdot 3\text{бит} = 0{,}375\ \text{бит}$



111 $0{,}125 \cdot 3\text{бит} = 0{,}375\ \text{бит}$

0,5+0,5+0,375+0,375 = 1,75 бит

В среднем, только 1,75 бит будет потрачено для кодирования информации о цвете 1го автомобиля

Информационная энтропия Шенона. Формула

$$H = -\sum_{i=1}^{n} p_i log_2(p_i)$$

n – число всех событий; p_i - вероятность наступления i-ого события

- Энтропия достоверного события, вероятность которого 1, равна 0.
- Энтропия двух независимых событий равна сумме энтропий этих событий.
- Энтропия максимальна, если все события равновероятны.

Информационная энтропия Шенона. Рассчеты

$$\boldsymbol{H = -\sum_{i=1}^{n} p_i log_2(p_i)}$$

n – число всех событий; $\boldsymbol{p_i}$ - вероятность наступления i-ого события

Рассчитаем для всех ранее рассмотренных экспериментов энтропию Шенона

Эксперимент 1. Монета с одинаковыми сторонами $\boldsymbol{H = -\left(1 \cdot log_2(1)\right) = 0}$

Эксперимент 2. Обычная монета $\boldsymbol{H = -\left(\frac{1}{2} \cdot log_2\left(\frac{1}{2}\right) + \frac{1}{2} \cdot log_2\left(\frac{1}{2}\right)\right) = 1}$

Эксперимент 3. Две обычные монеты

$$\boldsymbol{H = -\left(\frac{1}{4} \cdot log_2\left(\frac{1}{4}\right) + \frac{1}{4} \cdot log_2\left(\frac{1}{4}\right) + \frac{1}{4} \cdot log_2\left(\frac{1}{4}\right) + \frac{1}{4} \cdot log_2\left(\frac{1}{4}\right)\right) = 2}$$

Эксперимент 4. Наблюдение за автомобилями в случае разной вероятности их появления

$$\boldsymbol{H = -\left(\frac{1}{2} \cdot log_2\left(\frac{1}{2}\right) + \frac{1}{4} \cdot log_2\left(\frac{1}{4}\right) + 0{,}125 \cdot log_2(0{,}125) + 0{,}125 \cdot log_2(0{,}125)\right) = 1{,}75}$$

Во всех случаях H совпала с числом бит, необходимых для сообщения о событиях

Взаимная информация (Mutual information)

Взаимная информация (MI) статистическая функция двух случайных величин X и Y, описывающая количество информации, содержащееся в одной случайной величине относительно другой.

$$MI(X,Y) = H(Y) - H(Y|X) = \sum_{x\in X}\sum_{y\in Y} p_{X,Y}(x,y) ln \frac{p_{X,Y}(x,y)}{p_X(x)p_Y(y)}$$

Свойства взаимной информации:

- Взаимная информация является симметричной функцией случайных величин

$$MI(X,Y) = MI(Y,X)$$
$$MI(X,Y) = H(Y) - H(Y|X) = H(X) - H(X|Y)$$

- Взаимная информация неотрицательна и не превосходит информационную энтропию аргументов:

$$0 \le MI(X,Y) \le \min[H(Y), H(X)]$$

- Для независимых случайных величин взаимная информация равна нулю:

$$MI(X,Y) = H(Y) - H(Y|X) = H(Y) - H(Y) = 0$$

- Если одна случайная величина X является детерминированной функцией другой случайной величины Y, взаимная информация равна энтропии т.е.

$$Y = f(X) \Longrightarrow MI(X,Y) = H(Y) - H(Y|X) = \mathrm{H(Y)} - 0 = \mathrm{H(Y)}$$

В этом случае, взаимная информация принимает максимальное значение

Расчет взаимной информации на основе матрицы сопряженности

Дана выборка из $X^l = \{x_1, x_2, \dots x_l\}$ из l элементов, разделение на классы $X=\{X_1,X_2,\dots,X_r\}$, и полученное разделение на кластеры $Y=\{Y_1,Y_2,\dots,Y_s\}$, совпадения между X и Y могут быть отражены в таблице сопряженности.

X \ Y	Y_1	Y_2	…	Y_s	Суммы
X_1	n_{11}	n_{12}	…	n_{1s}	a_1
X_2	n_{21}	n_{22}	…	n_{2s}	a_2
…	…	…	…	…	…
X_r	n_{r1}	n_{r2}	…	n_{rs}	a_r
Суммы	b_1	b_2	…	b_s	l

$$a_1 = n_{11} + n_{12} + \dots + n_{1s}$$
$$b_1 = n_{11} + n_{21} + \dots + n_{r1}$$

n_{11} - общее число объектов,

которые попали

и в кластер X_1 и в кластер Y_1

MI рассчитывается на основе распределения вероятности по выборке:

$$MI(X,Y) = \sum_{i=1}^{r}\sum_{j=1}^{s} \frac{n_{i,j}}{l} ln \frac{n_{i,j}N}{a_i b_j}$$

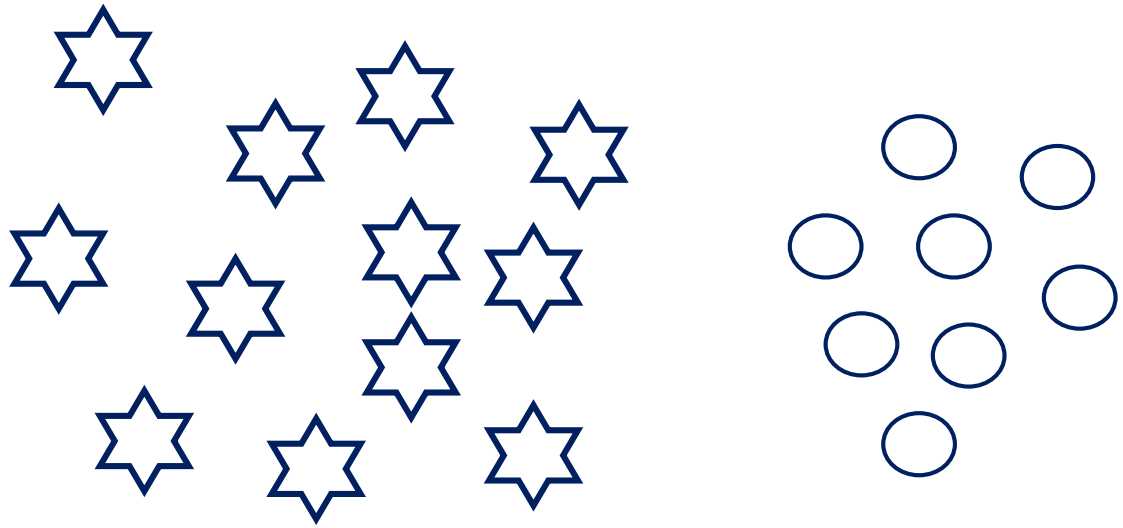
Если используется ln, единицей взаимной информации является нат . Если используется логарифмическая база 2, единицей взаимной информации является шеннон , также известный как бит.

Взаимная информация пример

Сравнить результат кластерного анализа с истинными метками.

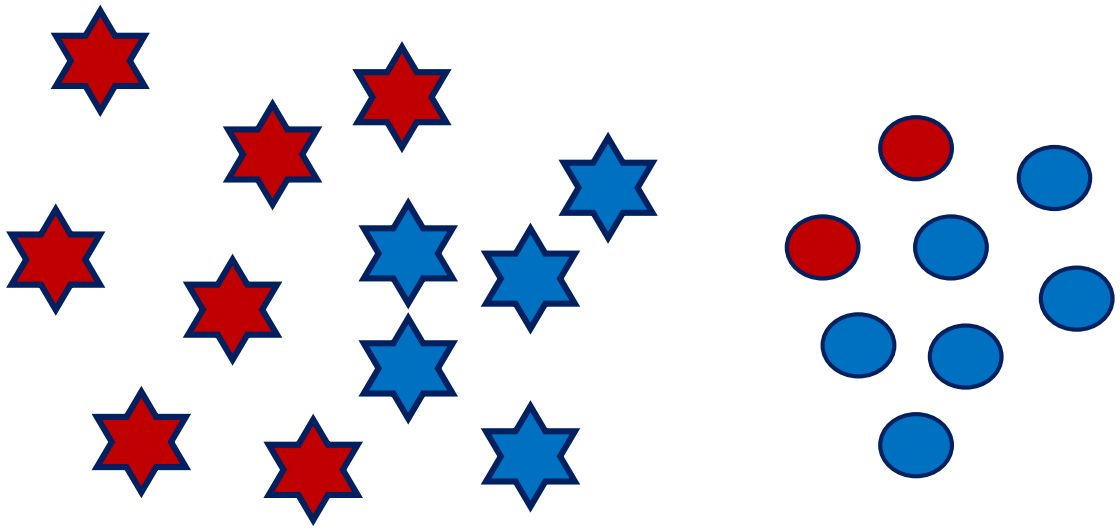
Дано: N=20 объектов.

Истинные метки были расставлены следующим образом: 2 кластера – звездочки и овал



Взаимная информация пример

Метки метода кластеризации расставлены при помощи цветов: 2 кластера – синий и красный



	Красные	Синие
Звезда 12	7	5
Овал 8	2	6

$$MI(X,Y) = \sum_{i=1}^{r}\sum_{j=1}^{s}\frac{n_{i,j}}{N} ln \frac{n_{i,j}N}{a_i b_j} = \frac{7}{20}\ln(\frac{7\cdot 20}{12\cdot 9}) + \frac{5}{20}\ln(\frac{5\cdot 20}{12\cdot 11}) + \frac{2}{20}\ln(\frac{2\cdot 20}{8\cdot 9}) + \frac{6}{20}\ln(\frac{6\cdot 20}{8\cdot 11})$$

Ограничения взаимной информации

- ✓Диапазон значений метрики MI интуитивно непонятен – решается нормализацией данной метрики. Kvalseth T. O. Entropy and correlation: Some comments. Systems // Man and Cybernetics, IEEE transactions on. – 1987. – 17(3). – 17–519.

- ✓Значение данной метрики не равно нулю, при случайных разбиениях данных – решается при помощи скорректированной взаимной информации (AMI)

Нормализованная взаимная информация (normalized mutual information - NMI)

Значения взаимной информации интуитивно-непонятно. Что если будет получено значение 4.5?

Насколько кластерный анализ выполнен адекватно относительно истинных меток объектов, либо другого метода кластерного анализа?

Очевидным решением является нормализация MI так, чтобы диапазон ее значений был бы [0, 1].

Если разделить значение взаимной информации на ее максимальное значение, то результат представляла бы собой нормализованное значение взаимной информации.

$$NMI = \frac{MI}{\max(MI)}$$

Какое значение можно выбрать за максимум взаимной информации?

NMI. Что принять за максимум взаимной информации?

В работе [Vinh, N. X., Epps, J., and Bailey, J. (2010). Information theoretic measures for clusterings comparison: Variants, properties, normalization and correction for chance. Journal of Machine Learning Research, 11:2837–2854.] предложен обзор различных способов нормализации MI.

$MI(X,Y) \in [0, \min\{H(X), H(Y)\}]$ Banerjee A., Dhillon I. S., Ghosh J., and Sra S. 2005.

Название NMI	Формула	Диапазон значений	Ссылка на литературу
NMI_{joint}	$\frac{MI(X,Y)}{H(X,Y)}$	[0, 1]	Yao Y. Y. 2003.
NMI_{max}	$\frac{MI(X,Y)}{\max\{H(X), H(Y)\}}$	[0, 1]	Kvalseth T. O. 1987.
NMI_{sum}	$\frac{2MI(X,Y)}{H(X) + H(Y)}$	[0, 1]	Kvalseth T. O. 1987.
NMI_{sqrt}	$\frac{MI(X,Y)}{\sqrt{H(X) \cdot H(Y)}}$	[0, 1]	Strehl A. and Ghosh J. 2003.
NMI_{min}	$\frac{MI(X,Y)}{\min\{H(X), H(Y)\}}$	[0, 1]	Kvalseth T. O. 1987. Liu, Z. Guo, and M. Tan. 2008

NMI. Можно использовать как меру сходства? [Vinh, N. X., Epps, J., and Bailey, J. 2010.]

MI – это неотрицательная метрика, которая могла бы быть использована как мера сходства.

MI ограничена сверху следующими значениями:

$$MI(X,Y) \le \min\{H(X),H(Y)\} \le \sqrt{H(X)\cdot H(Y)} \le \frac{1}{2}(H(X)+H(Y)) \le \max\{H(X),H(Y)\} \le H(X,Y)$$

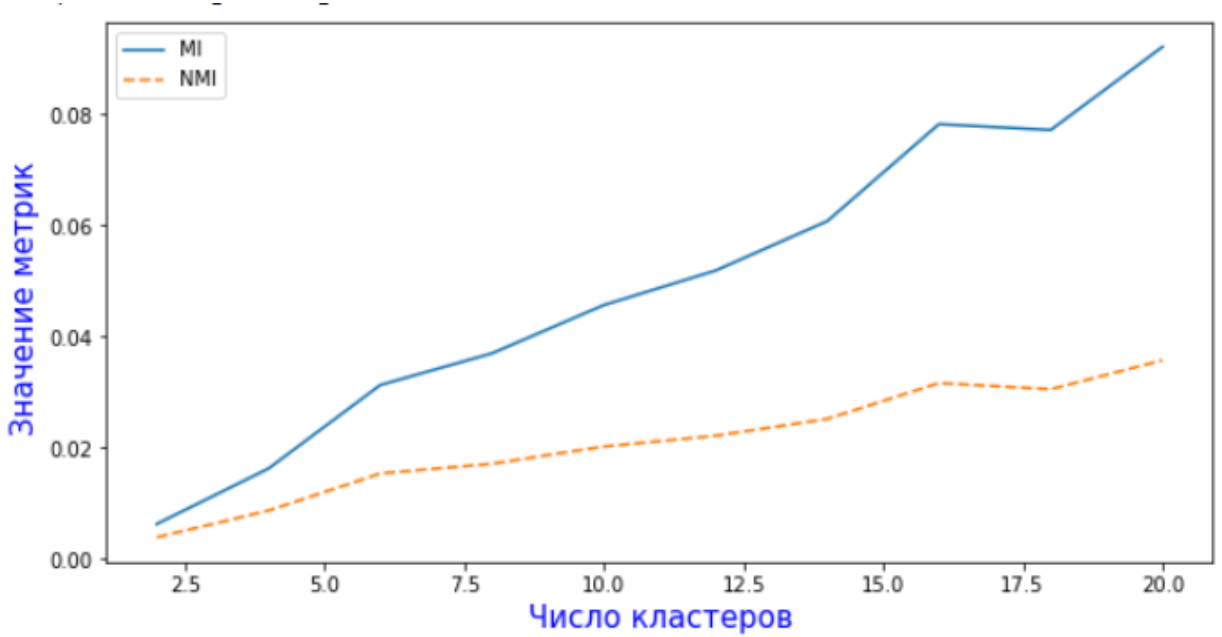
Опираясь на неравенство, представленное выше можно использовать некоторые нормализованные меры взаимной информации как меру сходства:

Название меры	**Формула**	**Диапазон значений**	**Является метрикой расстояния?**
D_{joint}	$H(X,Y) - MI(X,Y)$	[0, log*N*]	Да
D_{max}	$\max\{H(X),H(Y)\} - MI(X,Y)$	[0, log*N*]	Да
$D_{sum} = \frac{1}{2}D_{joint}$	$H(X)+H(Y) - 1/2MI(X,Y)$	[0, log*N*]	Да
D_{sqrt}	$\sqrt{H(X)\cdot H(Y)} - MI(X,Y)$	[0, log*N*]	Нет
D_{min}	$\min\{H(X),H(Y)\} - \mathrm{MI(X,Y)}$	[0, log*N*]	Нет

NMI. Ограничение

NMI теперь ранжируется в заранее заданном диапазоне [0, 1], где 1 получается в случае, если два метода кластеризации работают идентично, либо выбранный метод кластеризации отработал в соответствии с заранее заданными метками классов.

Однако, *NMI* не дает 0 во всех случаях, когда *X* и *Y* независимые множества (случайные множества меток).



Исходные данные:
1000 объектов. Кластеризация A выполнена и выявлено 10 кластеров.

Кластеризация B – сделана случайно. Число кластеров c варьируется от 2 до 21. Эксперимент с каждым числом кластеров повторяется по 30 раз, значение метрики усредняется.

При возрастании числа кластеров – растет значение метрик. Ссылка на ноутбук.

Скорректированная взаимная информация Adjusted mutual information (AMI)

Для того, чтобы скорректировать взаимную информацию из взаимной информации вычитается ожидаемое значение взаимной информации для случая когда множества *X, Y* получены случайным образом (независимо).

Результат такой корректировки статистически нормализуется т.е. 0 будет получен в том случае, если два множества X,Y получены независимо (случайно).

$$AMI = \frac{MI - E[MI]}{\max(MI) - E[MI]}$$

Для того, чтобы рассчитать ожидаемое значение взаимной информации для случая, когда множества X, Y независимы используется «модели перестановок» согласно которой кластеризация генерируются случайным образом с учетом наличия фиксированного количества кластеров и объектов в каждом кластере.

Ожидаемое значение взаимной информации E[MI]

[Vinh, N. X., Epps, J., and Bailey, J. 2010.]

E[MI] получается путем суммирования всех возможных значений таблиц сопряженности из множества *M*, которые строятся при помощи всех возможных перестановок объектов выборки между кластерами.

$$E[MI] = \sum_{M} MI(M)P(M) = \sum_{M}\sum_{i,j} \frac{n_{i,j}}{N} ln \frac{n_{i,j}N}{a_i b_j} P(M)$$

Ограничения:

✓ Не существует метода исчерпывающей генерации M

✓ Такая генерация чрезвычайно затратная по времени (вычисление перестановок требует O (n!))

Однако можно поменять местами внутреннее суммирование с внешним суммированием, тогда:

$$E[MI] = \sum_{M}\sum_{i,j} \frac{n_{i,j}}{N} ln \frac{n_{i,j}N}{a_i b_j} P(M) = \sum_{i,j}\sum_{n_{i,j}} \frac{n_{i,j}}{N} ln \frac{n_{i,j}N}{a_i b_j} P(n_{i,j})$$

Поменять местами

Изменено

$n_{i,j}$ имеет известное гипергеометрическое распределение, что позволяет значительно сократить время вычисления

Расчетная формула AMI

[Vinh, N. X., Epps, J., and Bailey, J. 2010.]

В зависимости от выбранного функционала для нормализации взаимной информации по верхней границе, можно использовать следующие расчётные формулы AMI:

Название AMI	Формула	Диапазон значений
AMI_{max}	$\frac{MI(X,Y) - E[MI(X,Y)]}{\max\{H(X), H(Y)\} - E[MI(X,Y)]}$	[0, 1]
AMI_{sum}	$\frac{MI(X,Y) - E[MI(X,Y)]}{\frac{1}{2}\left(H(X) + H(Y)\right) - E[MI(X,Y)]}$	[0, 1]
AMI_{sqrt}	$\frac{MI(X,Y) - E[MI(X,Y)]}{\sqrt{H(X) \cdot H(Y)} - E[MI(X,Y)]}$	[0, 1]
AMI_{min}	$\frac{MI(X,Y) - E[MI(X,Y)]}{\min\{H(X), H(Y)\} - E[MI(X,Y)]}$	[0, 1]

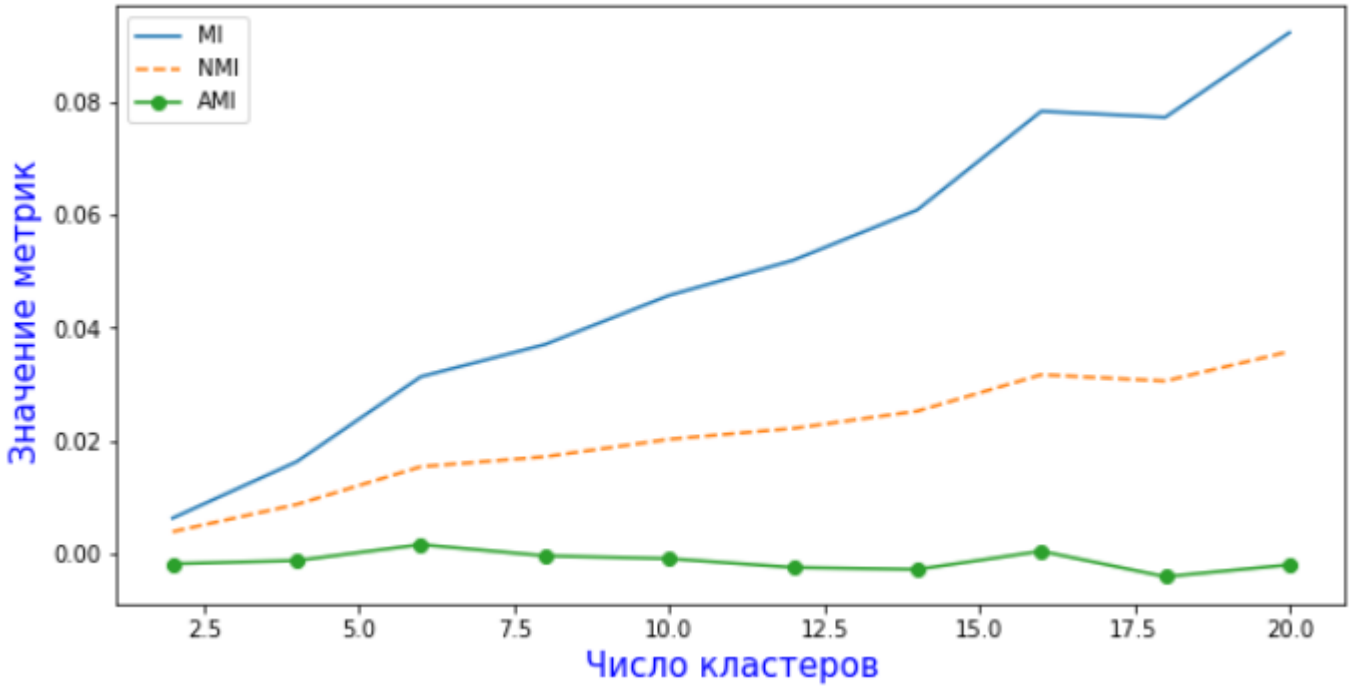
Эти показатели нормированы в статистическом смысле т.е. 0 будет получен в случае, если нескорректированная взаимная информация рассчитана для случайной разбивки на кластеры относительно заранее заданных меток или другого алгоритма кластеризации.

*Отрицательные значения AMI получить возможно, однако, эти значения интерпретируется как результат сравнимый с 0, то есть результат кластеризации даже «хуже», чем ожидаемый от случайности результат.

AMI при случайной кластеризации

Исходные данные: Дано 1000 объектов. Кластеризация A выполнена и выявлено 10 кластеров. Кластеризация B – выполнена случайно. Число кластеров c варьируется от 2 до 21. Эксперимент с каждым числом кластеров повторяется по 30 раз, значение метрики усредняется.

При возрастании числа кластеров – значение метрики AMI остается на прежнем уровне около 0.



AMI ограничения

AMI не учитывает систематическую ошибку отбора. Для того, чтобы учесть эти ограничения, можно использовать стандартизованную взаимную информацию (SMI)

[Romano S., Bailey J., Nguyen V., Verspoor K. Standardized mutual information for clustering comparisons: One step further in adjustment for chance. // Proceedings of the 31st International Conference on Machine Learning (ICML-14) . – 2014 . – 1143–1151p.]

F-мера

Пусть дана выборка объектов $X^l = \{x_1, x_2, \dots x_l\}$ из l элементов уже разделенная на кластеры $K=\{k_1,k_2,\dots,k_s\}$. Кроме этого известны истинные метки классов объектов, представленных в выборке $C=\{c_1,c_2,\dots,c_r\}$.

$$F(C,K) = \sum_{\substack{c_i \in C, \\ i=1\dots r}} \frac{|c_i|}{l} \max_{\substack{k_j \in K, \\ j=1\dots s}} \{F(c_i,k_j)\}$$

C \ K	k_1	k_2	…	k_s	Суммы
c_1	n_{11}	n_{12}	…	n_{1s}	a_1
c_2	n_{21}	n_{22}	…	n_{2s}	a_2
…	…	…	…	…	…
c_r	n_{r1}	n_{r2}	…	n_{rs}	a_r
Суммы	b_1	b_2	…	b_s	l

$$F(c_i,k_j) = \frac{2 \cdot R(c_i,k_j) \cdot P(c_i,k_j)}{R(c_i,k_j)+P(c_i,k_j)},$$

где $R(c_i,k_j)$ - это полнота (Recall), рассчитывается как доля элементов из класса c_i, которые присутствуют в кластере k_j,т.е. полнота измеряет насколько полным является кластер k_j по отношению к классу c_i.

$$R(c_i,k_j) = \frac{n_{i,j}}{|c_i|}$$

$P(c_i,k_j)$ - это точность (Precision), рассчитывается как доля элементов кластера k_j, которая входит в состав класса c_i, таким образом точность показывает насколько кластер k_j однороден по отношению к классу c_i

$$P(c_i,k_j) = \frac{n_{i,j}}{|k_j|}$$

F – значение варьируется от 0 до 1

Гомогенность

Гомогенность – это метрика основанная на энтропии Шенона, показывающая насколько два метода кластеризации схожи, либо насколько выбранный алгоритм кластеризации соответствуют референсным значениям меток классов.

K – результат кластеризации

C – истинное разбиение выборки на классы.

Гомогенность h измеряет, насколько каждый кластер состоит из объектов одного класса.

$$h = 1 - \frac{H(C|K)}{H(C)}$$

Идеальными являются такие обстоятельства, когда результат кластеризации полностью совпал с истинными метками классов. В этом случае, $H(C|K)$ = 0 и тогда *h=1*

Если свести данные кластеризации в таблицу сопряженности, то гомогенность можно вычислить следующим образом:

X \ **K**	K_1	K_2	…	$K_{\|K\|}$	Суммы
C_1	n_{11}	n_{12}	…	n_{1s}	a_1
C_2	n_{21}	n_{22}	…	n_{2s}	a_2
…	…	…	…	…	…
$C_{\|C\|}$	n_{r1}	n_{r2}	…	n_{rs}	$a_{\|C\|}$
Суммы	b_1	b_2	…	$b_{\|K\|}$	l

$$H(\mathrm{C}|K) = -\sum_{i=1}^{|K|}\sum_{j=1}^{|C|}\frac{n_{j,i}}{l}ln\frac{n_{j,i}}{b_i}$$

$$H(C) = -\sum_{i=1}^{|C|}\frac{\sum_{j=1}^{|K|}n_{i,j}}{|C|}\ln\left(\frac{\sum_{j=1}^{|K|}n_{i,j}}{|C|}\right)$$

Полнота - Completeness

Полнота – это метрика симметричная гомогенности, также вычисляется при помощи энтропии Шенона, показывает насколько объекты одного класса относятся к одному кластеру.

K – результат кластеризации, C – истинное разбиение выборки на классы.

$$c = 1 - \frac{H(K|C)}{H(K)}$$

Идеальными являются такие обстоятельства, когда объекты класса попали в соответствующие кластеры. В этом случае, $H(K|C) = 0$ и тогда *c=1*

Если свести данные кластеризации в таблицу сопряженности, то полноту можно рассчитать следующим образом:

X \ **K**	K_1	K_2	…	$K_{\|K\|}$	Суммы
C_1	n_{11}	n_{12}	…	n_{1s}	a_1
C_2	n_{21}	n_{22}	…	n_{2s}	a_2
…	…	…	…	…	…
$C_{\|C\|}$	n_{r1}	n_{r2}	…	n_{rs}	$a_{\|C\|}$
Суммы	b_1	b_2	…	$b_{\|K\|}$	l

$$H(K|C) = -\sum_{i=1}^{|C|}\sum_{j=1}^{|K|}\frac{n_{ij}}{l}\,ln\frac{n_{i,j}}{a_i}$$

$$H(K) = -\sum_{i=1}^{|K|}\frac{\sum_{j=1}^{|C|}(n_{j,i})}{|C|}\ln\left(\frac{\sum_{j=1}^{|C|}n_{j,i}}{|C|}\right)$$

V-мера

[Andrew Rosenberg and Julia Hirschberg, 2007. V-Measure: A conditional entropy-based external cluster evaluation measure]

Гомогенность и полнота принимают значение в диапазоне [0, 1]. Однако, также как и взаимная информация меры не являются нормализованными в статистическом смысле. То есть при случайных кластеризациях значения этих мер не будет равно 0, а будет зависеть от числа кластеров.

V-мера это средняя гармоническая мера рассчитанная от гомогенности и полноты.

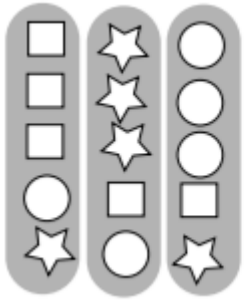
$$\mathrm{V} = 2\frac{hc}{h+c}$$

Она является симметричной и показывает, насколько две кластеризации схожи между собой.

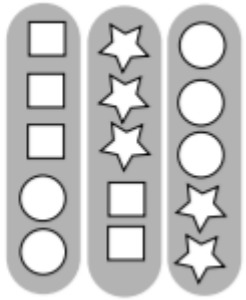
V-мера совершенно не зависит от количества классов и количества кластеров

V-мера, F-мера эксперимент

[Andrew Rosenberg and Julia Hirschberg, 2007. V-Measure: A conditional entropy-based external cluster evaluation measure]



Случай A
F=0,6
V=0,14



Случай B
F=0,6
V=0,39



Случай C
F=0,5
V=0,30



Случай D
F=0,5
V=0,41

На рисунках заштрихованные области представляют КЛАСТЕРЫ, фигуры представляют КЛАССЫ.

При идеально выполненном кластерном анализе, каждая заштрихованная область будет содержать фигуры одной формы.

Рассчитаем для случая A

	K1	K2	K3
■	3	1	1
●	1	1	3
★	1	3	1

$$R(c_1, k_1) = \frac{3}{5}$$

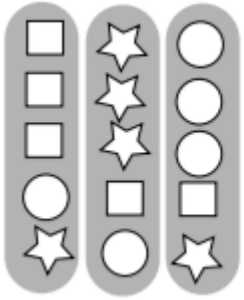
$$P(c_1, k_1) = \frac{3}{5}$$

...

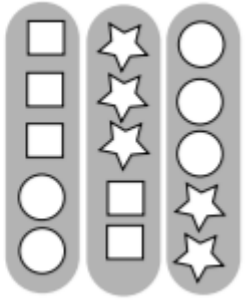
$$F = 3/5 = 0{,}6$$

V-мера, F-мера эксперимент

[Andrew Rosenberg and Julia Hirschberg, 2007. V-Measure: A conditional entropy-based external cluster evaluation measure]



Случай A
F=0,6
V=0,14



Случай B
F=0,6
V=0,39



Случай C
F=0,5
V=0,30



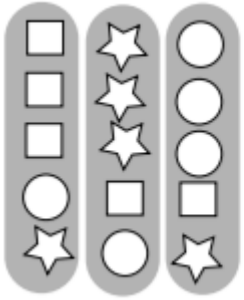
Случай D
F=0,5
V=0,41

Для случая A и B в каждом кластере «угадано» верно 3 объекта из 5.
F мера для обоих случаев (A и B) одинакова.

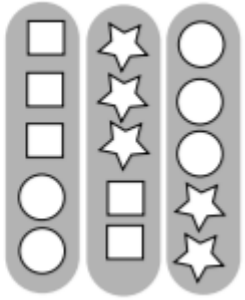
Результат кластеризации в случае B все же лучше результатов в случае A с точки зрения однородности (гомогенности), то есть каждый кластер содержит меньше разных классов, если сравнивать со случаем A.
Естественно, что по этой причине V-мера для случая B получилась больше.

V-мера, F-мера эксперимент

[Andrew Rosenberg and Julia Hirschberg, 2007. V-Measure: A conditional entropy-based external cluster evaluation measure]



Случай A
F=0,6
V=0,14



Случай B
F=0,6
V=0,39



Случай C
F=0,5
V=0,30



Случай D
F=0,5
V=0,41

Для случая C и D рассматривается ситуация, когда не все кластеры учитываются при расчете F-меры.

В обоих случаях С и Д F-мера получилась 0.5. Но Маленькие кластеры не учитываются при подсчете F-меры.

Случай D все же лучше случая С, потому что кластеры не содержат неверных классов (т.е одновременно два класса) как в случае С.

V-мера отражает это большим значением для случая D.

Силуэт

[Peter J. Rousseeuw (1987). “Silhouettes: a Graphical Aid to the Interpretation and Validation of Cluster Analysis”. Computational and Applied Mathematics 20: 53-65.]

Силуэт не предполагает знания истинных меток объектов или меток, и позволяет оценить качество кластеризации, используя только саму (неразмеченную) выборку и результат кластеризации.

Значение силуэта является мерой того, насколько похож объект на другие объекты, из своего кластера в сравнении с объектами из других кластеров.

Значение силуэта варьируется от -1 до 1.

Силуэт. Вычисление для объекта

[Peter J. Rousseeuw (1987). “Silhouettes: a Graphical Aid to the Interpretation and Validation of Cluster Analysis”. Computational and Applied Mathematics 20: 53-65.]

*1. С*илуэт определяется отдельно для каждого объекта.

Пусть дана выборка объектов $X^l = \{x_1, x_2, \dots x_l\}$ из l элементов уже разделенная на кластеры $C=\{C_1,C_2,\dots,C_r\}$

✓ *Для объекта* x_i *из кластера* $C_j, j \in [1 \dots r]$ *мера:*

$$a(x_i) = \frac{1}{|C_j|} \sum_{k \in C_j, i \neq k} d(x_i, x_k)$$

будет обозначать среднее расстояние между объектом x_i и другими объектами того же кластера.

✓ *Для объекта* x_i *из кластера* $C_j, j \in [1 \dots r]$ *мера:*

$$b(x_i) = \min_{\substack{j \neq k, \\ k=1 \dots r}} \frac{1}{|C_k|} \sum_{m \in C_k,} d(x_i, x_m)$$

будет обозначать наименьшее среднее расстояние от объекта x_i до объектов из других кластеров. Кластер до которого такое среднее расстояние является наименьшим будет называться соседним кластером.

✓ Далее можно определить силуэт для объекта x_i *из кластера* $C_j, j \in [1 \dots r]$:

$$s(x_i) = \begin{cases} \dfrac{b(x_i) - a(x_i)}{\max\{a(x_i), b(x_i)\}}, \text{если } |C_j| > 1 \\ 0, \text{если } |C_j| = 1 \end{cases}$$

$$\text{Отметим, что если } |C_j| = 1, \text{то } a(x_i) = 0$$

Силуэт. Вычисление для выборки объектов

[Peter J. Rousseeuw (1987). “Silhouettes: a Graphical Aid to the Interpretation and Validation of Cluster Analysis”. Computational and Applied Mathematics 20: 53-65.]

2. После того как силуэт рассчитан для каждого объекта, можно рассчитать значение силуэта для выборки объектов, которые были разделены на кластеры. Среднее значение $s(x_i)$ по всем объектам из набора данных показывает насколько хорошо была выполнена кластеризация и тем кластеры лучше отделены друг от друга.

$$\tilde{s} = \frac{1}{l}\sum_{i=1}^{l} s(x_i)$$

По значению силуэта можно судить о том, какой из вариантов кластеризации лучше. Например, если есть несколько результатов кластеризации, допустим при помощи k-means (возможно, по разному центройды выбраны или разные число кластеров), то большее значение силуэта говорит о лучшем варианте кластеризации.

Ссылка на литературу

1. Yao, Y. Y.. Information-theoretic measures for knowledge discovery and data mining. // Entropy Measures, Maximum Entropy Principle and Emerging Applications. Karmeshu (ed.), Springer. – 2003, . – 115–136. Karmeshu (ed.), Springer.

2. Kvalseth T. O. Entropy and correlation: Some comments. // Man and Cybernetics, IEEE transactions on. – 1987. – 17(3). – 17–519.

3. Strehl A., Ghosh, J. Cluster ensembles—a knowledge reuse framework for combining multiple partitions // The Journal of Machine Learning Research . – 2003 . – 3:583–617.

4. Vinh N. X., Epps J., Bailey, J. Information theoretic measures for clusterings comparison: Variants, properties, normalization and correction for chance // Journal of Machine Learning Research . – 2010. – 11:2837–2854.

5. Liu Z., Guo Z. , Tan M. Constructing tumor progression pathways and biomarker discovery with fuzzy kernel kmeans and dna methylation data // Cancer Inform.- 2008. – 6: 1–7.

6. Banerjee A., Dhillon I. S. , Ghosh J., Sra S. Clustering on the unit hypersphere using von mises-fisher distributions. J. Mach. Learn. Res., 2005. – 6: 1345–1382.

7. Romano S., Bailey J., Nguyen V., Verspoor K. Standardized mutual information for clustering comparisons: One step further in adjustment for chance. // Proceedings of the 31st International Conference on Machine Learning (ICML-14) . – 2014 . – 1143–1151

Ссылка на литературу

8. Rousseeuw P. J. Silhouettes: a Graphical Aid to the Interpretation and Validation of Cluster Analysis // . Computational and Applied Mathematics. – 1987 . – 20: 53-65.
9. Rosenberg A., Hirschberg J., V-Measure: A conditional entropy-based external cluster evaluation measure, // Proceedings of the 2007 Joint Conference on Empirical Methods in Natural Language Processing and Computational Natural Language Learning(EMNLP-CoNLL). – 2007. – 410-420.
10. Evaluation of Clusterings – Metrics and Visual Support. URL: https://imada.sdu.dk/~zimek/publications/ICDE2012/ICDE12_ELKI_0_5.pdf
11. Hierarchical Document Clustering Using Frequent Itemsets. URL: http://citeseerx.ist.psu.edu/viewdoc/download?doi=10.1.1.138.8984&rep=rep1&type=pdf

TYCYP
TUSUR UNIVERSITY