ТУСУР
TUSUR UNIVERSITY

Машинное обучение на базе правил

Доцент каф. КИБЭВС ТУСУР, канд. техн. наук
Якимук Алексей Юрьевич

ТУСУР
TUSUR UNIVERSITY

Основные понятия

Анализ потребительской корзины



- Все импульсивные покупки неслучайны, т.к. продавцы используют сложные методы поиска закономерностей, чтобы определить шаблоны потребительского поведения.
- Первоначально данные рекомендации строились на субъективном опыте и интуиции специалистов по маркетингу или менеджеров служб снабжения.
- Современные технологии позволяют собирать данные по всем транзакциям, осуществляемым в магазинах, и анализировать их.

Анализ потребительской корзины

ТУСУР
TUSUR UNIVERSITY

Цель анализа потребительской корзины — выявить действенные паттерны. Их можно выявить в любой сфере. Даже не связанной с розничными продажами.

Составными частями анализа потребительской корзины являются товары, которые есть в любой **транзакции**.

Если группа из одного или нескольких элементов заключена в фигурные скобки, это означает, что данные элементы образуют множество — множество товаров, которое встречается в данных с некоторой регулярностью. Транзакции определяются как множества товаров.

{хлеб, арахисовое масло, мармелад}

Анализ потребительской корзины

ТУСУР
TUSUR UNIVERSITY

Результатом анализа потребительской корзины является набор ассоциативных правил, которые определяют закономерности, обнаруженные во взаимосвязях между содержимым множества элементов.

Ассоциативные правила всегда состоят из двух подмножеств множества элементов и обозначаются как отношение между

- подмножеством элементов, расположенным слева ***(Left-Hand Side, LHS)***;
- подмножеством, расположенным справа ***(Right-Hand Side, RHS)***.

Анализ потребительской корзины

ТУСУР
TUSUR UNIVERSITY

LHS — это условие, которое должно быть выполнено для запуска правила, а ***RHS*** — ожидаемый результат выполнения этого условия.

Правило, сформулированное на основе транзакции из примера на предыдущем слайде, может быть выражено следующим образом:

$$\{\text{арахисовое масло, мармелад}\} \rightarrow \{\text{хлеб}\}.$$

Это ассоциативное правило гласит, что если покупатель приобретает арахисовое масло и мармелад, то, скорее всего, он также купит хлеб.

Другими словами, «покупка арахисового масла и мармелада подразумевает покупку хлеба»

Особенности данных алгоритмов

ТУСУР
TUSUR UNIVERSITY

- Алгоритмы обучения ассоциативных правил являются неконтролируемыми, поэтому нет необходимости в обучении алгоритма; данные не должны быть снабжены метками заранее.
- Программа просто выполняется для набора данных в надежде, что удастся выявить интересные зависимости.
- Не существует простого способа объективно измерить эффективность алгоритма обучения ассоциативных правил, кроме качественной оценки полезности — как правило, это оценка на глаз в той или иной форме

Применение методов анализа потребительской корзины

ТУСУР
TUSUR UNIVERSITY

Несмотря на то, что эта технология была основана на анализе покупок, она также полезна и в других областях.

Работа методов анализа потребительской корзины включает:

- использование простых показателей эффективности для поиска взаимосвязей в больших базах данных;
- понимание особенностей данных о транзакциях;
- умение выявлять полезные и действенные закономерности.

Применение методов анализа потребительской корзины

ТУСУР
TUSUR UNIVERSITY

Потенциальные области применения этой технологии включают:

- поиск интересных и часто встречающихся паттернов в последовательностях ДНК и белков среди данных о раковых заболеваниях;
- поиск паттернов покупок или медицинских жалоб в сочетании с мошенническим использованием кредитных карт или страховки;
- выявление вариантов поведения, которые предшествуют отказу покупателей от услуг сотовой связи или модернизации ими систем кабельного телевидения.

Меры для определения ассоциаций

ТУСУР
TUSUR UNIVERSITY

Существует три основные меры для определения ассоциаций:

- Поддержка – показывает то, как часто данный товарный набор появляется.
- Достоверность – показывает как часто товар Y появляется вместе с товаром X.
- Лифт – показывает то, как часто товары X и Y появляются вместе, одновременно учитывая, с какой частотой появляется каждый из них.

Поддержка

ТУСУР
TUSUR UNIVERSITY

Поддержка – показывает то, как часто данный товарный набор появляется.

- Измеряется долей покупок, в которых он присутствует.

В таблице[1] приведен пример покупок. Яблоко присутствует в 4 из 8 покупок, что соответствует поддержке в 50%.
Для определения часто встречающихся товарных наборов может быть установлен порог поддержки. Товарные наборы, встречаемость которых выше заданного числа будут считаться частотными.

$$\text{Поддержка}\{🍎\} = \frac{4}{8}$$

Покупка 1	
Покупка 2	
Покупка 3	
Покупка 4	
Покупка 5	
Покупка 6	
Покупка 7	
Покупка 8	

Теоретический минимум по Big Data. Всё, что нужно знать о больших данных. — СПб.: Питер, 2020. — 208 с

Достоверность

ТУСУР
TUSUR UNIVERSITY

Достоверность – показывает как часто товар Y появляется вместе с товаром X.

- Обозначают как {X -> Y}.
- Измеряется долей их одновременных появлений.

Данная мера может исказить степень важности предложенной ассоциации. Согласно таблице {яблоко->пиво} соответствует 75%. Однако, учитывается только то, как часто покупаются яблоки, но не то как часто покупают пиво. Как можно заметить, пиво в таблице тоже является популярным продуктом. Поэтому неудивительно, что покупки с яблоками часто содержат еще и пиво.



Покупка 1	🍎 🥤 🍚 🍗
Покупка 2	🍎 🥤 🍚
Покупка 3	🍎 🥤
Покупка 4	🍎 🍐
Покупка 5	🍾 🥤 🍚 🍗
Покупка 6	🍾 🥤 🍚
Покупка 7	🍾 🥤
Покупка 8	🍾 🍐

Лифт

Лифт – показывает то, как часто товары X и Y появляются вместе, одновременно учитывая, с какой частотой появляется каждый из них.

Лифт {яблоко->пиво} равен достоверности {яблоко->пиво}, деленной на частоту {пива}. Согласно таблице это значение будет равно 1. Это означает отсутствие связи между товарными позициями.

Значения лифта

- **больше единицы** означают, что товар Y вероятно купят вместе с товаром X;
- **меньше единицы** означают, что совместная покупка товаров X и Y маловероятна.

Покупка 1	
Покупка 2	
Покупка 3	
Покупка 4	
Покупка 5	
Покупка 6	
Покупка 7	
Покупка 8	

$$\text{Лифт}\{\text{🍎} \rightarrow \text{🥤}\} = \frac{\text{Поддержка}\{\text{🍎}, \text{🥤}\}}{\text{Поддержка}\{\text{🍎}\} \times \text{Поддержка}\{\text{🥤}\}}$$

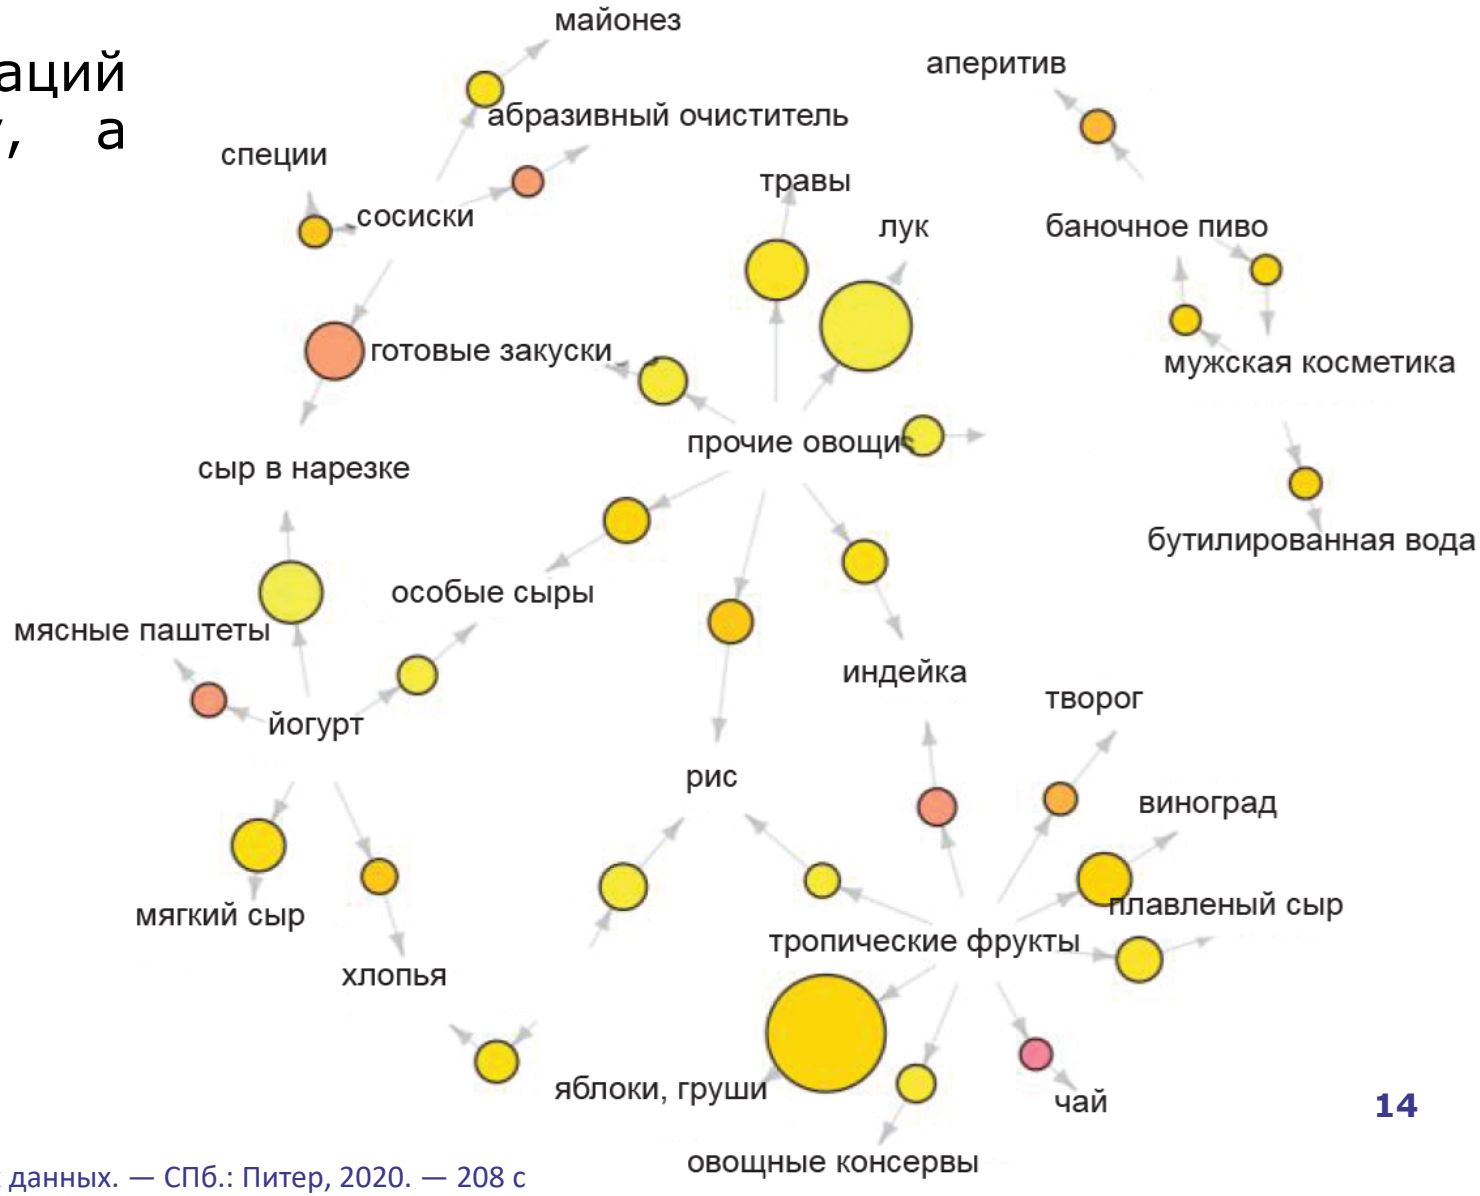
Ассоциации между товарами

ТУСУР
TUSUR UNIVERSITY

Большие круги на графе ассоциаций означают высокую поддержку, а темные — больший лифт.

На графе можно обнаружить следующие закономерности в покупках:

- чаще всего покупают яблоки и тропические фрукты;
- другая частая покупка: лук и овощи;
- если кто-то покупает сыр в нарезке, он, скорее всего, возьмет и сосиски;
- если кто-то покупает чай, то он, вероятно, возьмет и тропические фрукты.



Теоретический минимум по Big Data. Всё, что нужно знать о больших данных. — СПб.: Питер, 2020. — 208 с

Ассоциации между товарами

ТУСУР
TUSUR UNIVERSITY

Одним из недостатков меры «достоверность» является то, что она может создавать искаженное впечатление о значимости ассоциации.

Покупка	Поддержка	Достоверность	Лифт
Пиво → Газировка	1,38 %	17,8 %	1,0
Пиво → Ягоды	0,08 %	1,0 %	0,3
Пиво → Мужская косметика	0,09 %	1,2 %	2,6

Правило {пиво->газировка} имеет высокую достоверность — 17,8 %.

Однако и пиво, и газировка вообще часто появляются среди покупок, поэтому их ассоциация может оказаться простым совпадением. Это подтверждается значением лифта, указывающим на отсутствие связи между газировкой и пивом.

Ассоциации между товарами

ТУСУР
TUSUR UNIVERSITY

Значение поддержки для отдельных товаров в правилах, связанных с пивом можно выделить в таблицу.

Покупка	Поддержка
Пиво	7,77 %
Газировка	17,44 %
Ягоды	3,32 %
Мужская косметика	0,46 %

- Правило {пиво->мужская косметика} имеет низкую достоверность из-за того, что мужскую косметику вообще реже покупают. Тем не менее если кто-то покупает ее, он, вероятно, купит также и пиво, на что указывает высокое значение лифта в 2,6.
- Для пары {пиво->ягоды} верно обратное. Видя лифт меньше единицы, мы заключаем, что если кто-то покупает пиво, то он, скорее всего, не возьмет ягод.

ТУСУР
TUSUR UNIVERSITY

Принцип Apriori

Краткий смысл принципа

ТУСУР
TUSUR UNIVERSITY

Принцип Apriori утверждает, что если какой-то товарный набор редкий, то и бо̲льшие наборы, которые его включают, тоже должны быть редки.

Если редким в числе транзакций является, {пиво}, то редким должно быть и сочетание {пиво, пицца}. Таким образом, составляя список частотных товарных наборов, мы уже не будем рассматривать ни пару {пиво, пицца}, ни какую-либо другую с содержанием пива.

Алгоритм Apriori

ТУСУР
TUSUR UNIVERSITY

Шаг 0: начать с товарных наборов, содержащих всего один элемент.

Шаг 1: вычислить поддержку для каждого товарного набора. Оставить наборы, удовлетворяющие порогу, и отбросить остальные.

Шаг 2: увеличить размер анализируемого товарного набора на единицу и сгенерировать все возможные конфигурации, используя товарные наборы из предыдущего шага.

Шаг 3: повторять шаги 1 и 2, вычисляя поддержку для возрастающих товарных наборов до тех пор, пока они не закончатся.

Алгоритм Apriori

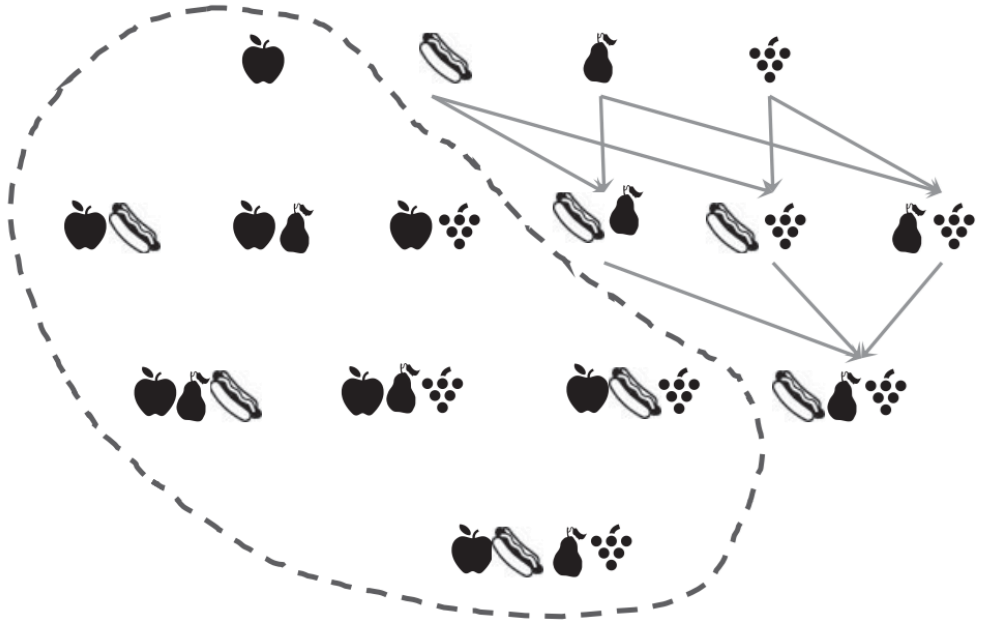
ТУСУР
TUSUR UNIVERSITY

Шаг 0: начать с товарных наборов, содержащих всего один элемент.

Шаг 1: вычислить поддержку для каждого товарного набора. Оставить наборы, удовлетворяющие порогу, и отбросить остальные.

Шаг 2: увеличить размер анализируемого товарного набора на единицу и сгенерировать все возможные конфигурации, используя товарные наборы из предыдущего шага.

Шаг 3: повторять шаги 1 и 2, вычисляя поддержку для возрастающих товарных наборов до тех пор, пока они не закончатся.



Если у элемента {яблоки} низкая поддержка, то он будет удален из списка анализируемых товарных наборов вместе со всем, что его содержит, тем самым это сократит число наборов для анализа более чем вдвое.

Товарные наборы в пределах пунктирной линии будут отброшены.

Сокращение количества правил

ТУСУР
TUSUR UNIVERSITY

Кроме определения товарных наборов с высокой поддержкой, принцип Apriori также может помочь найти товарные ассоциации с высокой достоверностью или лифтом.

Поиск этих ассоциаций требует меньше вычислений, поскольку если товарные наборы с высокой поддержкой известны, то достоверность и лифт вычисляются уже с использованием значения поддержки.

Если правило ***{A,B->C}*** имеет низкую достоверность, то и все другие правила с теми же образующими элементами и элементом ***{C}*** с правой стороны будут тоже иметь низкую достоверность, включая ***{A->C,B}*** и ***{B->C,A}***.

Как и прежде, эти правила могут быть отброшены благодаря принципу Apriori, тем самым снижая число потенциально рассматриваемых правил.

Ограничения

ТУСУР
TUSUR UNIVERSITY

- Требуются долгие вычисления

Хотя принцип Apriori и снижает число потенциальных товарных наборов для рассмотрения, оно все еще может быть достаточно значительным, если список товаров большой или указан низкий порог поддержки. В качестве альтернативного решения можно сократить число сравнений, используя расширенные структуры данных, чтобы отобрать потенциальные товарные наборы с большей эффективностью.

- Ложные ассоциации

В больших наборах данных ассоциации могут быть чистой случайностью. Чтобы убедиться, что обнаруженные ассоциации масштабируемы, их нужно оценить.

ТУСУР
TUSUR UNIVERSITY

Реализация принципа Apriori на R

Команды Apriori для анализа

ТУСУР
TUSUR UNIVERSITY

Команды на языке R

```
# Установка необходимых пакетов
install.packages("arules")
install.packages("arulesViz")

# Подключение пакетов
library(arules)
library(arulesViz)
```

- arules – пакет для анализа данных по транзакциям и выявления закономерностей (часто приобретаемых товаров и ассоциативных правил)
- arulesViz – пакет для визуализации ассоциативных правил и сочетаний товаров на основе arules.

Поиск ассоциативных правил

ТУСУР
TUSUR UNIVERSITY

```
myrules <- apriori(data = mydata, parameter =
 list(support = 0.1, confidence = 0.8, minlen = 1))
```

- data – разреженная матрица данных о транзакциях;
- support – минимально необходимая поддержка правила;
- confidence – минимально необходимое доверие правила;
- minlen – минимальное число элементов в транзакции.

- apriori - функция возвращает объект правил, в котором хранятся все правила, удовлетворяющие указанным минимальным критериям.

Проверка ассоциативных правил

```
inspect(myrules)
```

- myrules – множество ассоциативных правил, полученных с помощью функции apriori().
- inspect - функция выводит ассоциативные правила на экран. Для выбора одного или нескольких правил для просмотра можно применять к myrules векторные операторы.

Команды Apriori для анализа

ТУСУР
TUSUR UNIVERSITY

Команда на языке R

```
groceries <- read.transactions("groceries.csv", sep = ",")
```



Результат выполнения команды

В результате будет создана разреженная матрица с именем groceries, содержащая данные из файла groceries.csv

Команды Apriori для анализа

ТУСУР
TUSUR UNIVERSITY

Команда на языке R

```
summary(groceries)
```



Результат выполнения команды

```
transactions as itemMatrix in sparse format with
 9835 rows (elements/itemsets/transactions) and
 169 columns (items) and a density of 0.02609146

most frequent items:
      whole milk other vegetables       rolls/buns             soda           yogurt          (other)
            2513             1903             1809             1715             1372            34055

element (itemset/transaction) length distribution:
sizes
   1    2    3    4    5    6    7    8    9   10   11   12   13   14   15   16   17   18   19   20   21   22   23   24
2159 1643 1299 1005  855  645  545  438  350  246  182  117   78   77   55   46   29   14   14    9   11    4    6    1
  26   27   28   29   32
   1    1    1    3    1

   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  1.000   2.000   3.000   4.409   6.000  32.000

includes extended item information - examples:
            labels
1 abrasive cleaner
2 artif. sweetener
3   baby cosmetics
```

Команды Apriori для анализа

ТУСУР
TUSUR UNIVERSITY

Команда на языке R

```
inspect(groceries[1:5])
```



Результат выполнения команды

```
    items
[1] {citrus fruit, margarine, ready soups, semi-finished bread}
[2] {coffee, tropical fruit, yogurt}
[3] {whole milk}
[4] {cream cheese, meat spreads, pip fruit, yogurt}
[5] {condensed milk, long life bakery product, other vegetables, whole milk}
```

Команды Apriori для анализа

ТУСУР
TUSUR UNIVERSITY

Команда на языке R

```
itemFrequency(groceries[, 1:3])
```



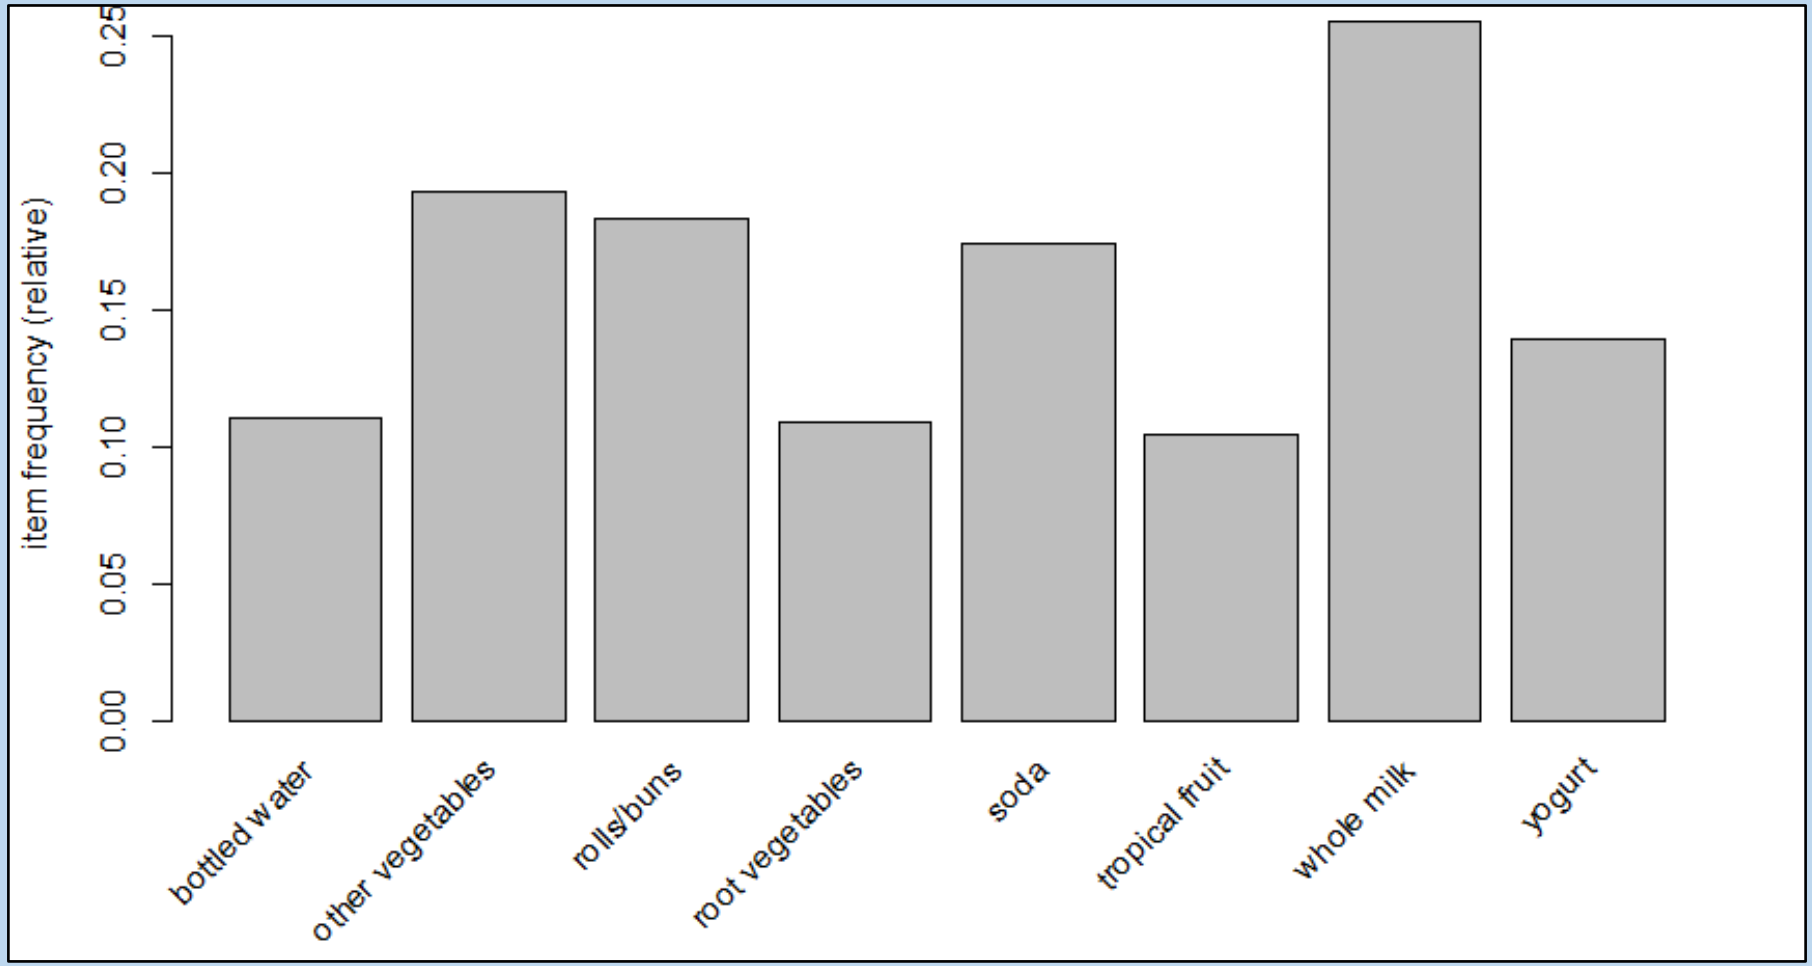
Результат выполнения команды

```
abrasive cleaner artif. sweetener   baby cosmetics
     0.0035587189      0.0032536858      0.0006100661
```

Команда на языке R

```
itemFrequencyPlot(groceries, support = 0.1)
```

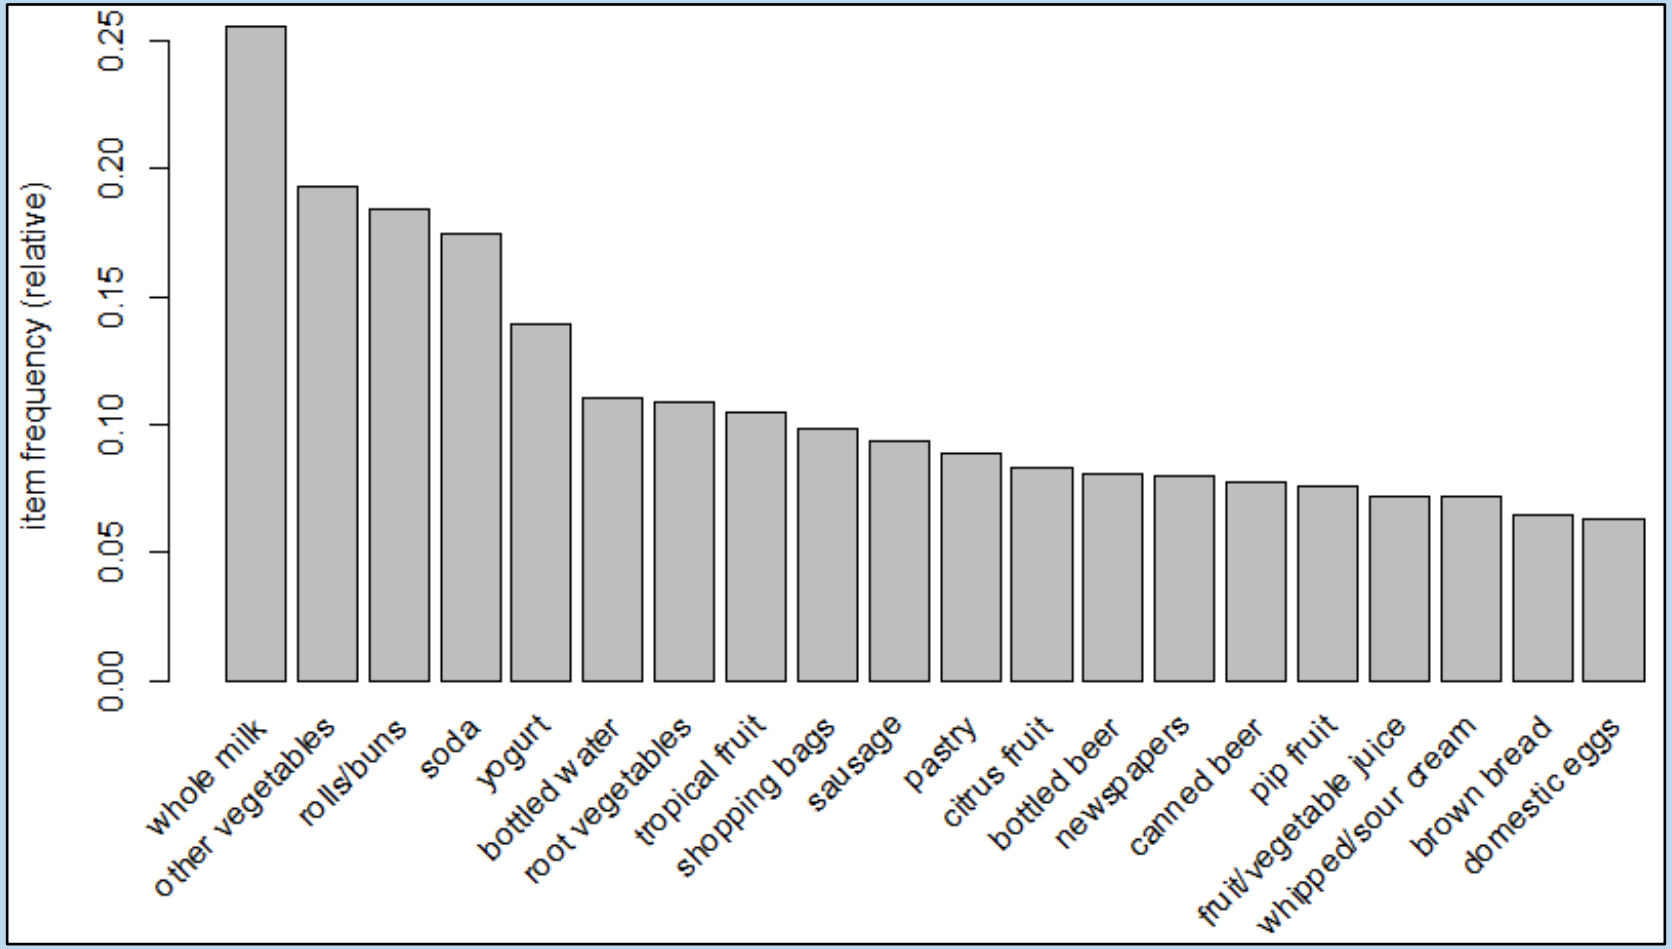
Результат выполнения команды



Команда на языке R

```
itemFrequencyPlot(groceries, topN = 20)
```

Результат выполнения команды



Команды Apriori для анализа

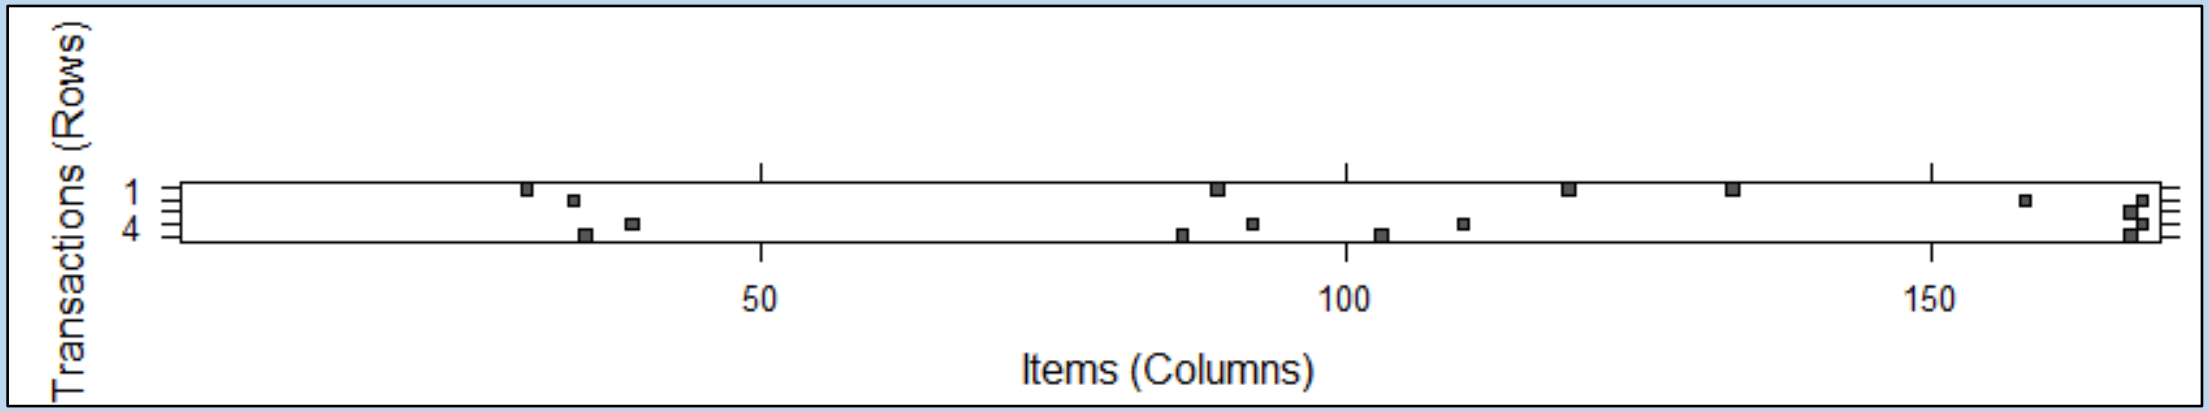
ТУСУР
TUSUR UNIVERSITY

Команда на языке R

```
image(groceries[1:5])
```

R

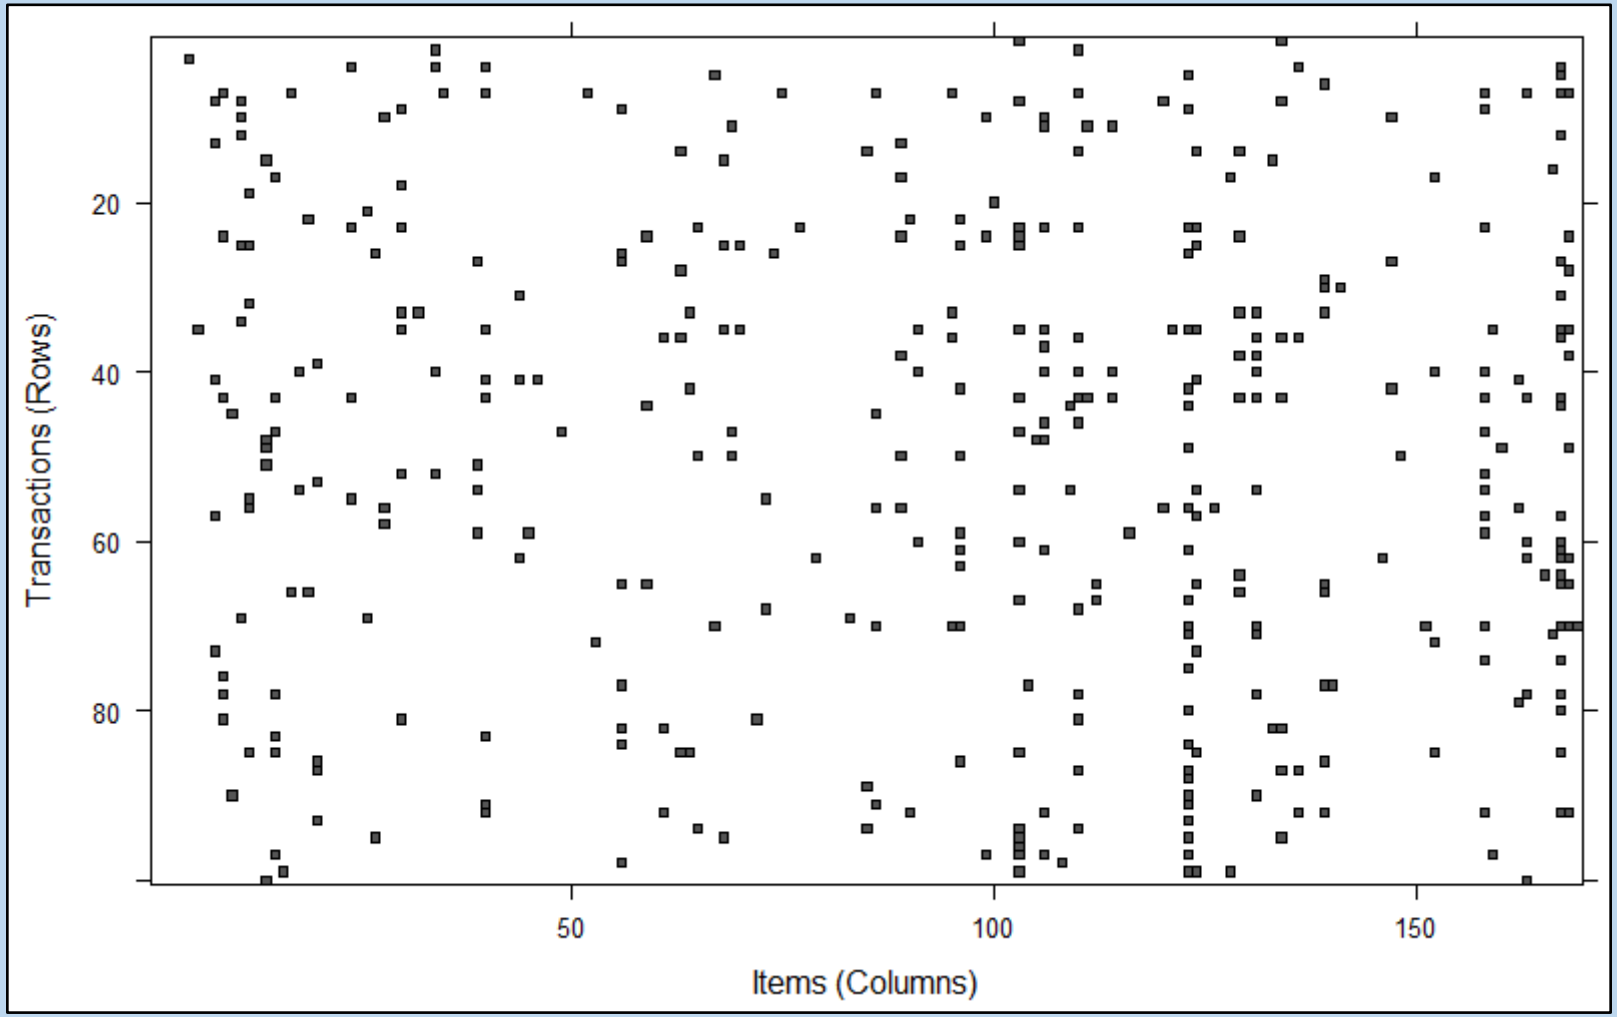
Результат выполнения команды



Команда на языке R

```
image(sample(groceries, 100))
```

Результат выполнения команды



Команда на языке R

```
apriori(groceries)
```

Результат выполнения команды

```
Apriori

Parameter specification:
 confidence minval smax arem  aval originalSupport maxtime support minlen maxlen target  ext
        0.8    0.1    1 none FALSE            TRUE       5     0.1      1     10  rules TRUE

Algorithmic control:
 filter tree heap memopt load sort verbose
    0.1 TRUE TRUE  FALSE TRUE    2    TRUE

Absolute minimum support count: 983

set item appearances ...[0 item(s)] done [0.00s].
set transactions ...[169 item(s), 9835 transaction(s)] done [0.04s].
sorting and recoding items ... [8 item(s)] done [0.00s].
creating transaction tree ... done [0.00s].
checking subsets of size 1 2 done [0.00s].
writing ... [0 rule(s)] done [0.00s].
creating S4 object  ... done [0.00s].
set of 0 rules
```

Команда на языке R

```
groceryrules <- apriori(groceries, parameter = list(support
= 0.006, confidence = 0.25, minlen = 2))
```

Результат выполнения команды

```
Apriori

Parameter specification:
 confidence minval smax arem  aval originalSupport maxtime support minlen maxlen target  ext
       0.25    0.1    1 none FALSE            TRUE       5   0.006      2     10  rules TRUE

Algorithmic control:
 filter tree heap memopt load sort verbose
    0.1 TRUE TRUE  FALSE TRUE    2    TRUE

Absolute minimum support count: 59

set item appearances ...[0 item(s)] done [0.00s].
set transactions ...[169 item(s), 9835 transaction(s)] done [0.00s].
sorting and recoding items ... [109 item(s)] done [0.00s].
creating transaction tree ... done [0.00s].
checking subsets of size 1 2 3 4 done [0.00s].
writing ... [463 rule(s)] done [0.00s].
creating S4 object  ... done [0.00s].
```

Команда на языке R

```
summary(groceryrules)
```

Результат выполнения команды

```
set of 463 rules

rule length distribution (lhs + rhs):sizes
  2   3   4
150 297  16

   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  2.000   2.000   3.000   2.711   3.000   4.000

summary of quality measures:
    support           confidence        coverage             lift           count
 Min.   :0.006101   Min.   :0.2500   Min.   :0.009964   Min.   :0.9932   Min.   : 60.0
 1st Qu.:0.007117   1st Qu.:0.2971   1st Qu.:0.018709   1st Qu.:1.6229   1st Qu.: 70.0
 Median :0.008744   Median :0.3554   Median :0.024809   Median :1.9332   Median : 86.0
 Mean   :0.011539   Mean   :0.3786   Mean   :0.032608   Mean   :2.0351   Mean   :113.5
 3rd Qu.:0.012303   3rd Qu.:0.4495   3rd Qu.:0.035892   3rd Qu.:2.3565   3rd Qu.:121.0
 Max.   :0.074835   Max.   :0.6600   Max.   :0.255516   Max.   :3.9565   Max.   :736.0

mining info:
      data ntransactions support confidence
 groceries          9835   0.006       0.25
                                                                                call
 apriori(data = groceries, parameter = list(support = 0.006, confidence = 0.25, minlen = 2))
```

Команды Apriori для анализа

ТУСУР
TUSUR UNIVERSITY

Команда на языке R

```
inspect(groceryrules[1:3])
```



Результат выполнения команды

```
    lhs                  rhs                    support     confidence coverage   lift     count
[1] {potted plants}   => {whole milk}       0.006914082 0.4000000  0.01728521 1.565460 68
[2] {pasta}           => {whole milk}       0.006100661 0.4054054  0.01504830 1.586614 60
[3] {herbs}           => {root vegetables}  0.007015760 0.4312500  0.01626843 3.956477 69
```

Визуализация данных результатов

ТУСУР
TUSUR UNIVERSITY

Команда на языке R

```
rules <- apriori(groceries, parameter = list(support
= 0.006, confidence = 0.25, minlen = 2))

# создание таблицы данных

redundant <- is.redundant(rules)

rules <- rules[!redundant]

table <- inspectDT(rules)

# создание виджета для отображения таблицы

htmlwidgets::saveWidget(table, "arules.html",
selfcontained = FALSE)

browseURL("arules.html")
```

Результат выполнения команды

Show 10 entries Search:

	LHS	RHS	support	confidence	coverage	lift	count
	All	All	All	All	All	All	All
[1]	{potted plants}	{whole milk}	0.007	0.400	0.017	1.565	68.000
[2]	{pasta}	{whole milk}	0.006	0.405	0.015	1.587	60.000
[3]	{herbs}	{root vegetables}	0.007	0.431	0.016	3.956	69.000
[4]	{herbs}	{other vegetables}	0.008	0.475	0.016	2.455	76.000
[5]	{herbs}	{whole milk}	0.008	0.475	0.016	1.859	76.000
[6]	{processed cheese}	{whole milk}	0.007	0.423	0.017	1.657	69.000
[7]	{semi-finished bread}	{whole milk}	0.007	0.402	0.018	1.574	70.000
[8]	{beverages}	{whole milk}	0.007	0.262	0.026	1.024	67.000
[9]	{detergent}	{other vegetables}	0.006	0.333	0.019	1.723	63.000
[10]	{detergent}	{whole milk}	0.009	0.466	0.019	1.822	88.000

Showing 1 to 10 of 446 entries Previous 1 2 3 4 5 … 45 Next

Команды Apriori для анализа

ТУСУР
TUSUR UNIVERSITY

Команда на языке R

```
inspect(sort(groceryrules, by = "lift")[1:5])
```



Результат выполнения команды

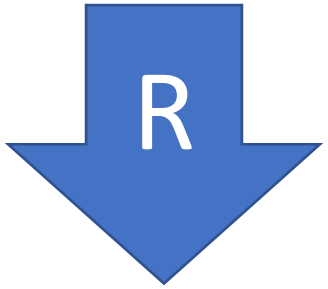
```
    lhs                                                rhs                    support     confidence coverage   lift
[1] {herbs}                                         => {root vegetables}     0.007015760 0.4312500  0.01626843 3.956477
[2] {berries}                                       => {whipped/sour cream}  0.009049314 0.2721713  0.03324860 3.796886
[3] {other vegetables, tropical fruit, whole milk}  => {root vegetables}     0.007015760 0.4107143  0.01708185 3.768074
[4] {beef, other vegetables}                        => {root vegetables}     0.007930859 0.4020619  0.01972547 3.688692
[5] {other vegetables, tropical fruit}              => {pip fruit}           0.009456024 0.2634561  0.03589222 3.482649
    count
[1] 69
[2] 89
[3] 69
[4] 78
[5] 93
```

Команды Apriori для анализа

ТУСУР
TUSUR UNIVERSITY

Команда на языке R

```
berryrules <- subset(groceryrules, items %in% "berries")
inspect(berryrules)
```



Результат выполнения команды

```
    lhs           rhs                    support     confidence coverage  lift     count
[1] {berries} => {whipped/sour cream} 0.009049314 0.2721713  0.0332486 3.796886  89
[2] {berries} => {yogurt}             0.010574479 0.3180428  0.0332486 2.279848 104
[3] {berries} => {other vegetables}   0.010269446 0.3088685  0.0332486 1.596280 101
[4] {berries} => {whole milk}         0.011794611 0.3547401  0.0332486 1.388328 116
```

Команды Apriori для анализа

ТУСУР
TUSUR UNIVERSITY

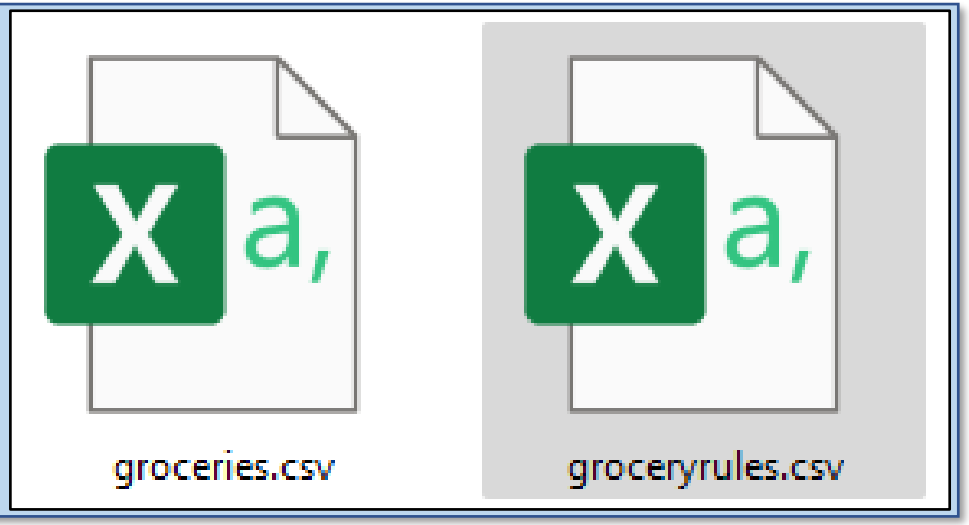
Команда на языке R

```
write(groceryrules, file = "groceryrules.csv",
      sep = ",", quote = TRUE, row.names = FALSE)
```

R

Результат выполнения команды

В результате будет создан файл с именем groceryrules.csv, содержащий данные правил, выбранные нами.



Команды Apriori для анализа

ТУСУР
TUSUR UNIVERSITY

Команда на языке R

```
groceryrules_df <- as(groceryrules, "data.frame")
str(groceryrules_df)
```



Результат выполнения команды

```
'data.frame':   463 obs. of  6 variables:
 $ rules     : chr  "{potted plants} => {whole milk}" "{pasta} => {whole milk}" "{herbs} => {root vegetables}" "{herbs} =>
 {other vegetables}" ...
 $ support   : num  0.00691 0.0061 0.00702 0.00773 0.00773 ...
 $ confidence: num  0.4 0.405 0.431 0.475 0.475 ...
 $ coverage  : num  0.0173 0.015 0.0163 0.0163 0.0163 ...
 $ lift      : num  1.57 1.59 3.96 2.45 1.86 ...
 $ count     : int  68 60 69 76 76 69 70 67 63 88 ...
```

TYCYP
TUSUR UNIVERSITY