ТУСУР
TUSUR UNIVERSITY

Тема 3.3. Аутентификация по голосу

Задачи обработки аудио. Извлечение признаков из аудиосигналов. Методы предварительной обработки аудиосигналов. Аугментация аудиосигналов. Методы распознавания образов в аудиосигналах. Сравнение с методами классификации изображений.

Задачи обработки аудио

ТУСУР
TUSUR UNIVERSITY

- Речь
- Музыка
- Звуки

Задачи обработки речи

ТУСУР
TUSUR UNIVERSITY

– Состояние диктора: эмоции, интоксикация, сонливость, правдивость, …

– Характеристики диктора: возраст, пол, рост, вес, привлекательность, …

– Идентификация диктора

– Тональность высказывания

– Распознавание речи

– Нелингвистические вокализации: кашель, смех, вздох, …

– Распознавание языка

– Нарушения речи

– Диалекты, социолект

– Окружение, микрофон, кодировка, канал передачи, …

Области применения (речь)

ТУСУР
TUSUR UNIVERSITY

- Взаимодействие человек-машина:
  - Интерпретация намерений пользователя
  - Адаптация диалога
- Извлечение данных:
  - Выделение ключевых моментов, специфических частей, …
  - Анализ собраний/встреч
- Мониторинг:
  - Оценка сонливости/интоксикации на производстве/в автомобиле
  - Оценка здоровья
  - Антитеррористический мониторинг/вандализм
  - Мониторинг клиентской заинтересованности

Музыка

ТУСУР
TUSUR UNIVERSITY

– Темп, метр
– Тональность
– Мелодия
– Структура
– Нотная запись
– Жанр
– Настроение
– Аранжировка
– Лирика

Области применения (музыка)

ТУСУР
TUSUR UNIVERSITY

- Взаимодействие с пользователем
  - Поиск по мотиву, музыкальные игры
  - Перемещение по структуре песни
  - Музыкальные рекомендательные системы
- Редактирование музыки
  - Изоляция инструментов
  - Автоматическое добавление/удаление
  - Автоматическая транскрипция

Звуки

ТУСУР
TUSUR UNIVERSITY

Анализ звуков:

– Структура
– Источник
– Состояние источника звука
– Характеристики источника звука

Области применения (звуки)

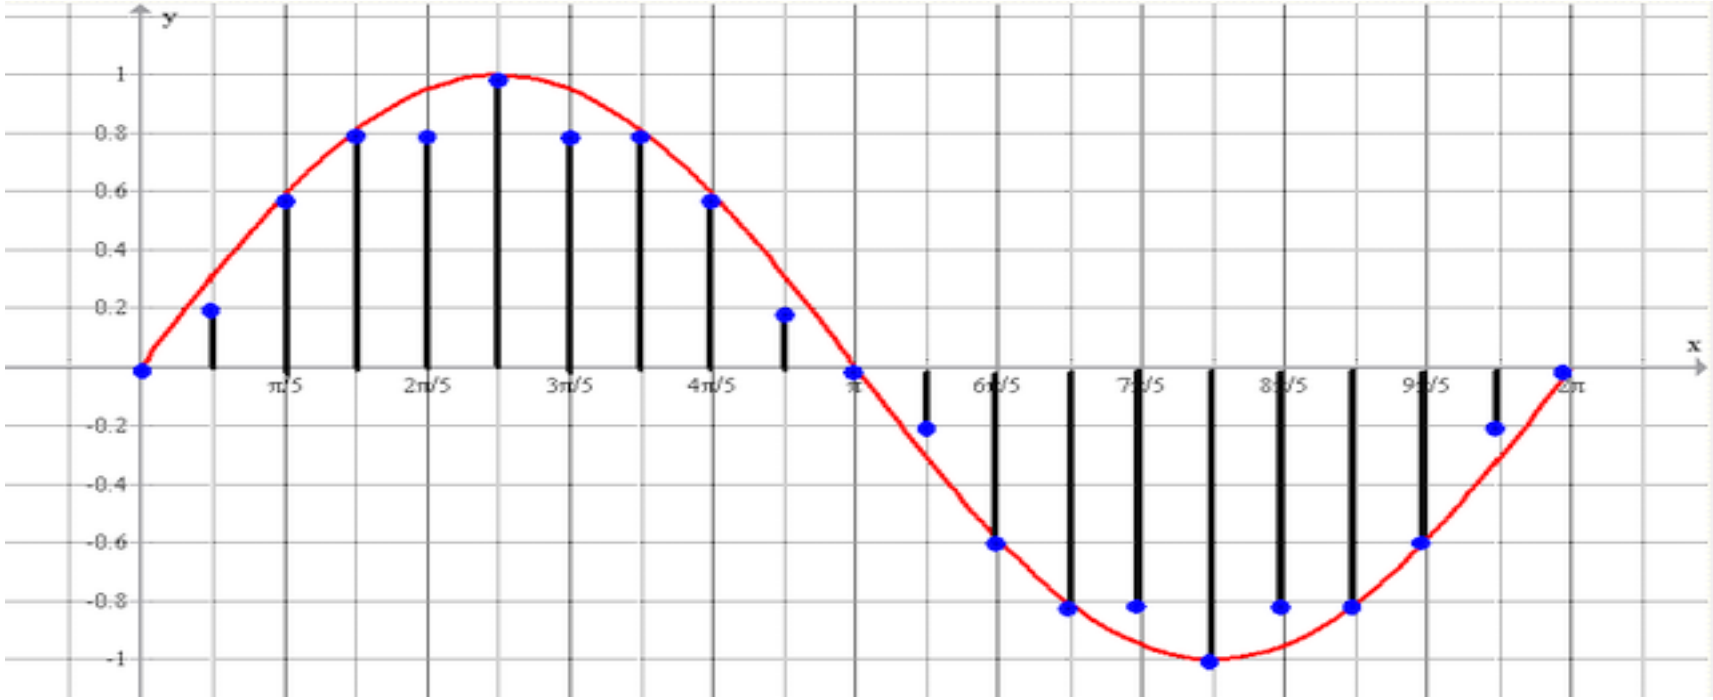
ТУСУР
TUSUR UNIVERSITY

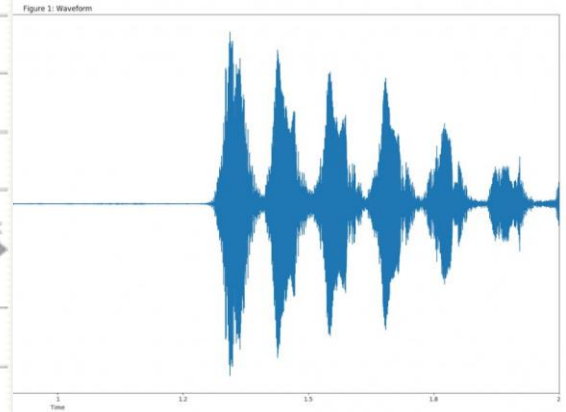
- Извлечение данных
  - Семантическая разметка аудио
- Вычислительный интеллект
  - Робототехника
  - Видеоигры
- Наблюдение
  - Контроль состояния оборудования
  - Определение ЧС
  - Террор, вандализм (выстрелы, …)

Как хранится аудиофайл?

ТУСУР
TUSUR UNIVERSITY

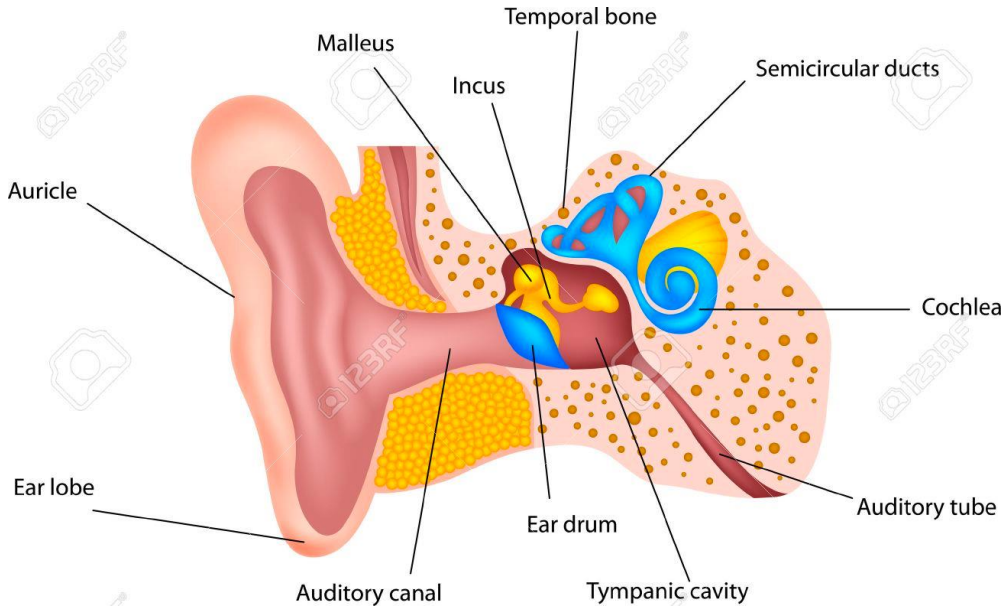
sample rate — число отсчетов в секунду. Типичные значения: 16000, 22050, 44100

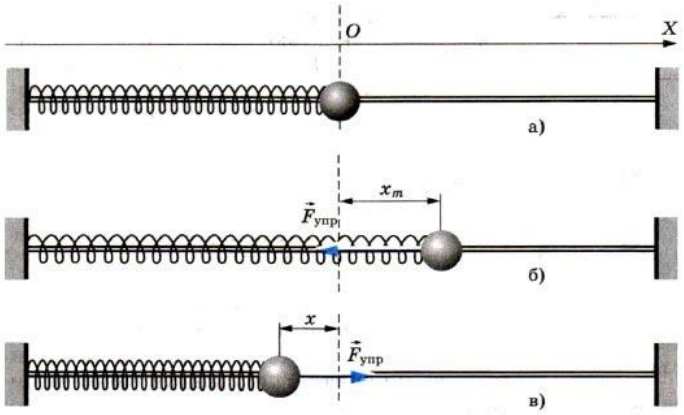


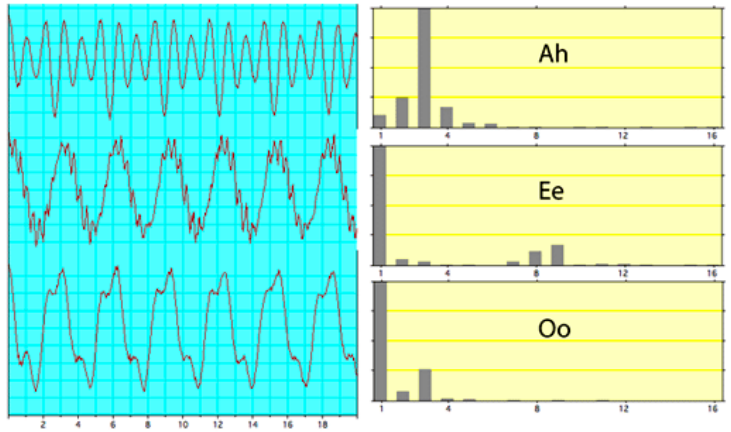


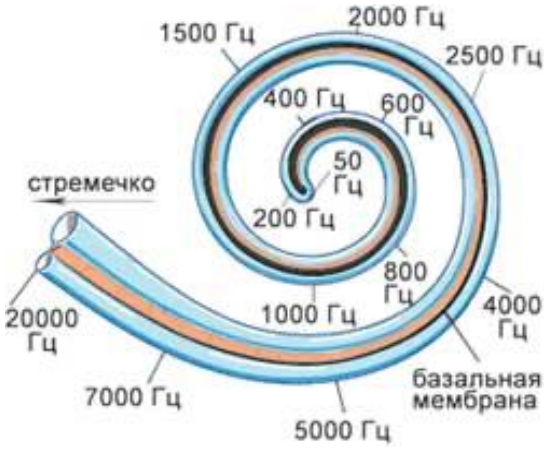
Человеческое ухо

- Улитка == много резонаторов
- В улитке есть нервы, идущие к разным нейронам
- Разные места улитки колеблются с разной частотой, зависимой от входного сигнала, передавая сигнал на нервы



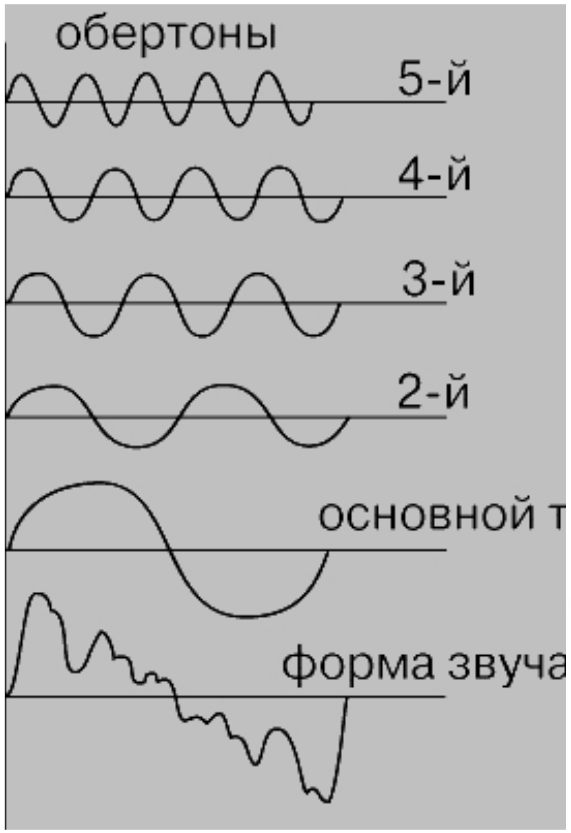




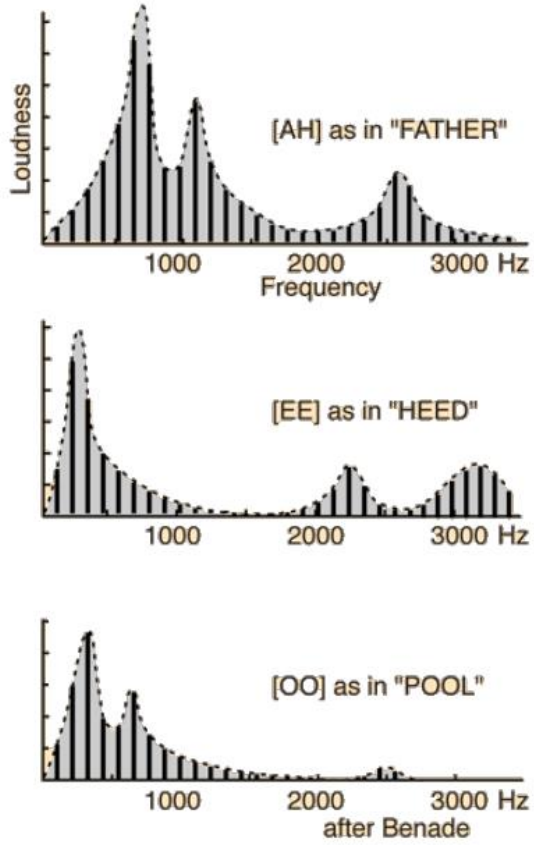


Быстрое преобразование Фурье (FFT)

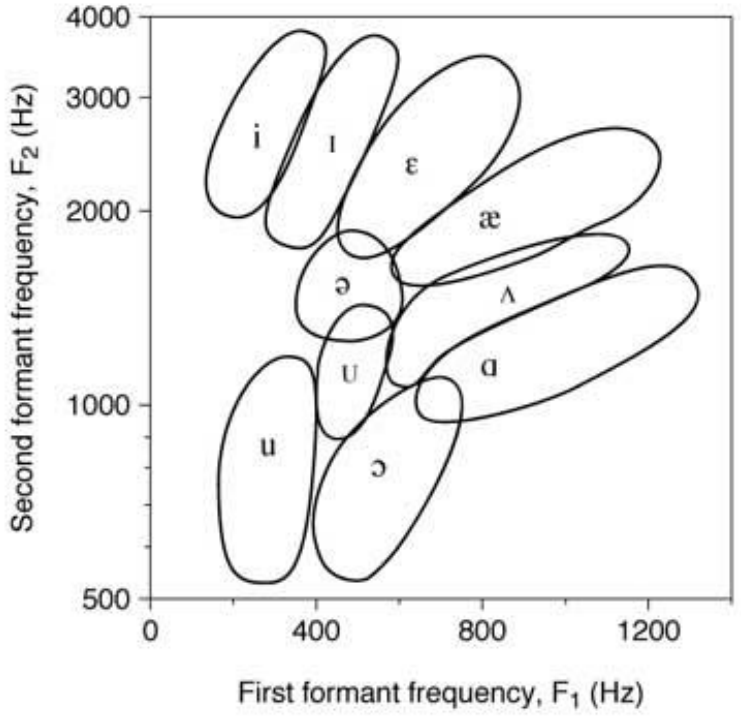
- Частота колебаний связок – основная частота голоса, частота основого тона (60-400 Гц)
- Преобразования голосового тракта обеспечивают обертона
- STFT намного проще понять, чем исходный звуковой сигнал!

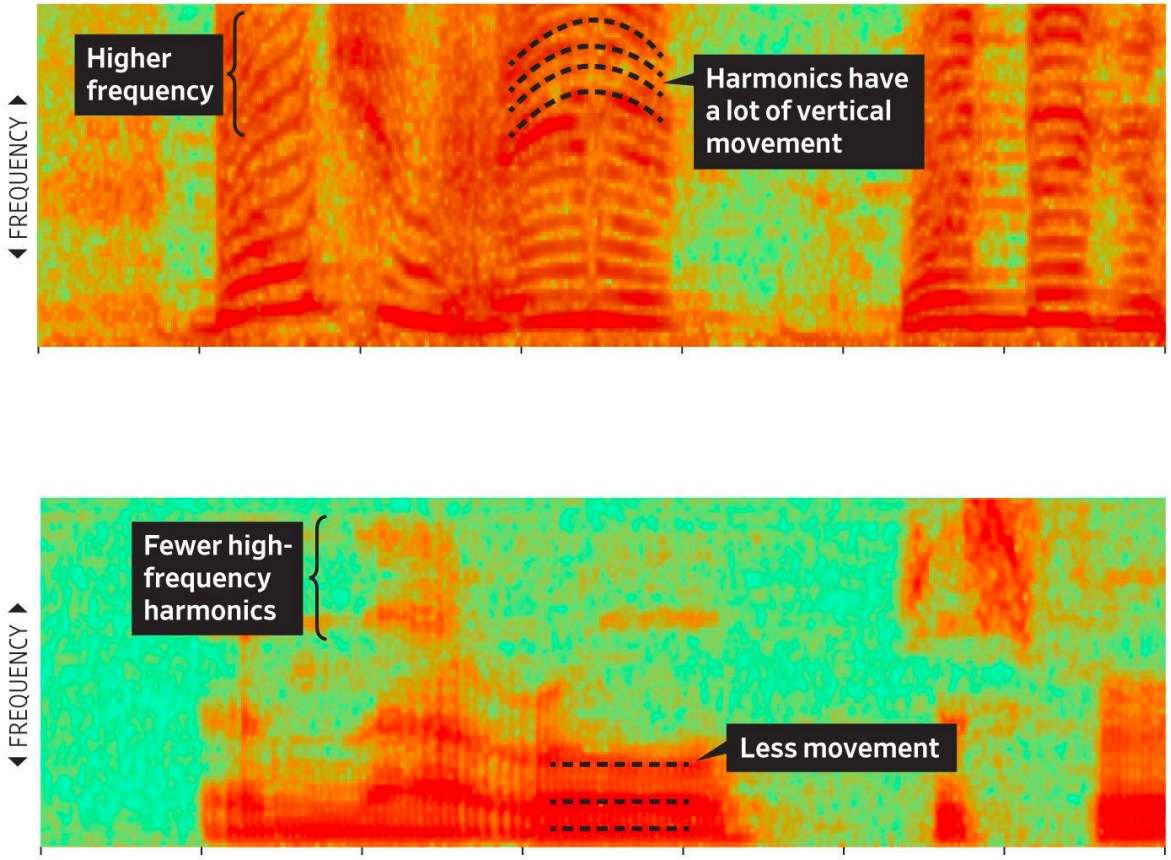






Параметры звука



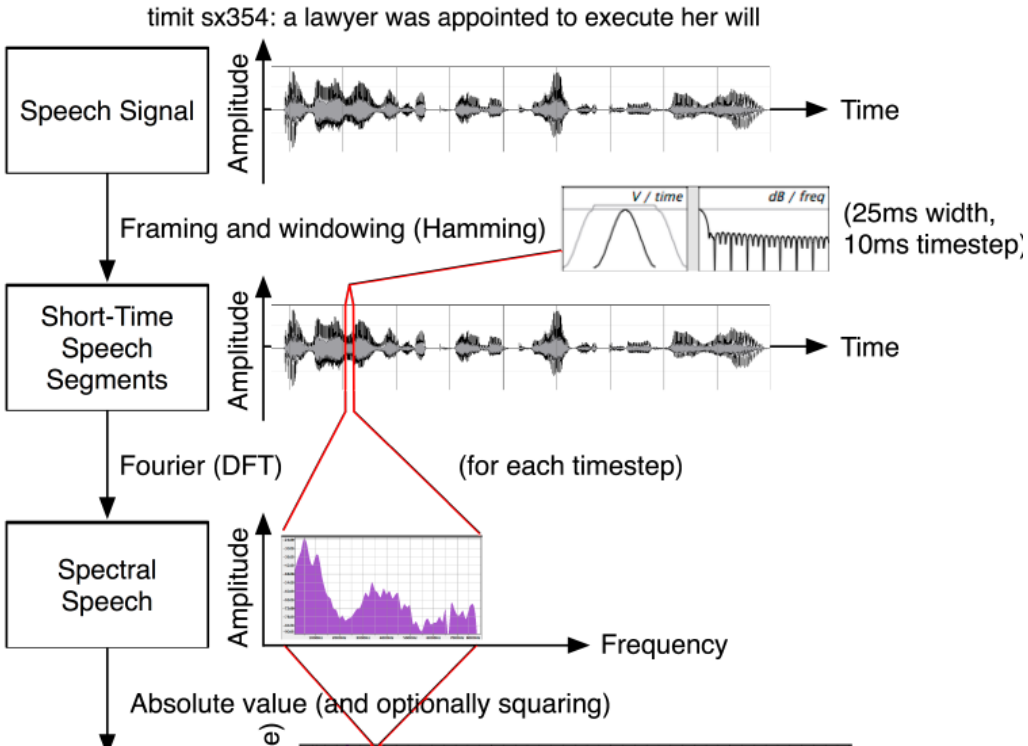


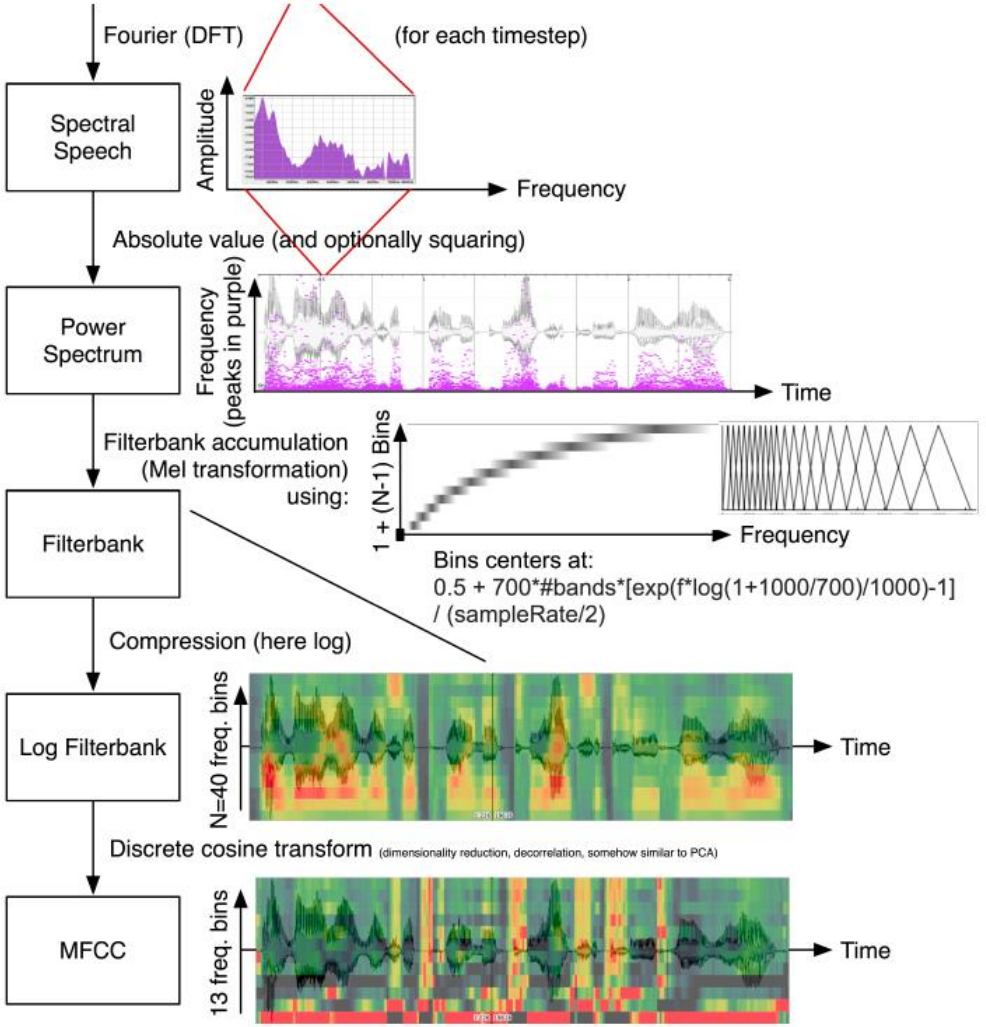
Речевые характеристики

ТУСУР
TUSUR UNIVERSITY

- Мел-кепстральные коэффициенты (MFCC)
- Коэффициенты линейного предсказания (LPC)
- Частота основного тона
- Формантные частоты
- Частота пересечения нуля
- …
- Высокоуровневые признаки (Эмбеддинги)

Предобработка речи





Разбиение на фреймы

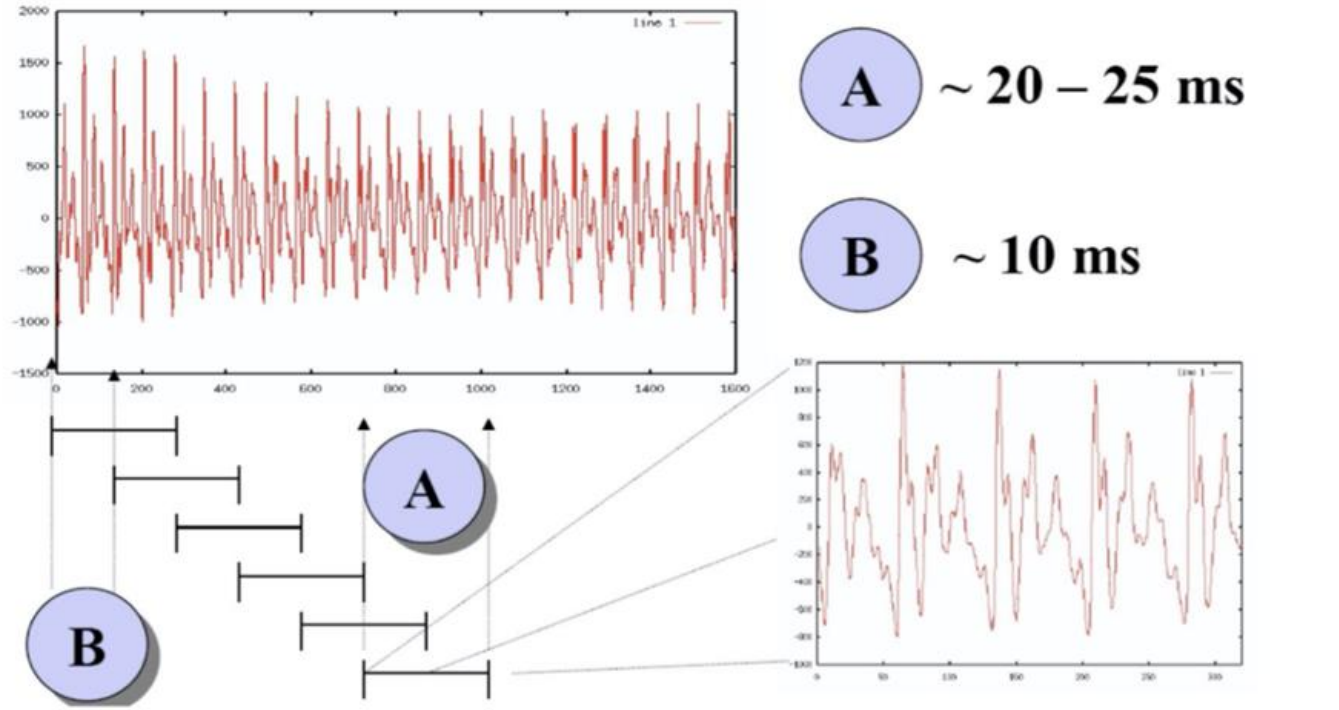


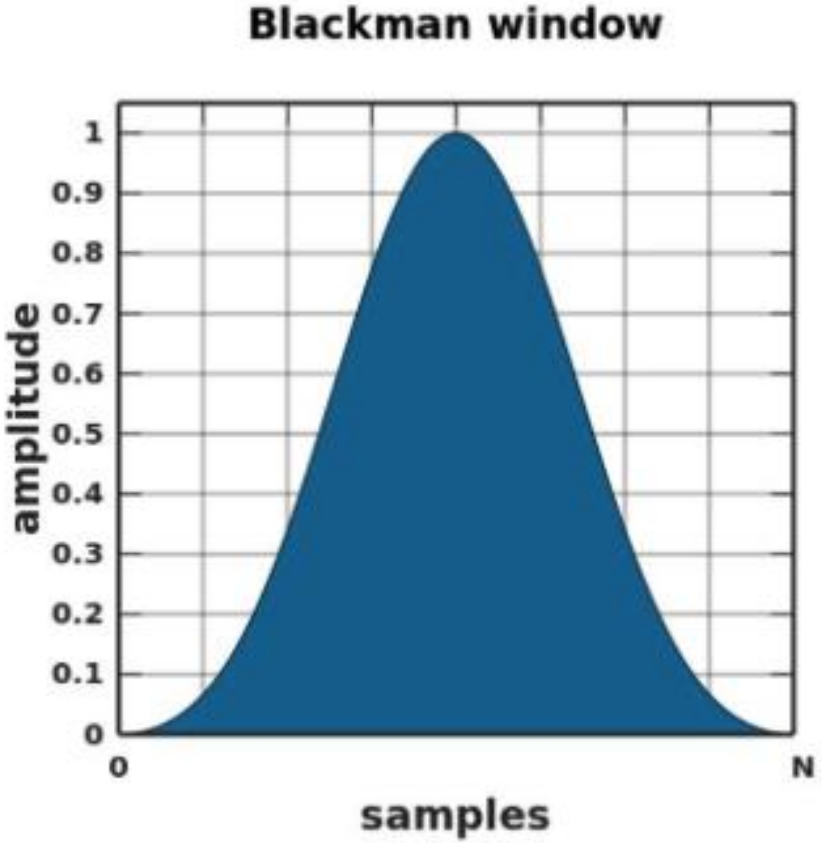
Image from Bryan Pellom

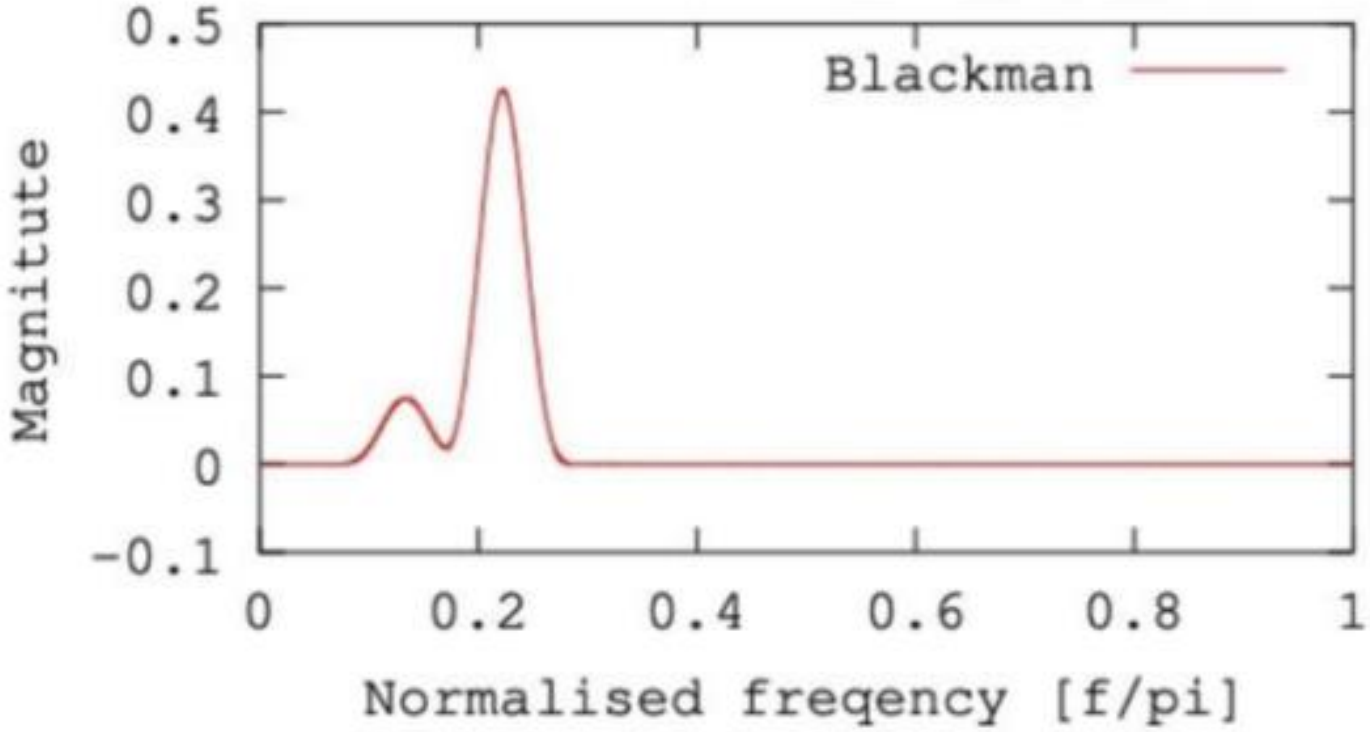
https://medium.com/@jonathan_hui/speech-recognition-feature-extraction-mfcc-plp-5455f5a69dd9

Оконная функция

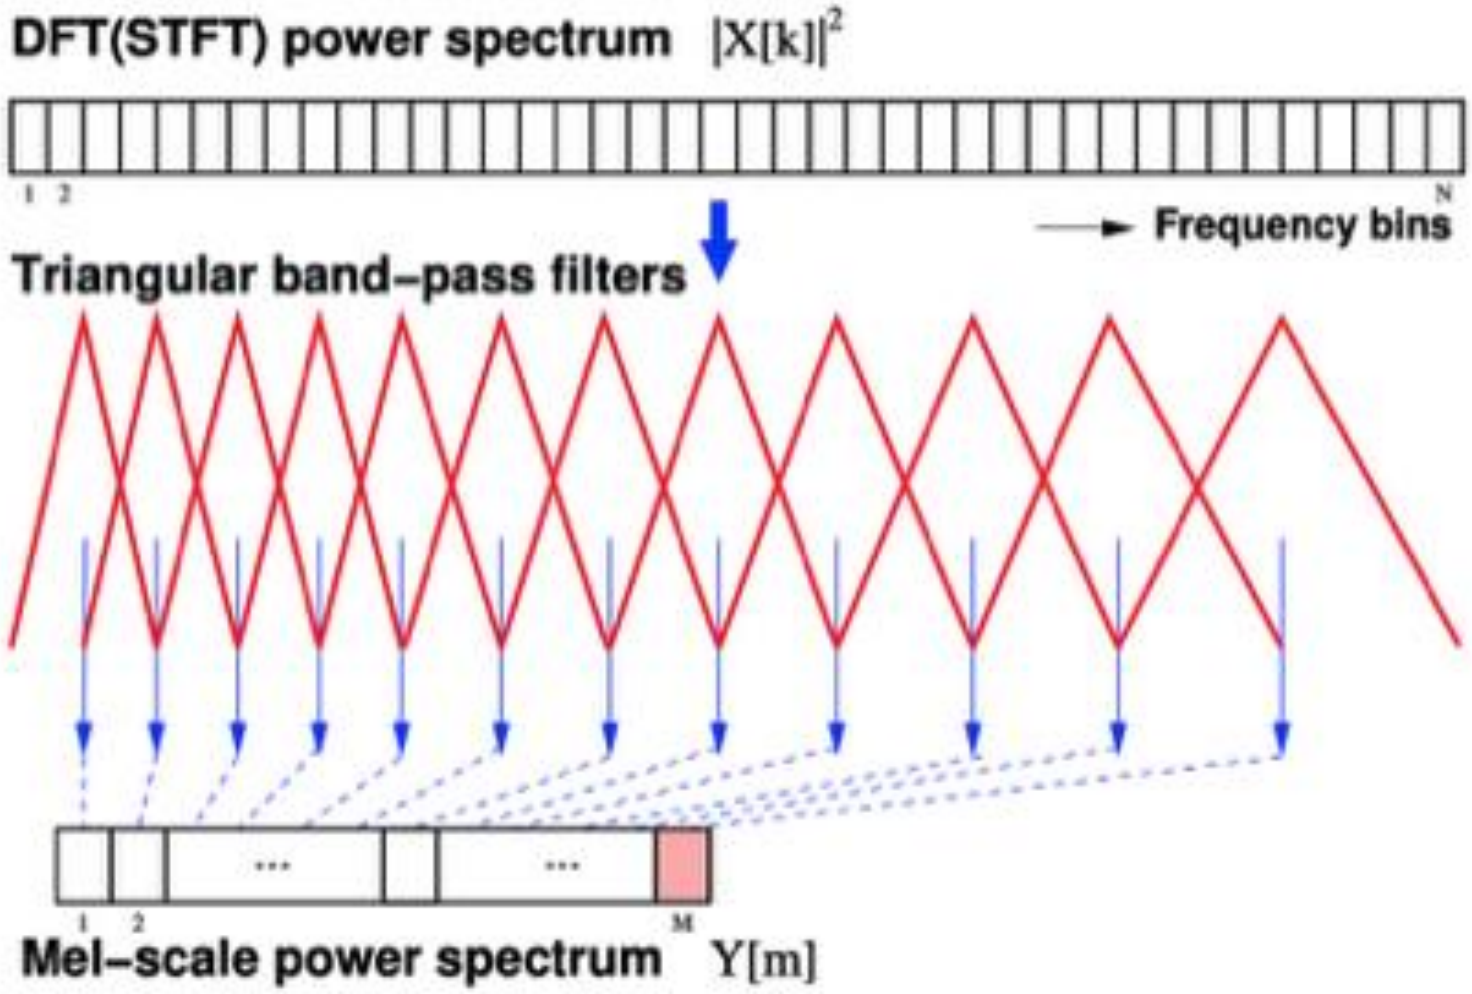
ТУСУР
TUSUR UNIVERSITY

Windowing (with smoothing)



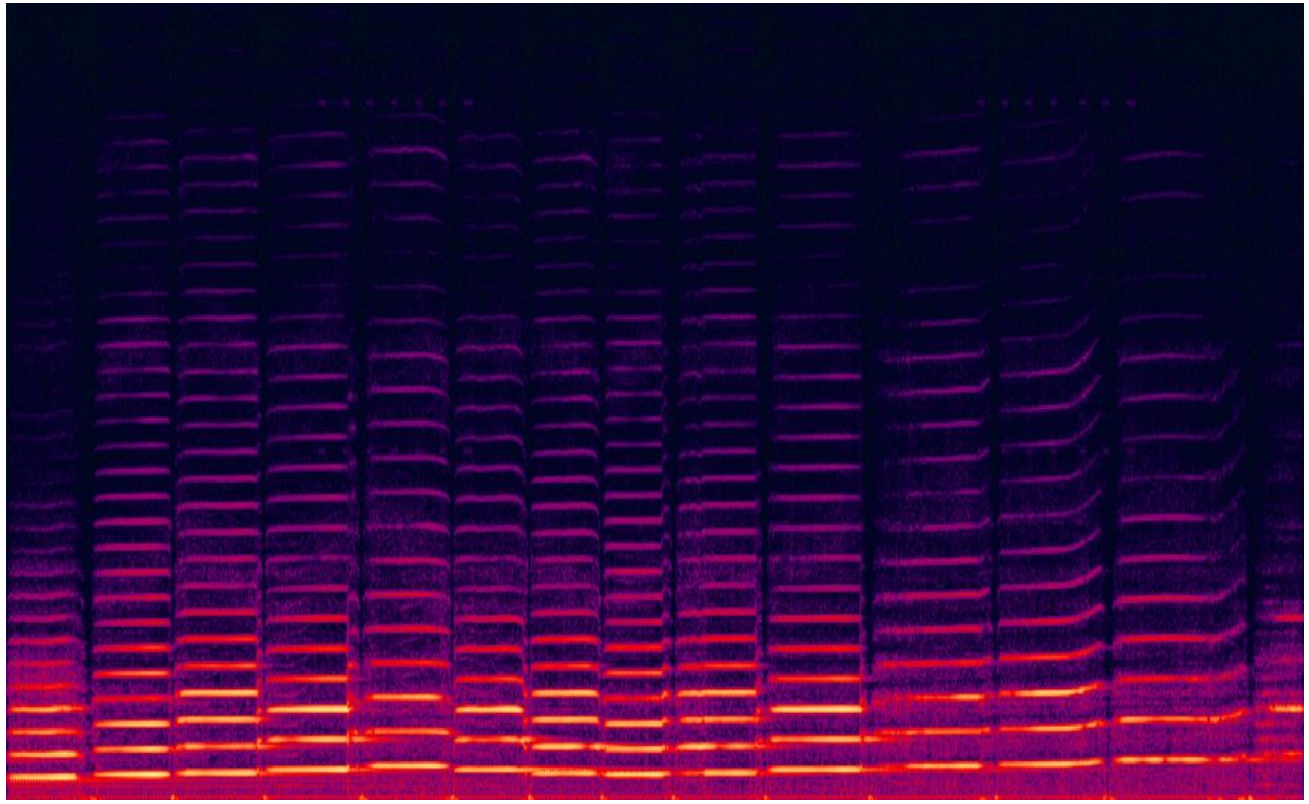


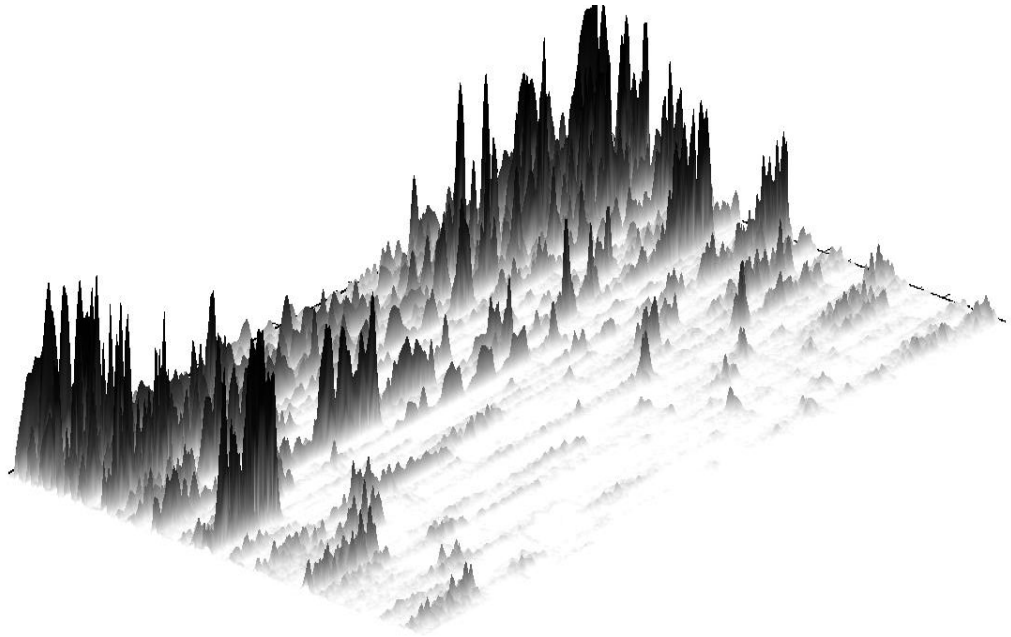
Мел-кепстральные коэффициенты



Мел-кепстральные коэффициенты

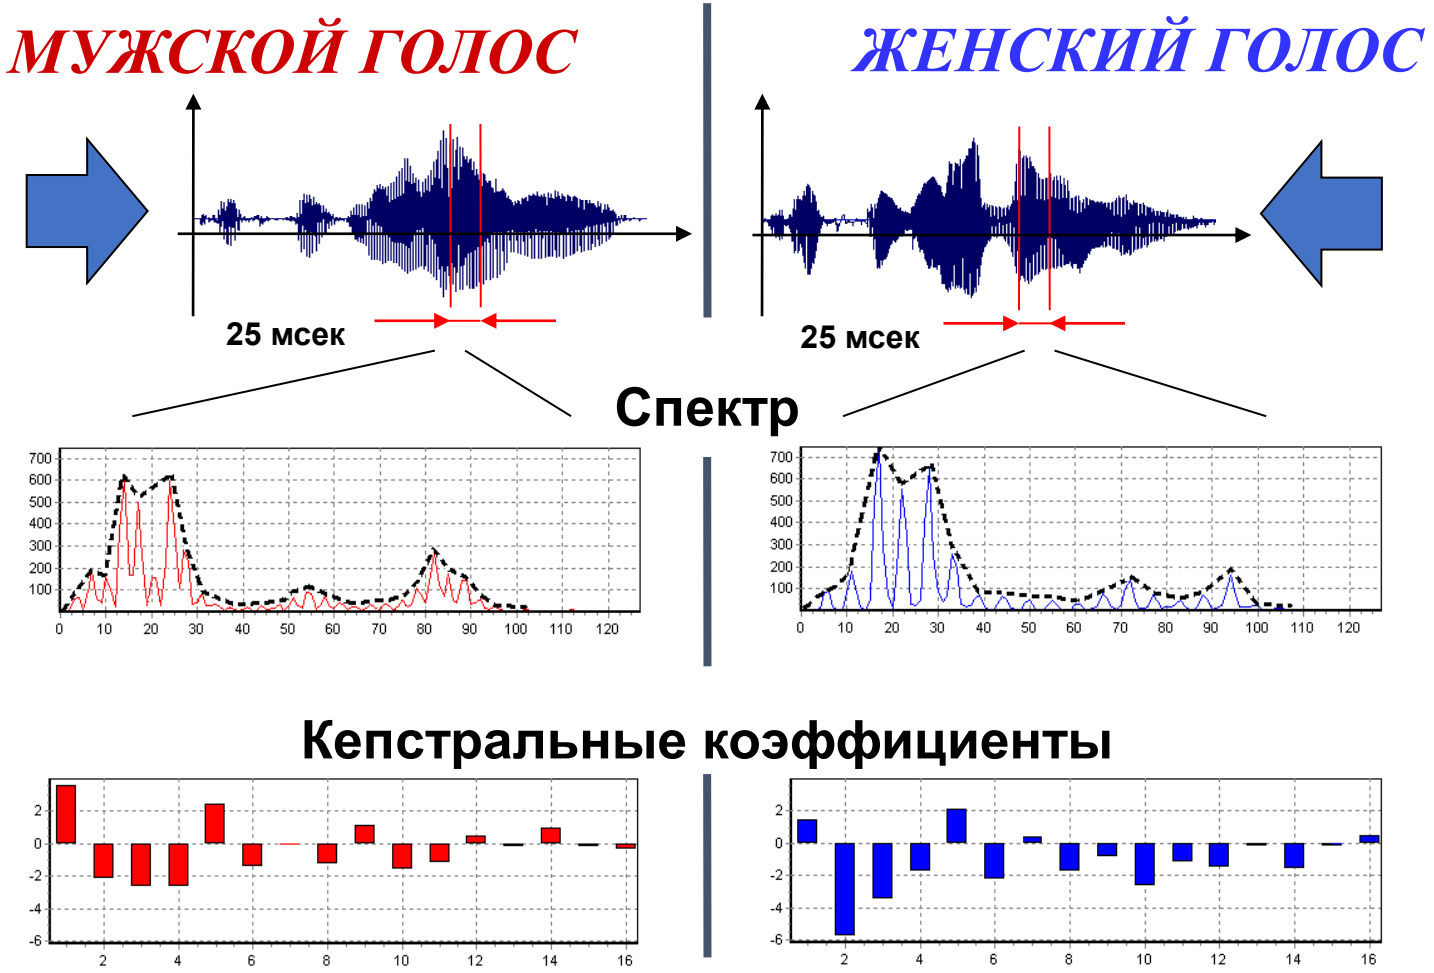
ТУСУР
TUSUR UNIVERSITY





Мел-кепстральные коэффициенты

ТУСУР
TUSUR UNIVERSITY



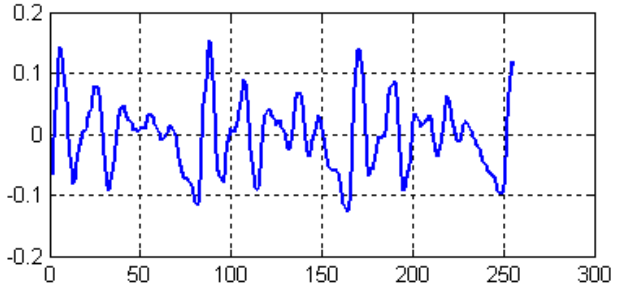
Коэффициенты линейного предсказания

$$s(n) = -\sum_{i=1}^{N_{LP}} a_{LP}(i) \cdot s(n-i) + e(n) \qquad (1)$$

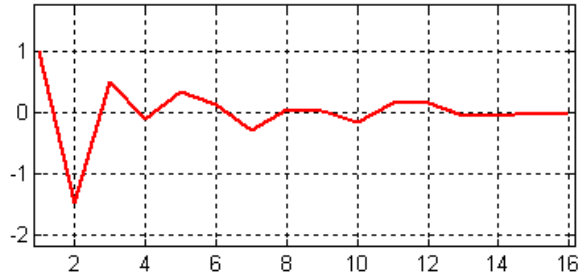
где N_{LP} - количество коэффициентов модели (порядок предсказания); *s(n)* – анализируемый сигнал;

a_{LP} - коэффициенты линейного предсказания; $e(n)$ - функция ошибки модели

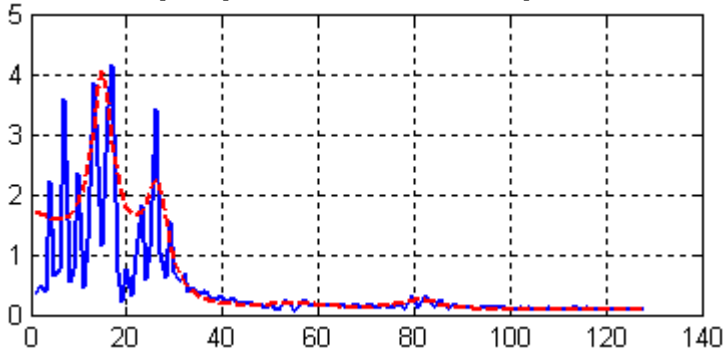
Речевой сигнал звука [a]



КЛП (порядок = 15)

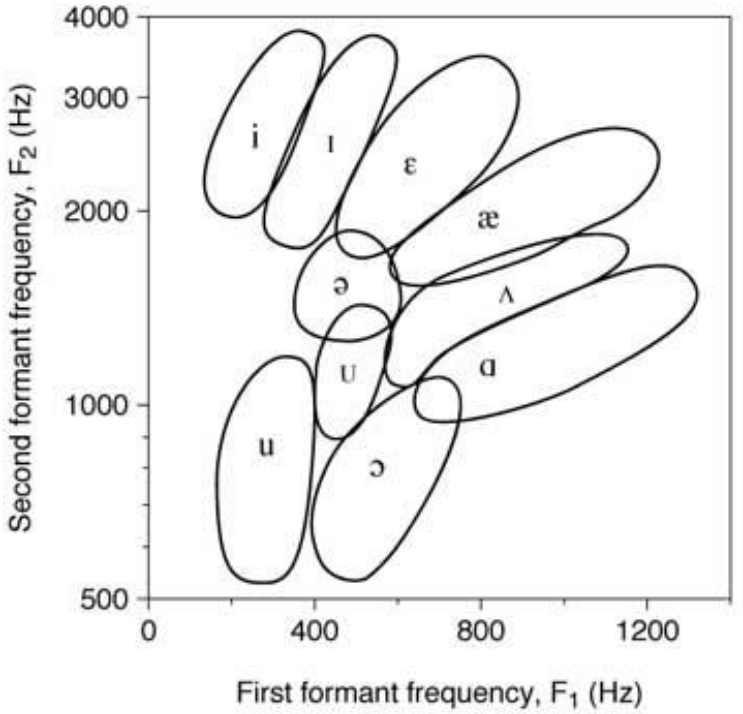


Спектр речевого сигнала, инвертированный спектр КЛП



Форманты

- Пики в спектре речевого сигнала называют формантами
- F1-F3: фонетический контекст
- F4-F7: характеристики диктора
- Описываются: позицией (центральная частота), амплитудой, шириной



Wav2vec

TUSUR UNIVERSITY

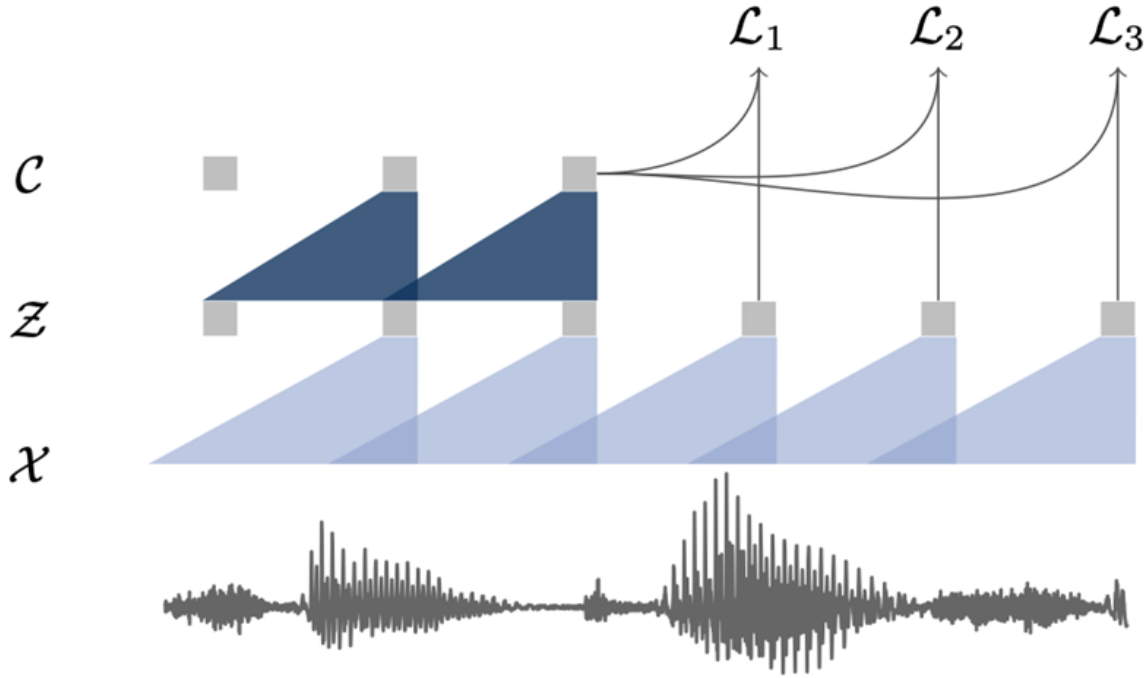


Figure 1: Illustration of pre-training from audio data $\mathcal{X}$ which is encoded with two convolutional neural networks that are stacked on top of each other. The model is optimized to solve a next time step prediction task.

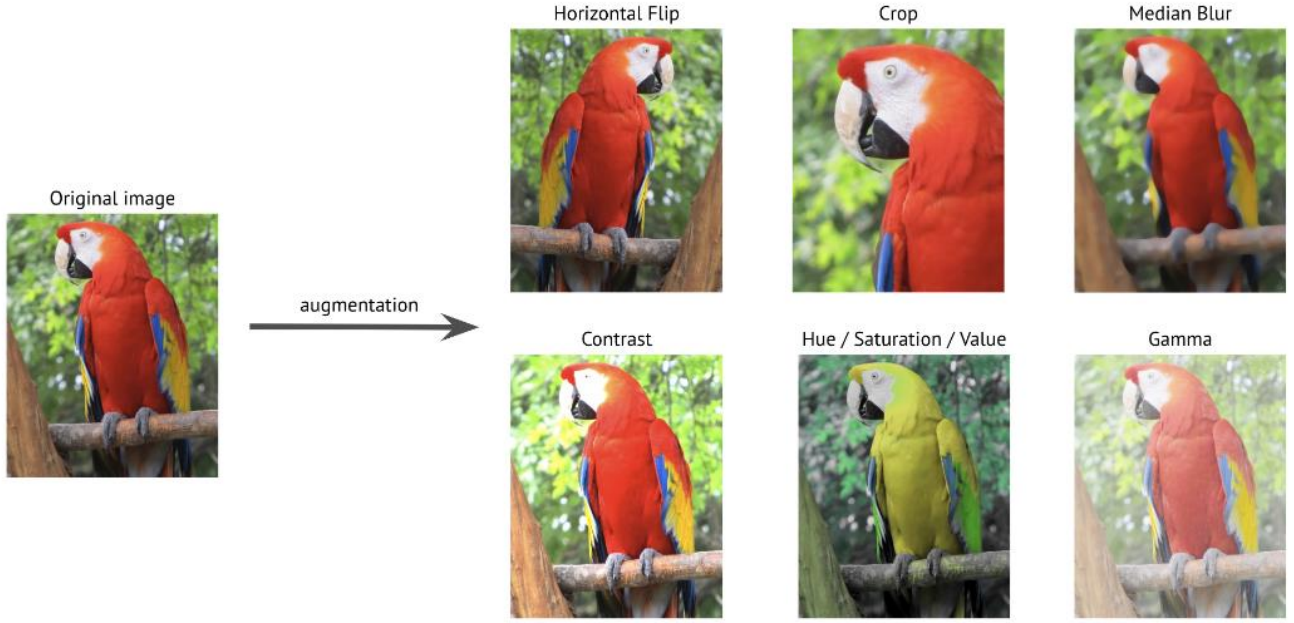
Аугментация данных

ТУСУР
TUSUR UNIVERSITY

- Проблема отсутствия большого количества данных
- Методы аугментации данных позволяют генерировать **новые образцы данных из уже имеющихся**
- Аугментации применяют только во время обучения нейросетей
- Аугментация при помощи генерации данных
- Аугментации должны соответствовать реальным примерам

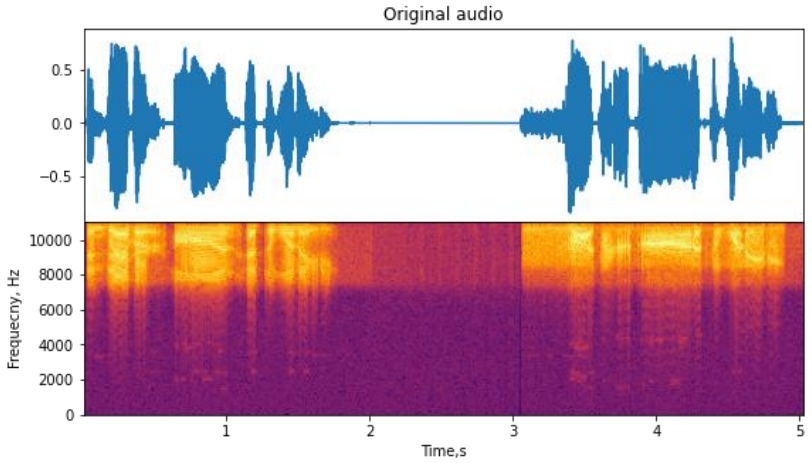
Аугментация данных (изображения)

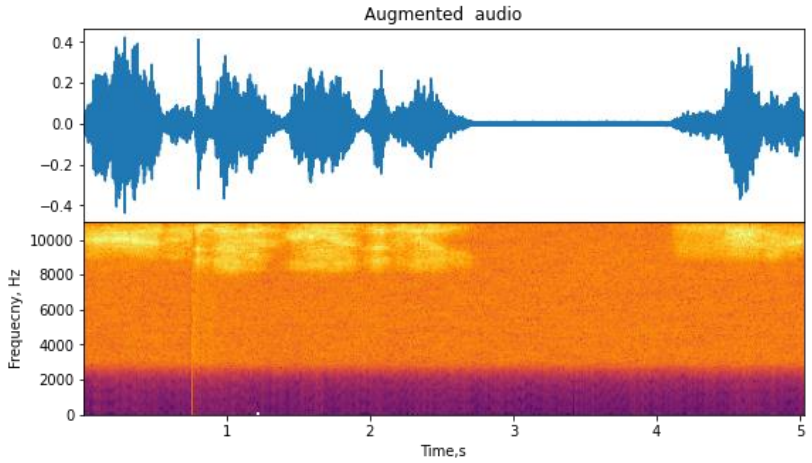
- Геометрические (афинные, проективные, ...).
- Яркостные/цветовые
- Замена фона
- Искажения, характерные для решаемой задачи: блики, шумы, размытие и т. д.
- Добавление/удаление объектов с изображения
- Генерация данных (GAN)



Аугментация данных (аудио)

- Добавление фоновых шумов
  - Реалистичные фоновый шум (шум улицы, офисный шум)
  - Белый шум(цветные шумы)
  - Громкие звуки (дрель, сигнал автомобиля, стук, …)
- Ускорение/замедление аудио (Time Stretch)
- Изменение высоты тона (Pitch Shift)
- Добавление реверберации





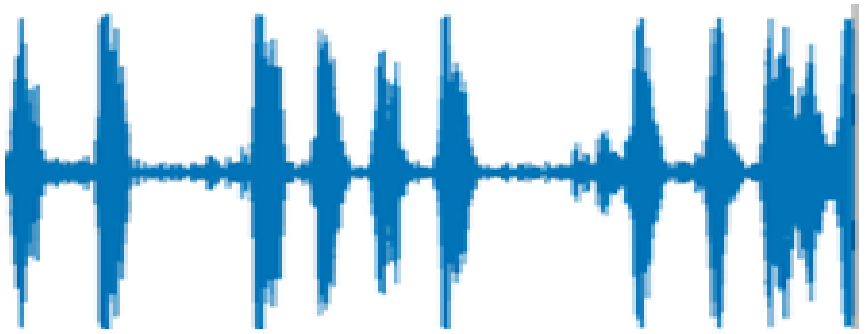
Изображения vs Аудио

ТУСУР
TUSUR UNIVERSITY

1. 2d (чб)
2. 256x256 ~ 65k pix

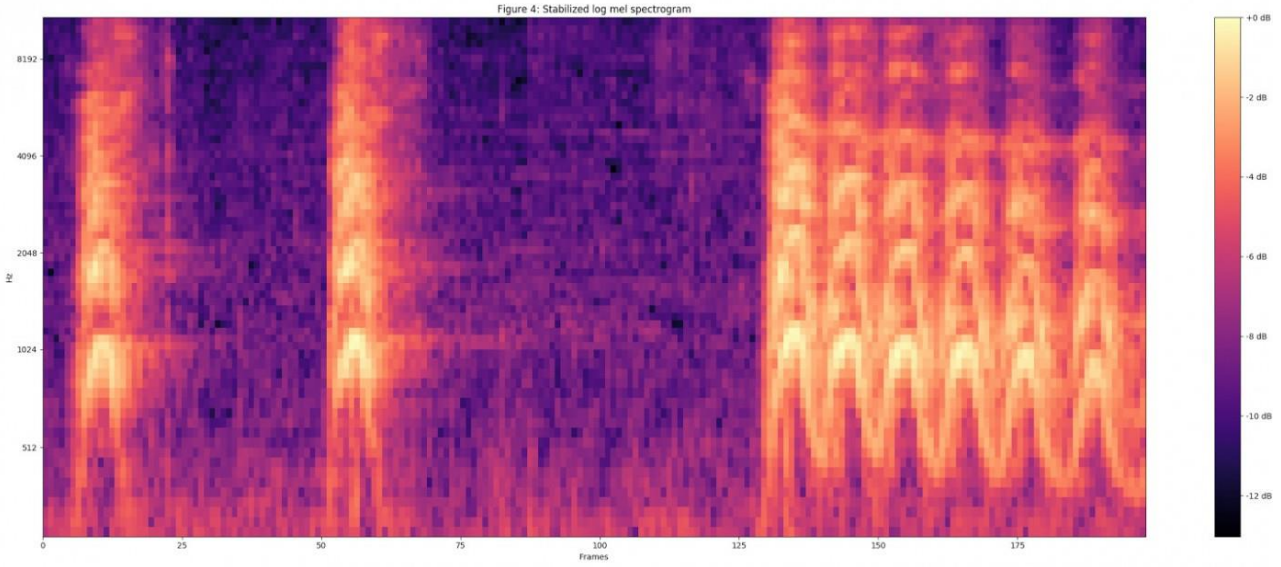


1. 1d (mono)
2. 1 sec ~ 44100



Классификация аудиоданных

ТУСУР
TUSUR UNIVERSITY



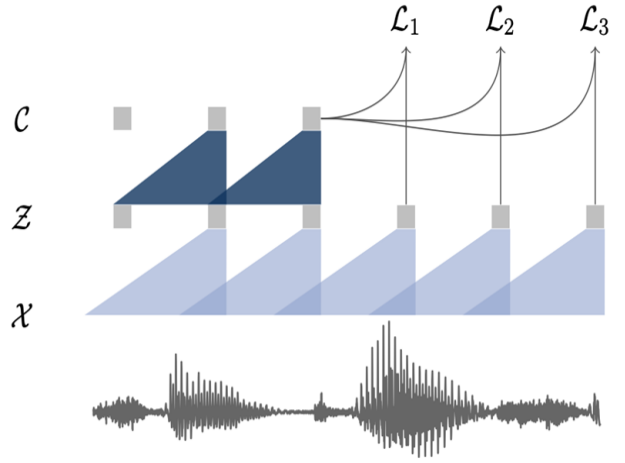


Figure 1: Illustration of pre-training from audio data $\mathcal{X}$ which is encoded with two convolutional neural networks that are stacked on top of each other. The model is optimized to solve a next time step prediction task.

Проблема размерности аудио

ТУСУР
TUSUR UNIVERSITY

Длительность аудио не фиксирована, в отличие от изображений.

Решение:

- Использование Pooling слоя

$$\mathcal{P}_{\text{tap}}(\mathbf{X}) = \frac{1}{T}\sum_{t=1}^{T}\mathbf{x}_t \quad (2)$$

- Statistics Pooling

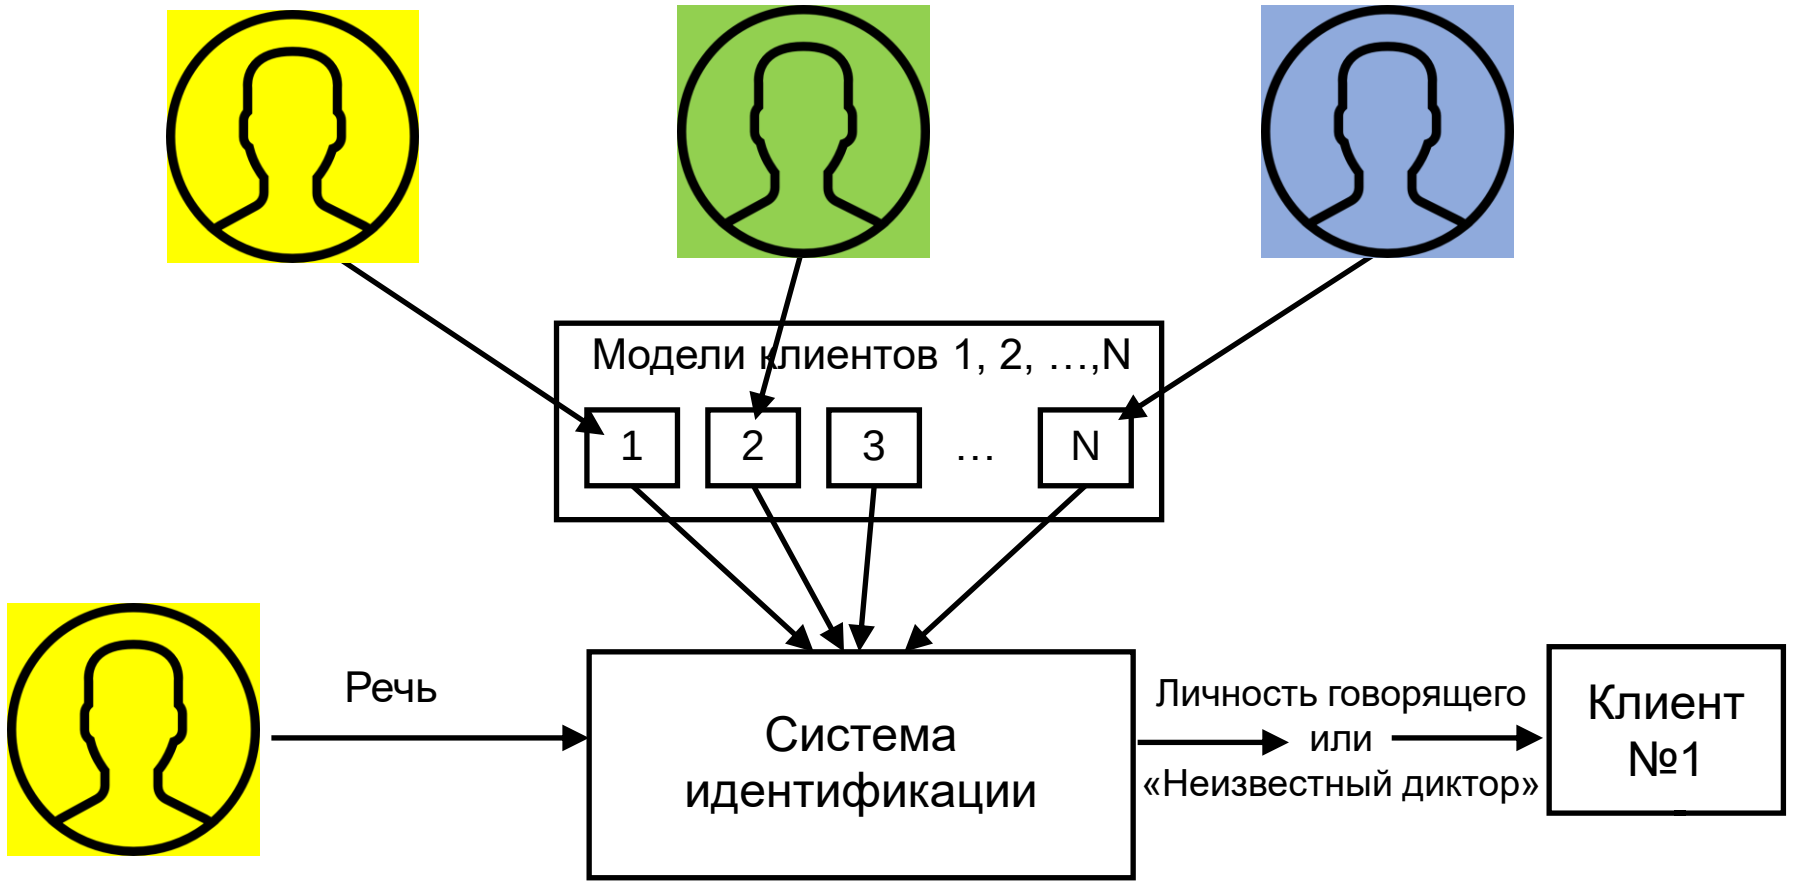
$$\mathcal{P}_{\text{tstp}}(\mathbf{X}) = [\boldsymbol{\mu}^\top, \boldsymbol{\sigma}^\top]^\top \quad (3)$$

Голосовая биометрия

ТУСУР
TUSUR UNIVERSITY

- Идентификация
- Верификация
- Диаризация

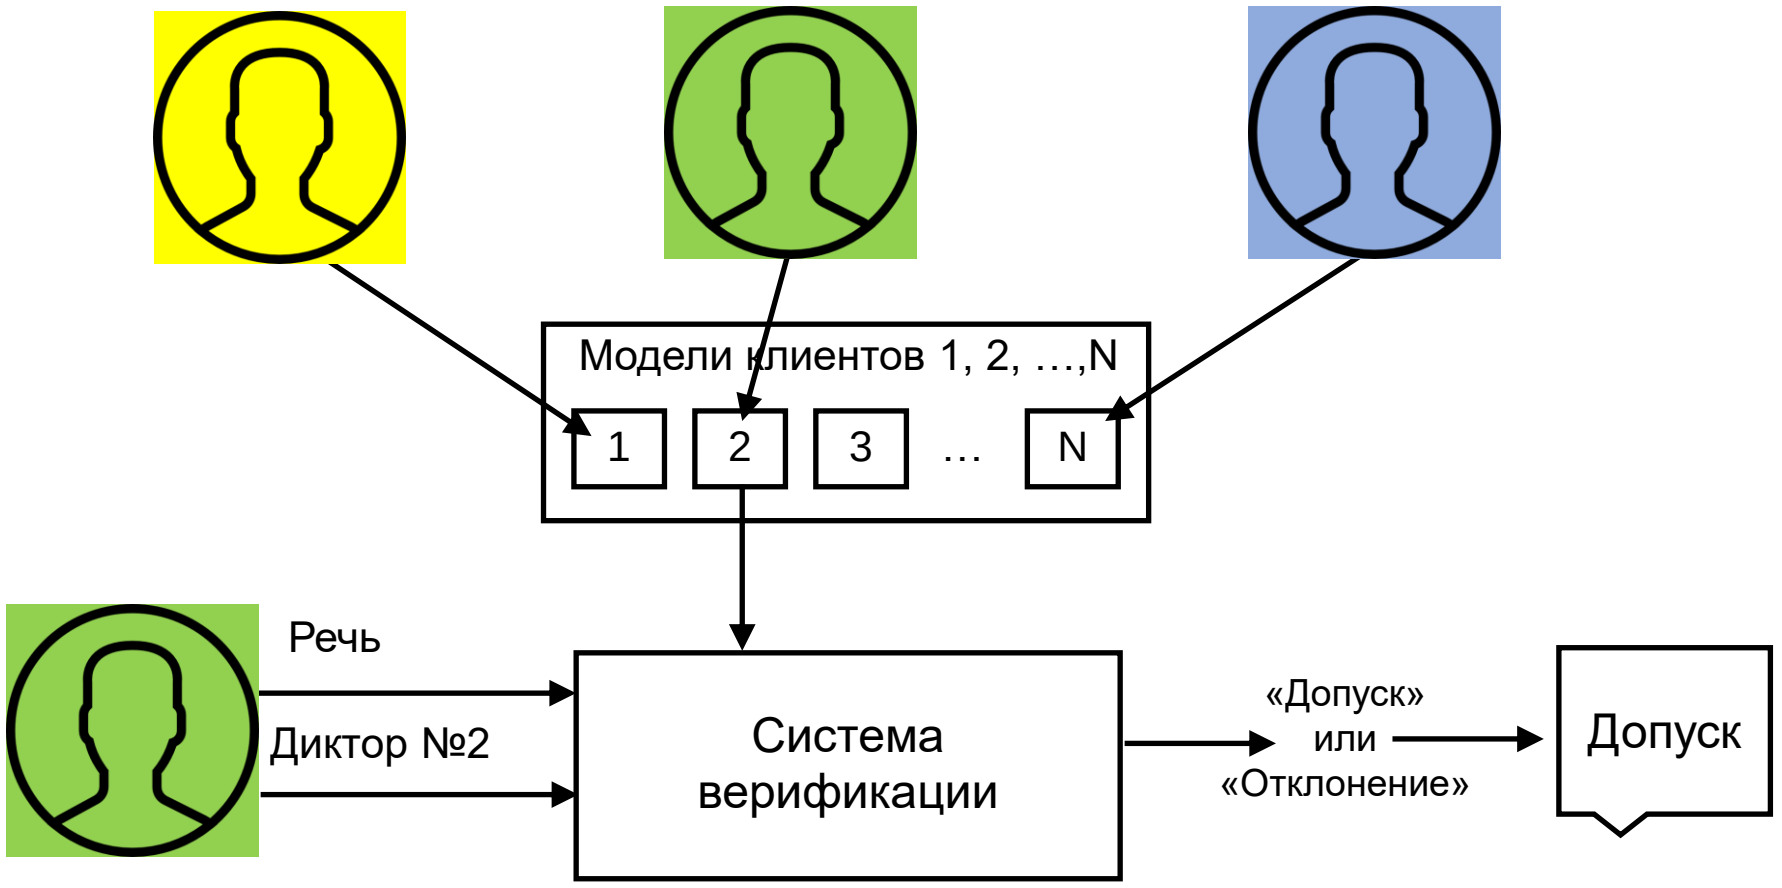
Идентификация



Области применения идентификации

- криминалистическая экспертиза;
- антитеррористические мероприятия;
- контрразведка;
- слежка за определенными категориями граждан;
- идентификация диктора на фонограммах или в реальном времени во время конференций или интервью с несколькими участниками.

Верификация



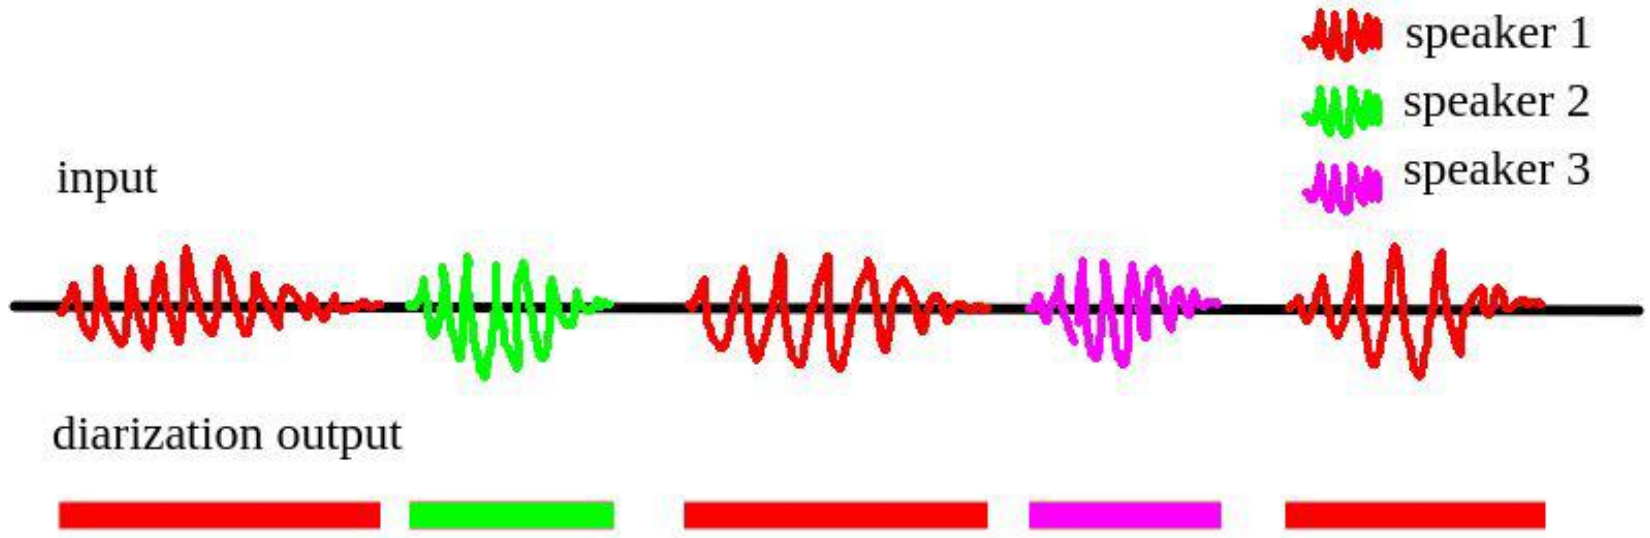
Области применения верификации

- санкционирование распоряжения финансовыми процессами по электронным или телефонным каналам
- разрешение на смену пароля или PIN-кода
- доступ к компьютеру или отдельным программам компьютера
- разрешение на вход в помещение, открывание сейфа
- управление механизмами и системами
- мониторинг того, кто, когда и к каким компьютерным ресурсам имел доступ.

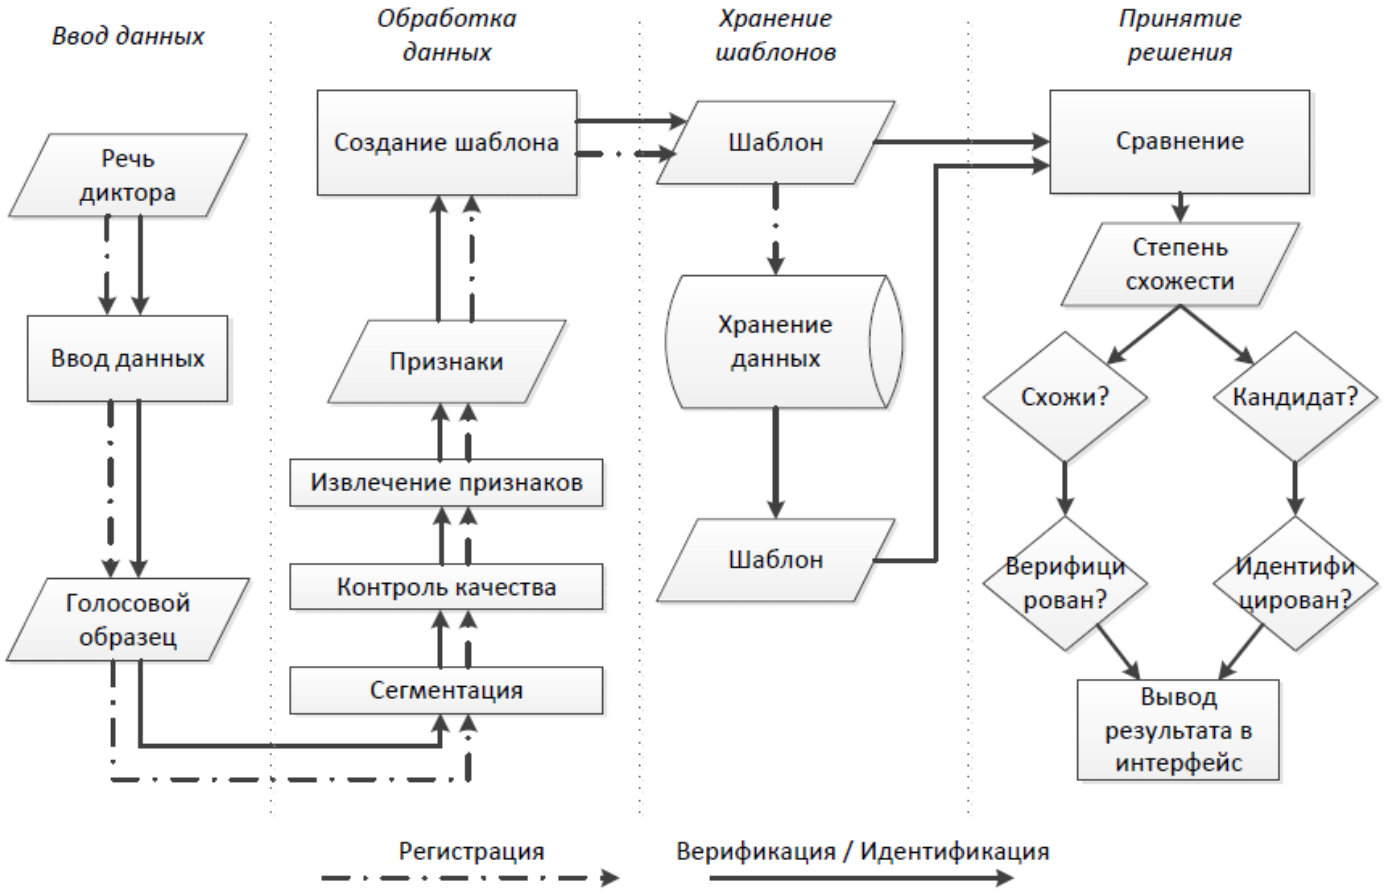
Диаризация

ТУСУР
TUSUR UNIVERSITY

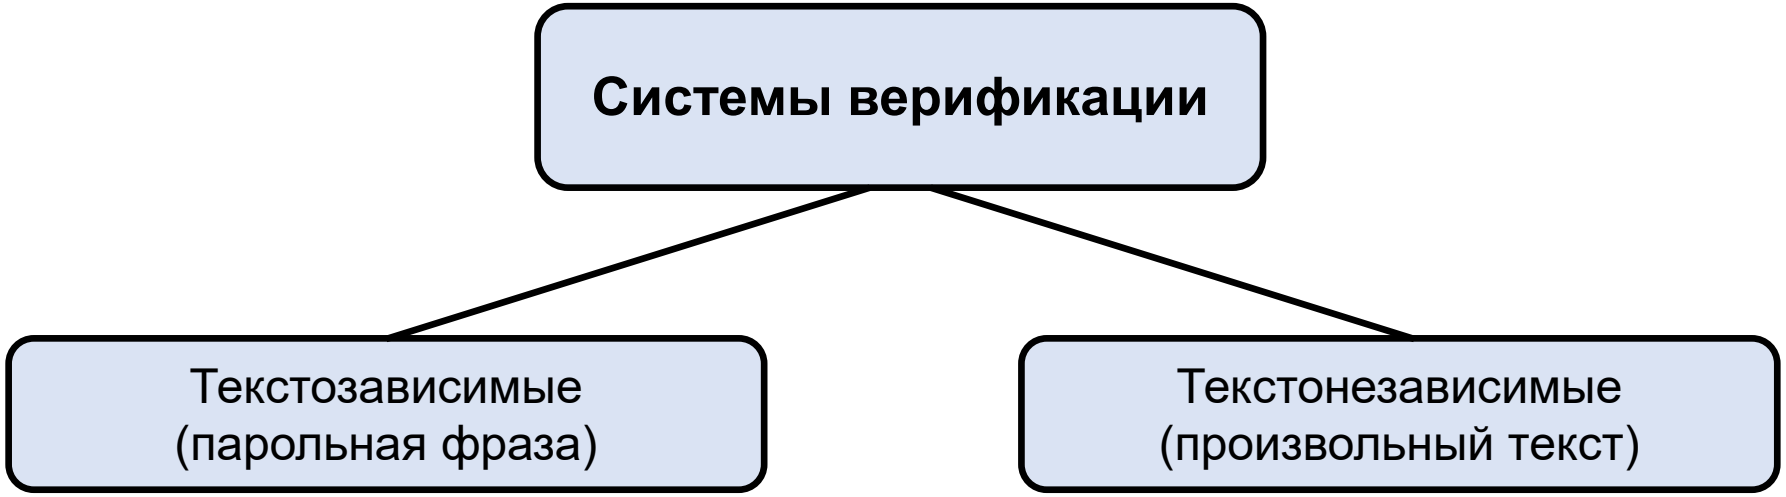
Задача определения кто именно говорит в текущий момент?



Компоненты обобщенной голосовой биометрической системы



Классификация

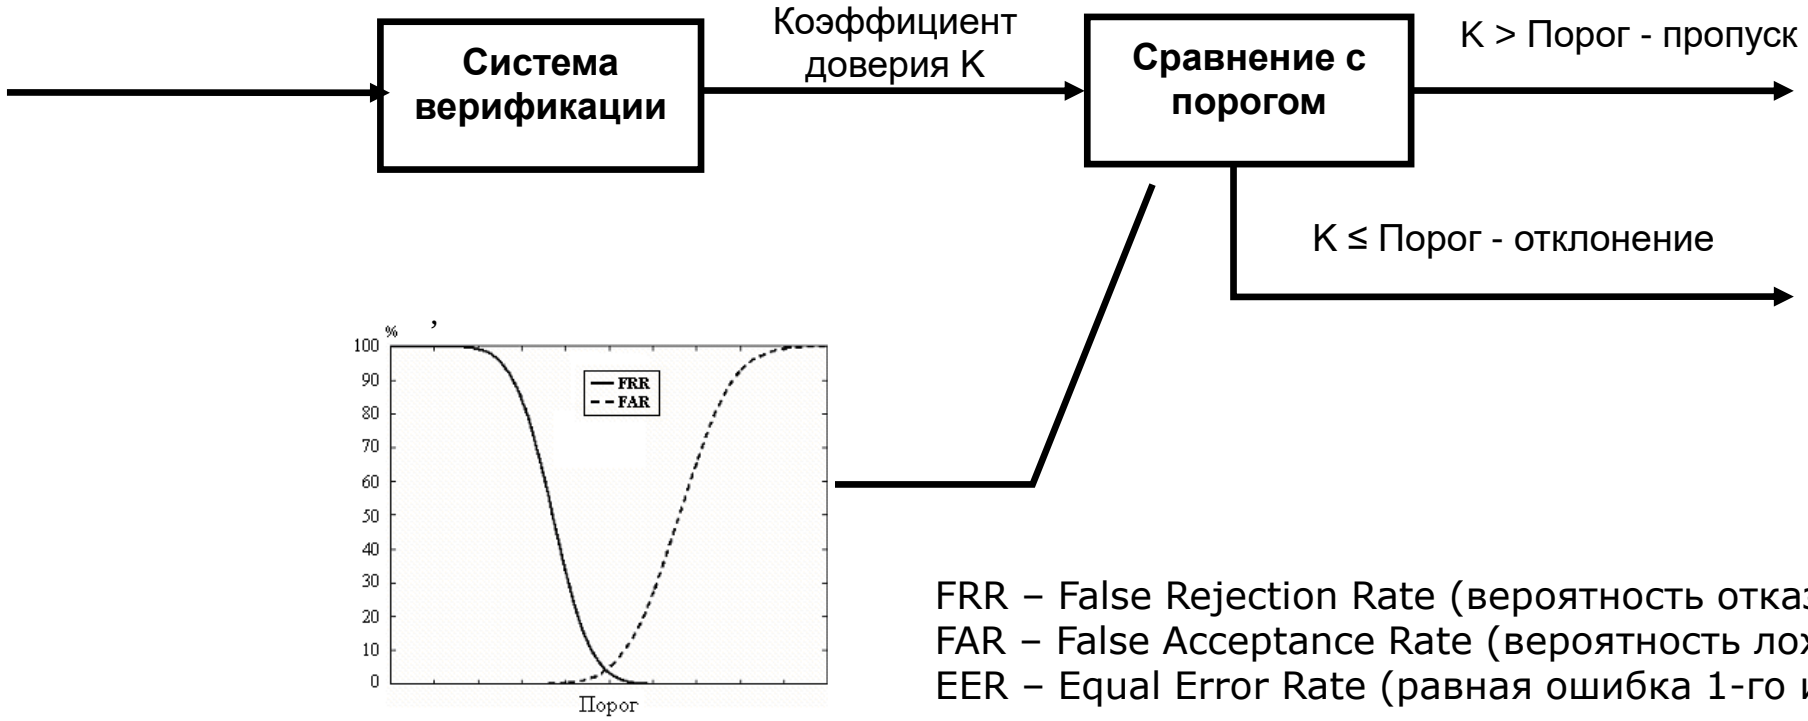


Верификация дикторов

- Проблемы разработки систем верификации
  - Стохастичность речевых характеристик
  - Неравномерность произношения
  - Зависимость качества верификации от произношения
  - Зависимость качества верификации от внешних условий

- Этапы разработки системы верификации
  - Выбор речевых характеристик с индивидуальными признаками личности
  - Компенсация неравномерности произношения
  - Принятие решения о результате верификации

Критерий качества

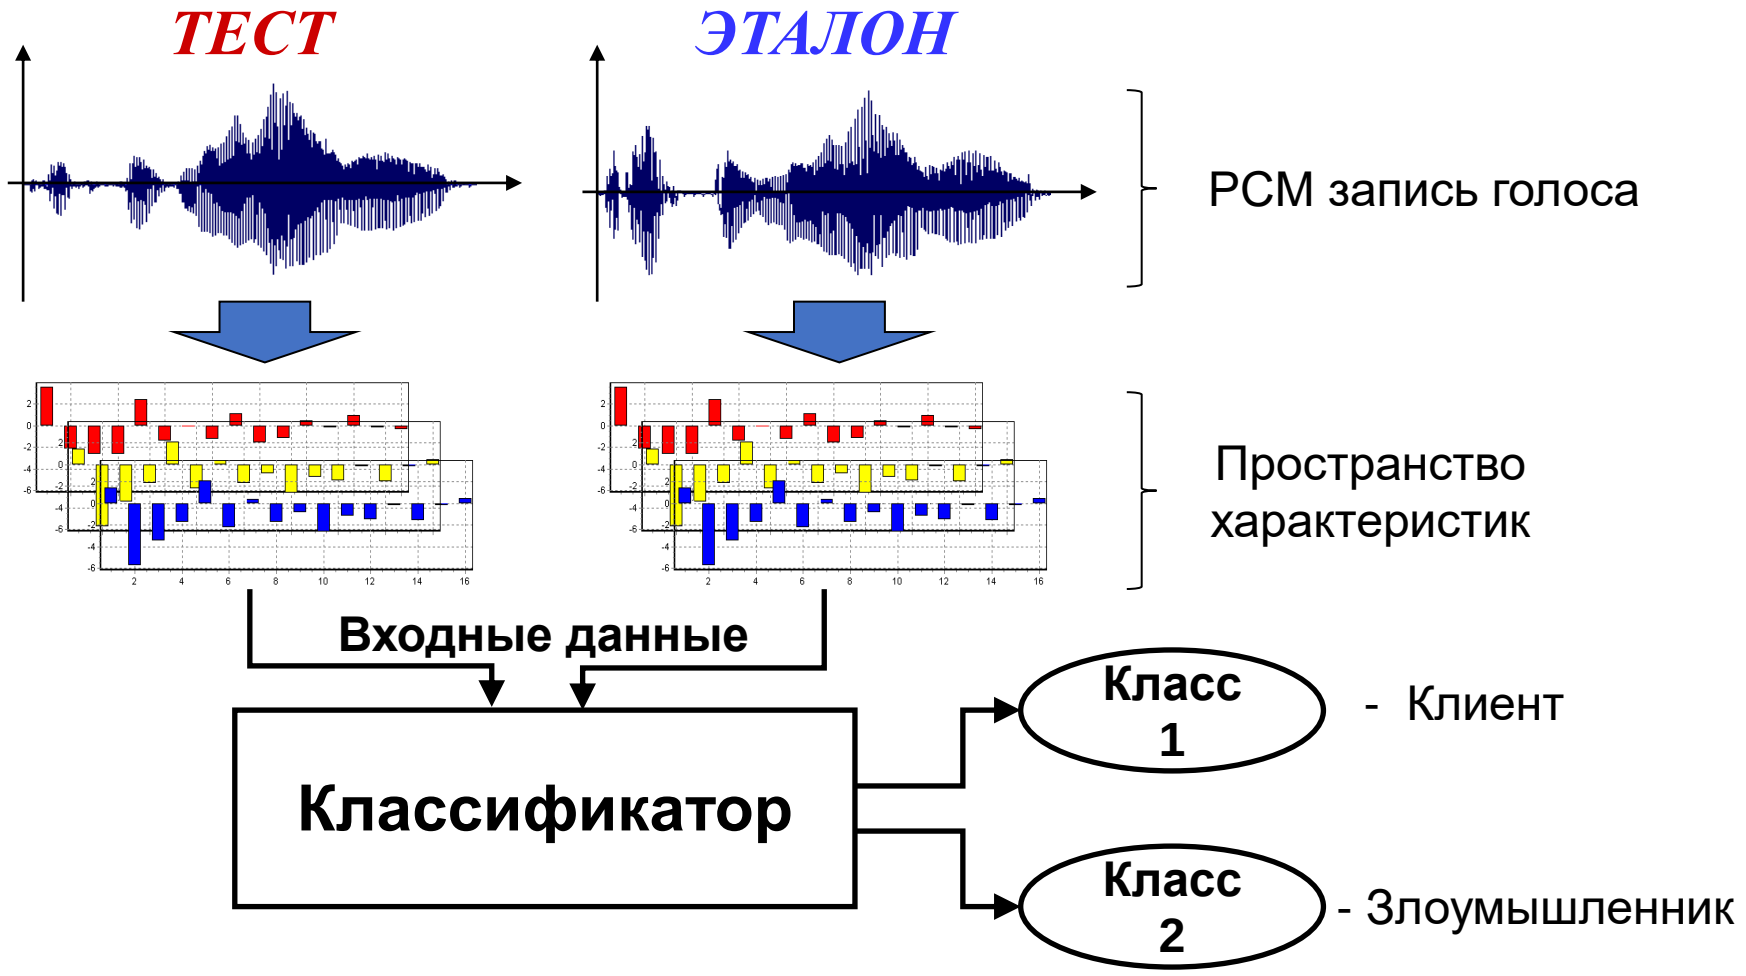


FRR – False Rejection Rate (вероятность отказа целевому диктору)
FAR – False Acceptance Rate (вероятность ложного допуска)
EER – Equal Error Rate (равная ошибка 1-го и 2-го рода)

$$\mathrm{D}CF(t) = C_{miss}P_{miss}(t)P_{target} + C_{FA}P_{FA}(t)(1 - P_{target}) \qquad (4)$$

где C_{FA} – стоимость ошибки ложного допуска,
C_{miss} – стоимость ошибки отказа целевому диктору.

Принятие решения верификации



Системы верификации диктора

ТУСУР
TUSUR UNIVERSITY

- GMM-системы
- Системы на основе i-векторов
- Системы на основе d-векторов
- Системы на основе x-векторов
- Системы с применением Metric Learning

GMM-системы

ТУСУР
TUSUR UNIVERSITY

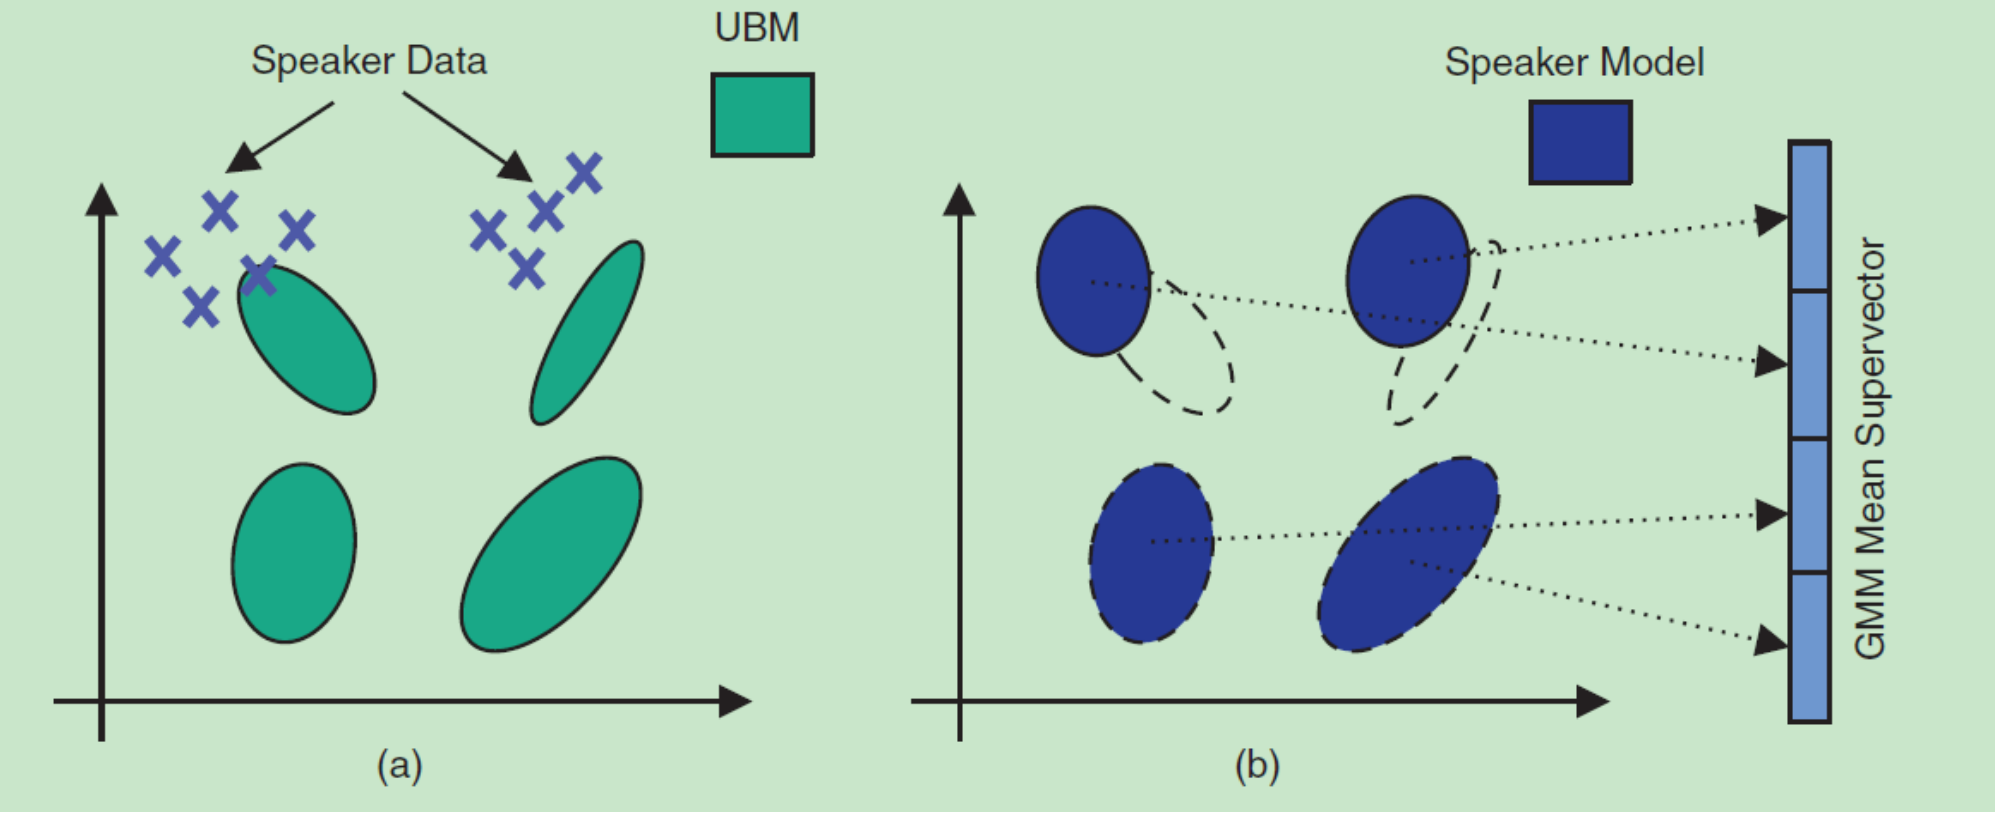
- GMM (модель Гауссовых смесей) – вероятностная модель основных звуков, содержащихся в речи диктора
- UBM (Universal Background Model, универсальная фоновая модель): обученная на аудиоданных большого количества дикторов GMM (модель Гауссовых смесей) с большим количеством Гауссоид (~2048)
- При обучении не учитываются взаимосвязь последовательностей данных, только распределение мел-кепстральных коэффициентов в одном фрейме
- Для каждого диктора обучается модель с помощью MAP-адаптации UBM
- Эти GMM можно напрямую использовать для верификации диктора с помощью оценки логарифма отношения правдоподобия (*LLR*), где X – тестовая фраза, Θ_s – модель целевого диктора, Θ_0 – UBM.

$$LLR(X,s) = \log \frac{p(X|\theta_s)}{p(X|\theta_0)} = \log p(X|\theta_s) - \log p(X|\theta_0) \qquad (5)$$

- Если $LLR\ (X,s)\ \geq t$, то принять
- Если $LLR\ (X,s) < t$, то отклонить

GMM-системы

ТУСУР
TUSUR UNIVERSITY



Системы на основе i-векторов

ТУСУР
TUSUR UNIVERSITY

Высказывание X_u в форме супервектора (GMM) представляется как комбинация супервектора UBM и **i-вектора (identity вектор)** этого высказывания:

$$m_u = m_0 + Tw_u \qquad (6)$$

- m_u и m_0 – D-мерные супервекторы для высказывания u и UBM
- w_u – i-вектор сокращенной размерности ($d \sim 400$) для высказывания u
- T – матрица размера D x d (Total variability matrix), которая отображает супервектор высказывания m_u в i-вектор
- T обучается на большом речевом корпусе с помощью EM-алгоритма.

N Dehak et al (2011), Front-End Factor Analysis for Speaker Verification, IEEE Trans Audio, Speech, and Language Processing, 19(4):788-798

Системы на основе i-векторов

ТУСУР
TUSUR UNIVERSITY

Для сравнения двух высказываний и проверки совпадения голосов дикторов на них, в i-vector системах используются:

- Косинусное расстояние:

$$f_{\cos}(\boldsymbol{w}_{\text{target}}, \boldsymbol{w}_{\text{test}}) = \frac{\boldsymbol{w}_{\text{target}} \cdot \boldsymbol{w}_{\text{test}}}{||\boldsymbol{w}_{\text{target}}|| \, ||\boldsymbol{w}_{\text{test}}||} \quad (7)$$

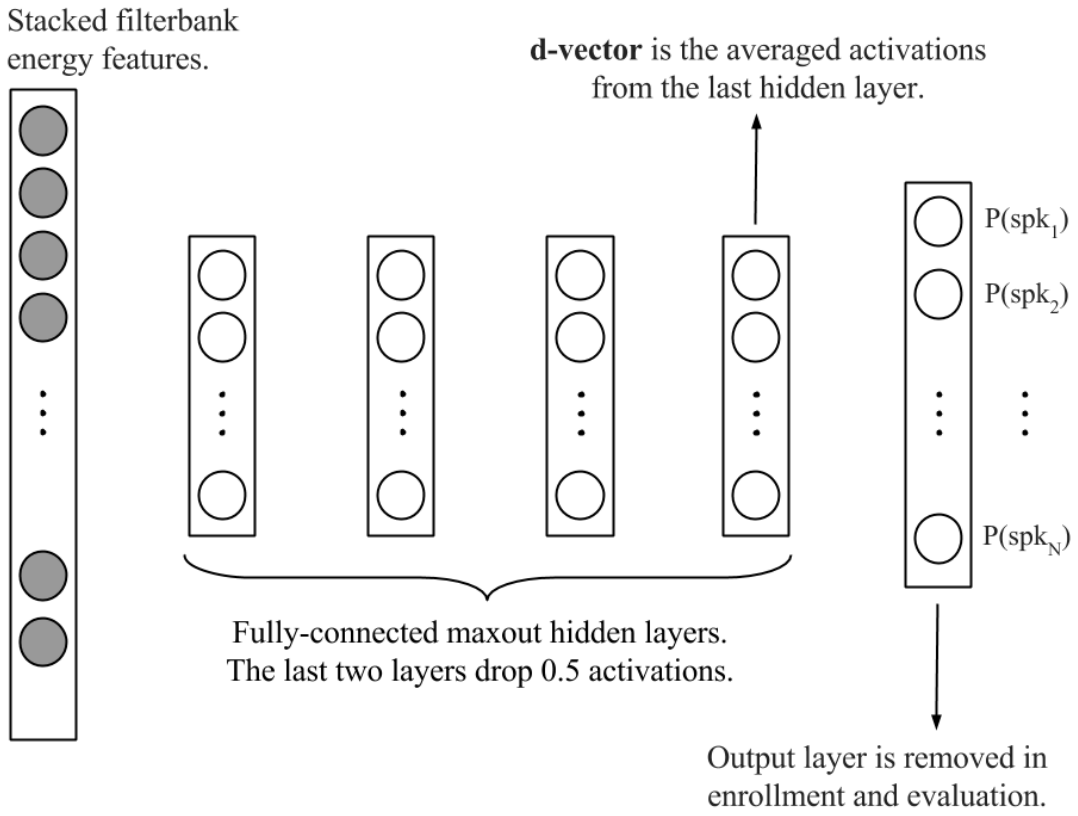
- Модель вероятностного линейного дискриминантного анализа (Probabilistic linear discriminant analysis, PLDA) – вероятностная модель, учитывающая изменчивость в голосе диктора и изменчивость канала. Данная модель может быть использована для вычисления логарифма отношения правдоподобия:

$$f_{\text{plda}}(\boldsymbol{w}_{\text{target}}, \boldsymbol{w}_{\text{test}}) = \log p(\boldsymbol{w}_{\text{target}}, \boldsymbol{w}_{\text{test}}|H_1) - \log \left[p(\boldsymbol{w}_{\text{target}}|H_0) p(\boldsymbol{w}_{\text{test}}|H_0) \right] \quad (8)$$

где H_1 – гипотеза, что в тестовом и целевом высказывании диктор один и тот же, H_0 – гипотеза, что дикторы разные

Системы на основе d-векторов

- Обучение: нейронная сеть обучается для идентификации диктора (первые версии – для распознавания речи)
- Регистрация диктора: извлечение характерных для диктора признаков из последнего скрытого слоя (эмбеддинги)
- d-вектор: усредненный по всем фреймам фразы диктора вектор признаков (слой пулинга)



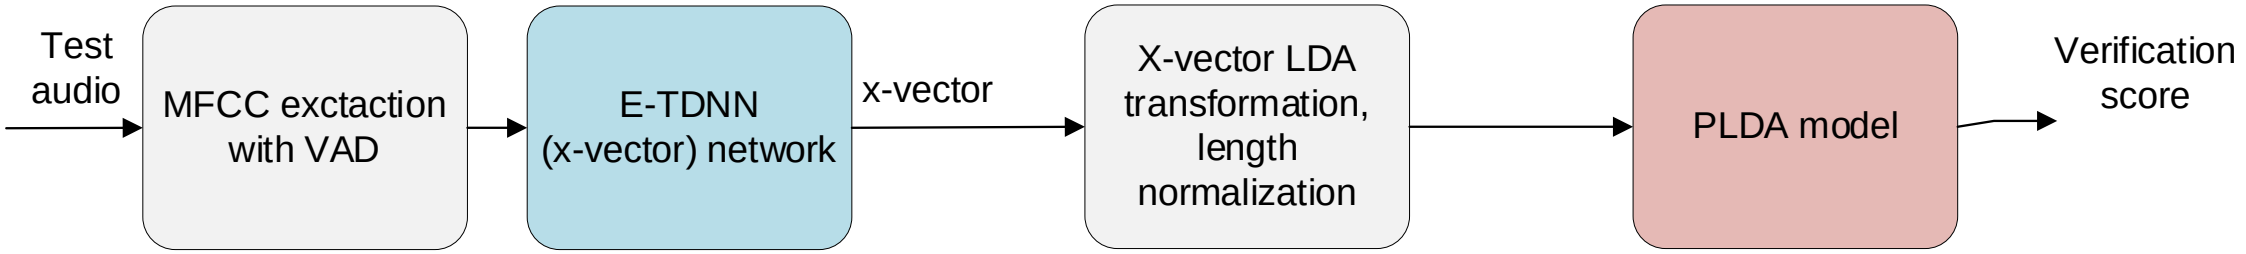
E Variani et al (2014), Deep neural networks for small footprint text-dependent speaker verification, ICASSP

Система верификации, основанная на PLDA и x-векторах

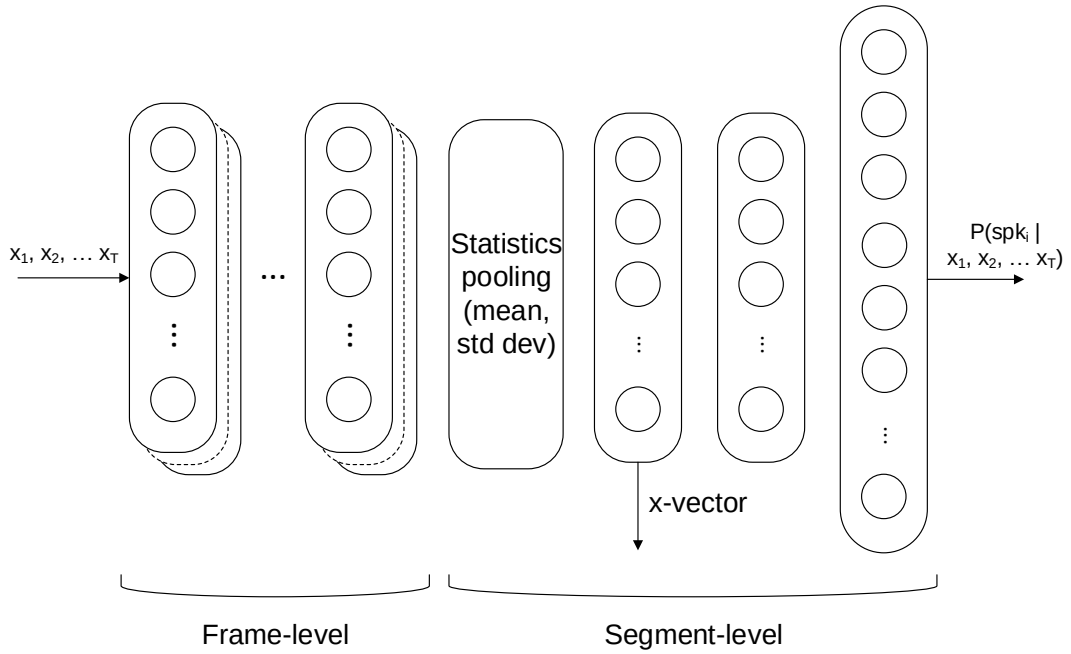
ТУСУР
TUSUR UNIVERSITY

Два ключевых компонента:

- TDNN-сеть (для извлечения x-вектора)
- PLDA-модель (для оценки близости x-векторов)



X-vector сеть

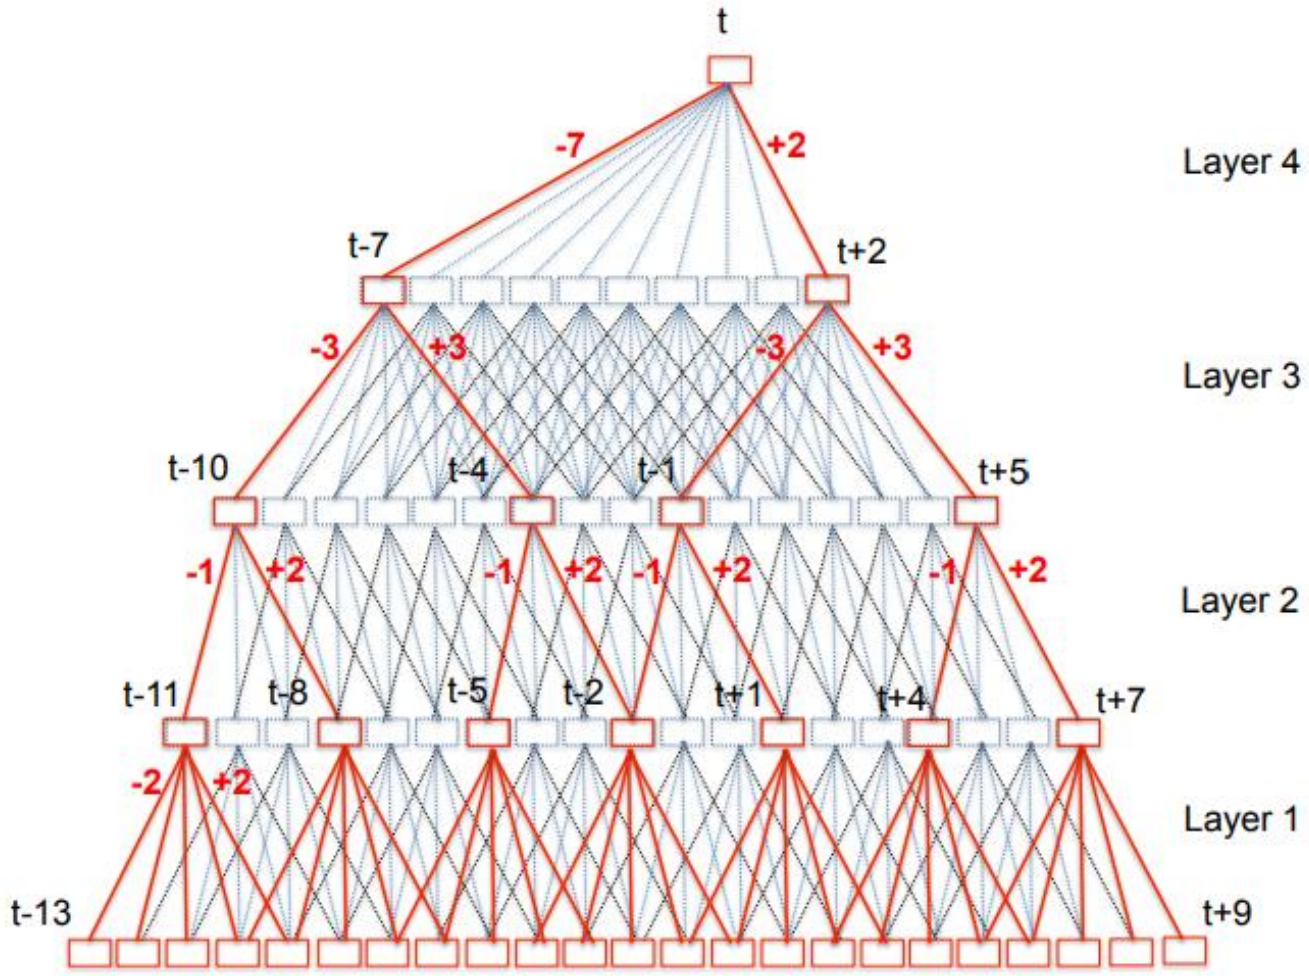


Layer	Layer type	Context	Size
1	TDNN-ReLU	t-2;t-1;t;t+1;t+2	512
2	Dense-ReLU	t	512
3	TDNN-ReLU	t-2;t;t+2	512
4	Dense-ReLU	t	512
5	TDNN-ReLU	t-3;t;t+3	512
6	Dense-ReLU	t	512
7	TDNN-ReLU	t-4;t;t+4	512
8	Dense-ReLU	t	512
9	Dense-ReLU	t	1536
10	Pooling (mean+stddev)	Full-seq	2x1536
11	Dense-ReLU(x-vector)	Full-seq	512
12	Dense-ReLU	Full-seq	512
13	Dense-Softmax	Full-seq	7323(# speakers)

Snyder, D., Garcia-Romero, D., Sell, G., McCree, A., Povey, D., & Khudanpur, S. (2019, May). Speaker recognition for multi-speaker conversations using x-vectors. In ICASSP 2019 (pp. 5796-5800)

TDNN сеть

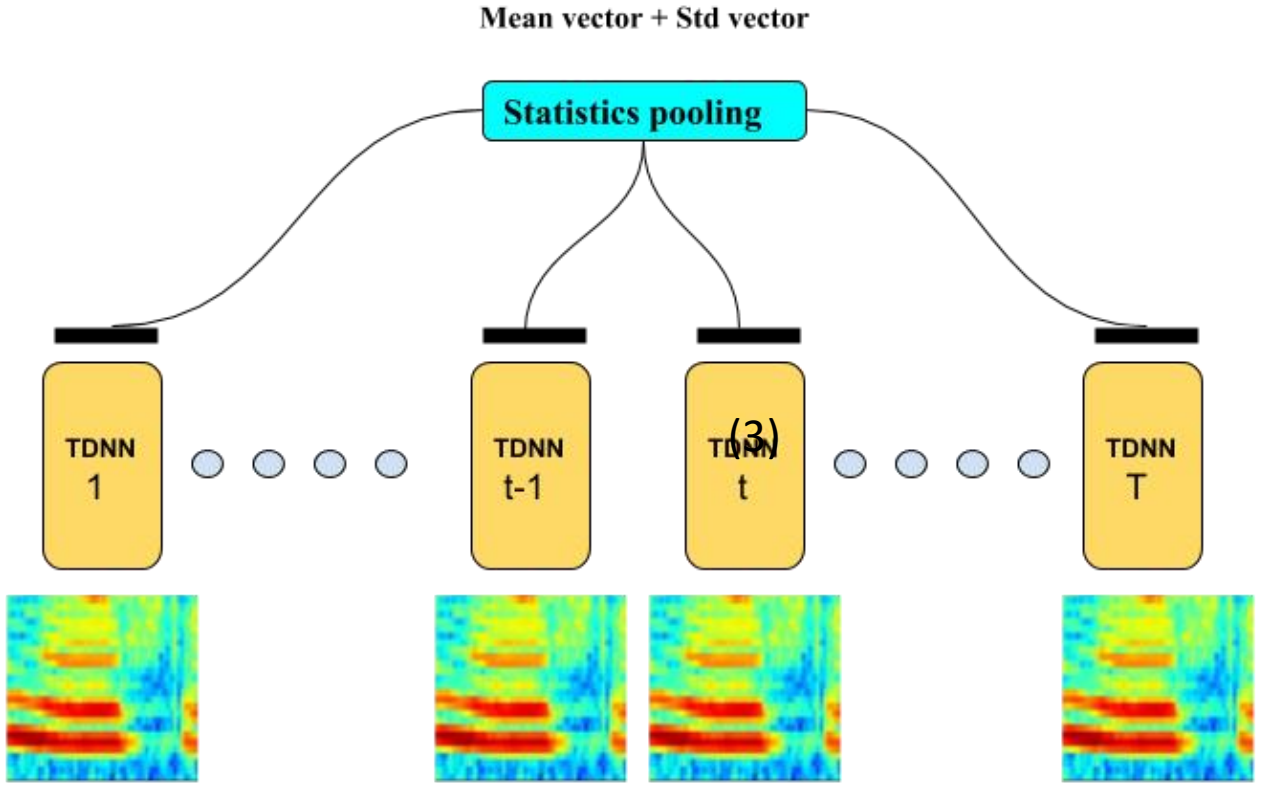
- На входе в TDNN фиксированное количество векторов признаков
- TDNN обрабатывает их с фиксированным локальным временным контекстом
- Ширина контекста увеличивается по мере перехода к верхним слоям



Statistics pooling

- Позволяет собрать усредненный вектор признаков по всему временному промежутку T
- Помимо средних значений параметров, добавлено среднеквадратичное отклонение

$$\mathcal{P}_{\text{tstp}}(\mathbf{X}) = [\boldsymbol{\mu}^\top, \boldsymbol{\sigma}^\top]^\top \qquad (3)$$



Face recognition

ТУСУР
TUSUR UNIVERSITY

Какие могут возникнуть задачи?

- Кто из людей в тренировочных данных изображен на новом фото?
- На двух новых фото один и тот же человек или нет?
- Даны 3 фото нового человека. Изображен ли он на еще одном фото?



Distractors

1 Million Photos

690,572 Unique Users

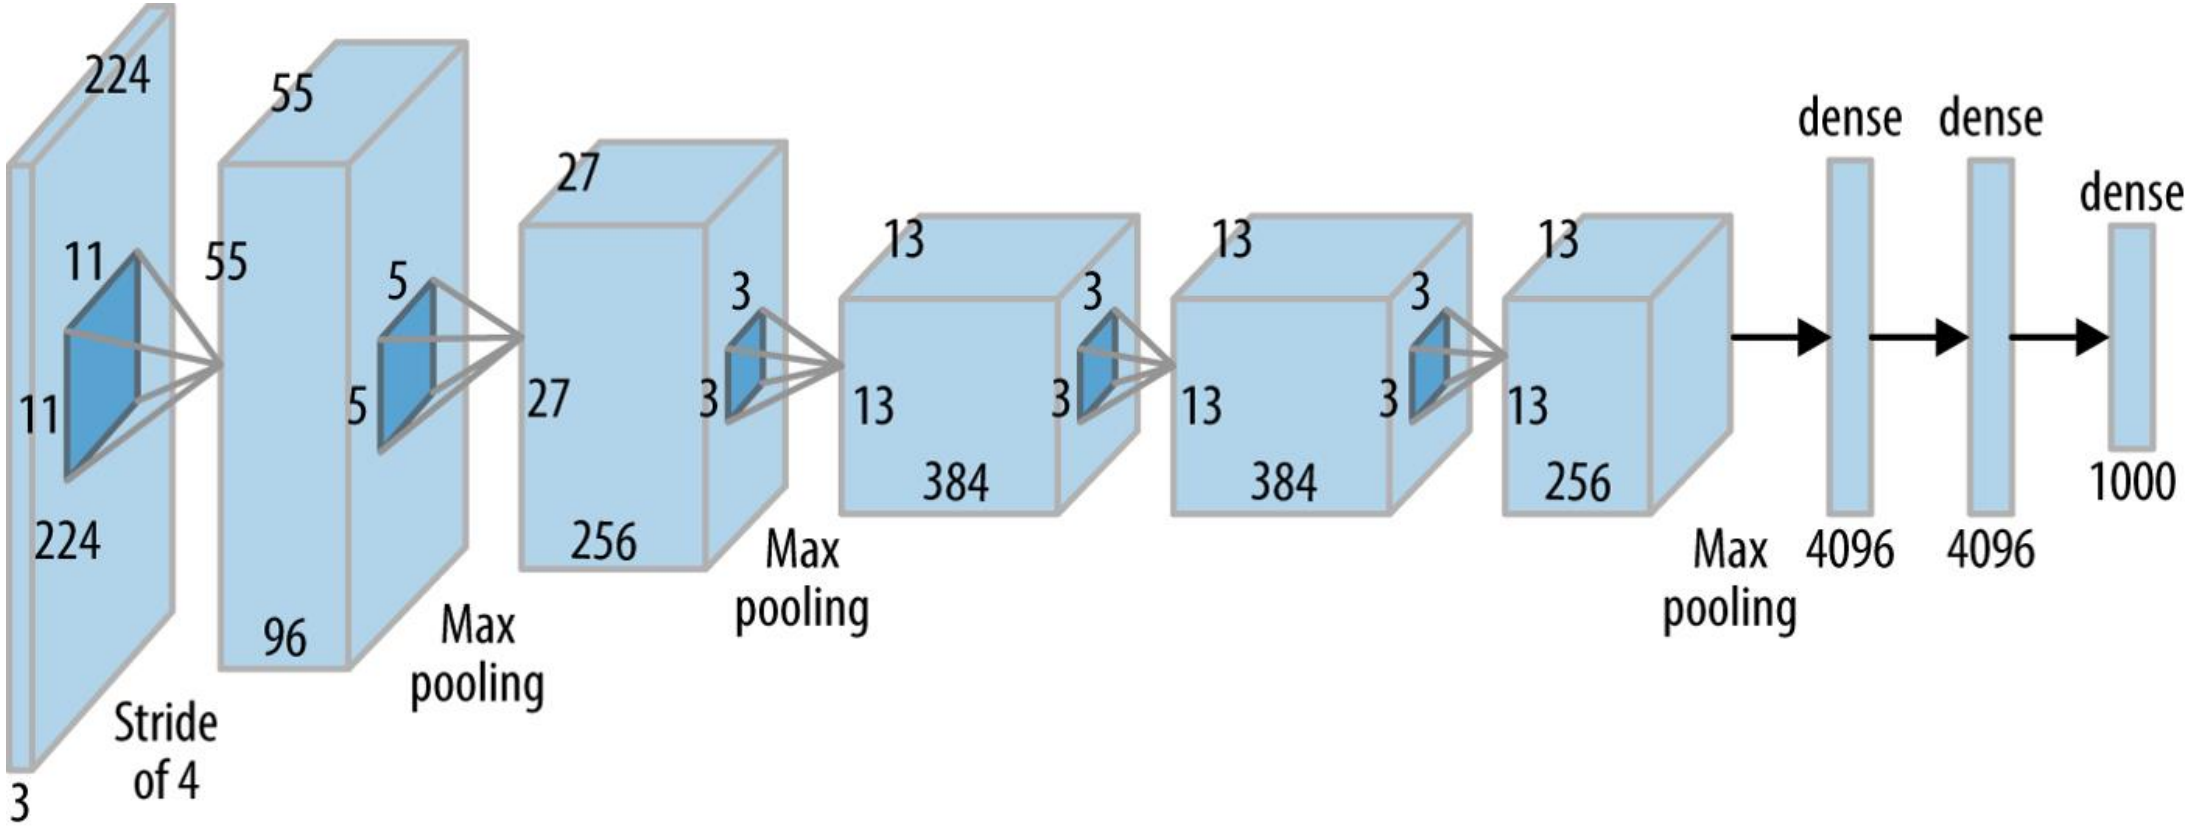
Training Set

4.7 Million Photos

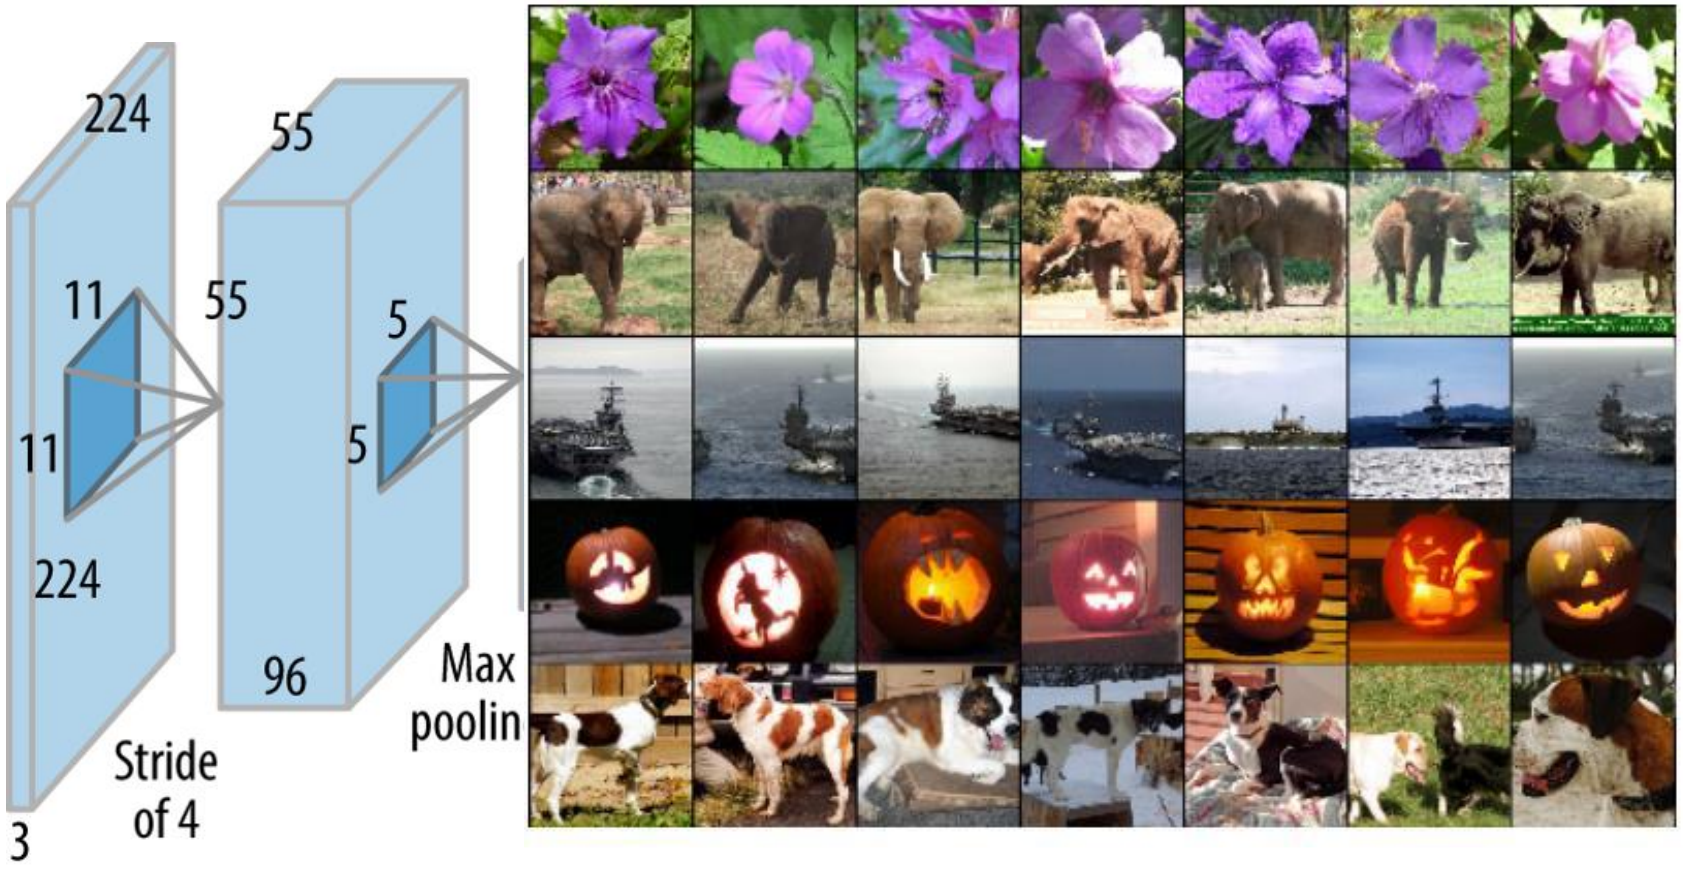
672,057 Unique Identities

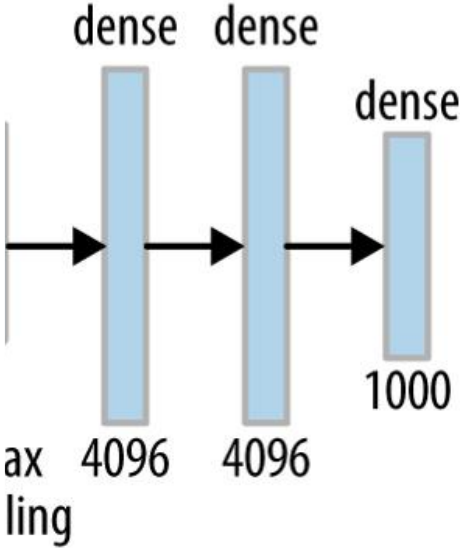
7 Mean photos / person (3 min, 2469 max)

Признаки предпоследнего слоя. Embedding



Признаки предпоследнего слоя. Embedding





Metric Learning

- Кто из людей в тренировочных данных изображен на новом фото?

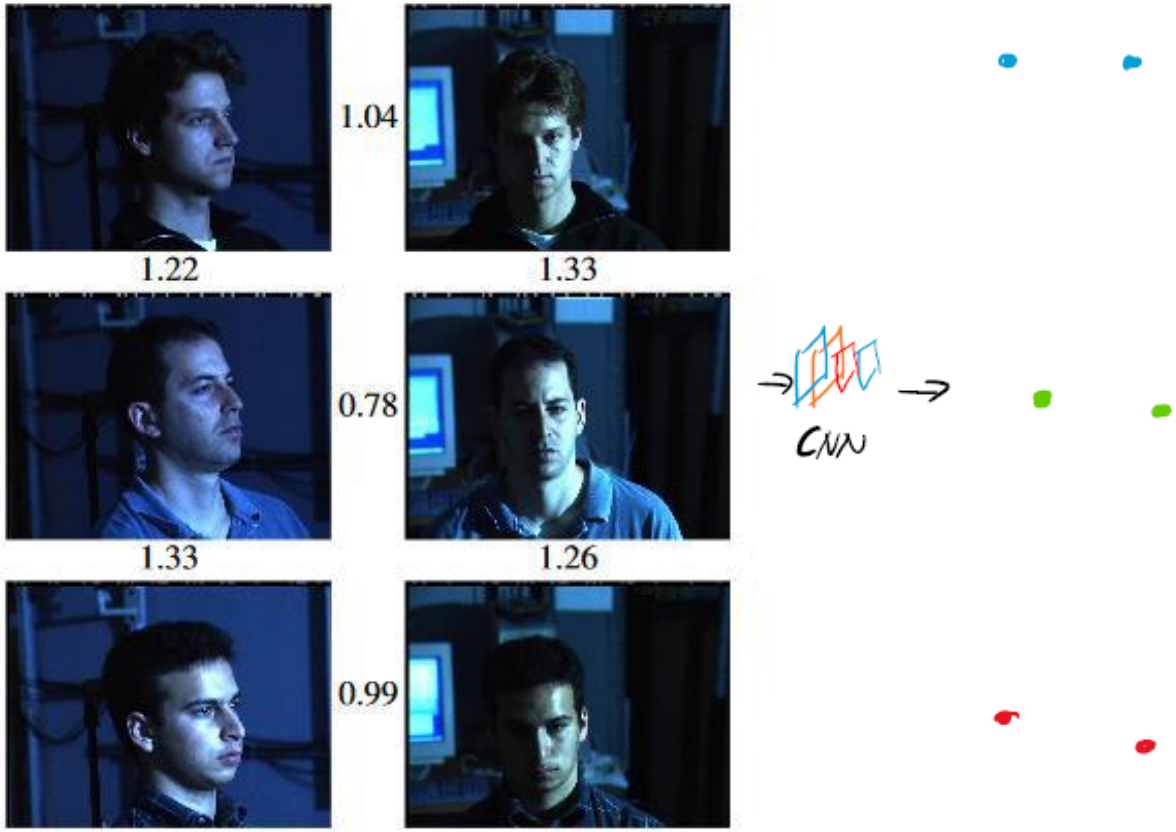
K-nearest neighbour

- На двух новых фото один и тот же человек или нет?

Отсечка по расстоянию

- Даны 3 фото нового человека. Изображен ли он на еще одном фото?

Добавить новые точки + K-nearest neighbour



Schroff, F., Kalenichenko, D., & Philbin, J. (2015). Facenet: A unified embedding for face recognition and clustering. In Proceedings of the IEEE conference on computer vision and pattern recognition (pp. 815-823).

Triplet Loss



Figure 2. **Model structure.** Our network consists of a batch input layer and a deep CNN followed by L_2 normalization, which results in the face embedding. This is followed by the triplet loss during training.

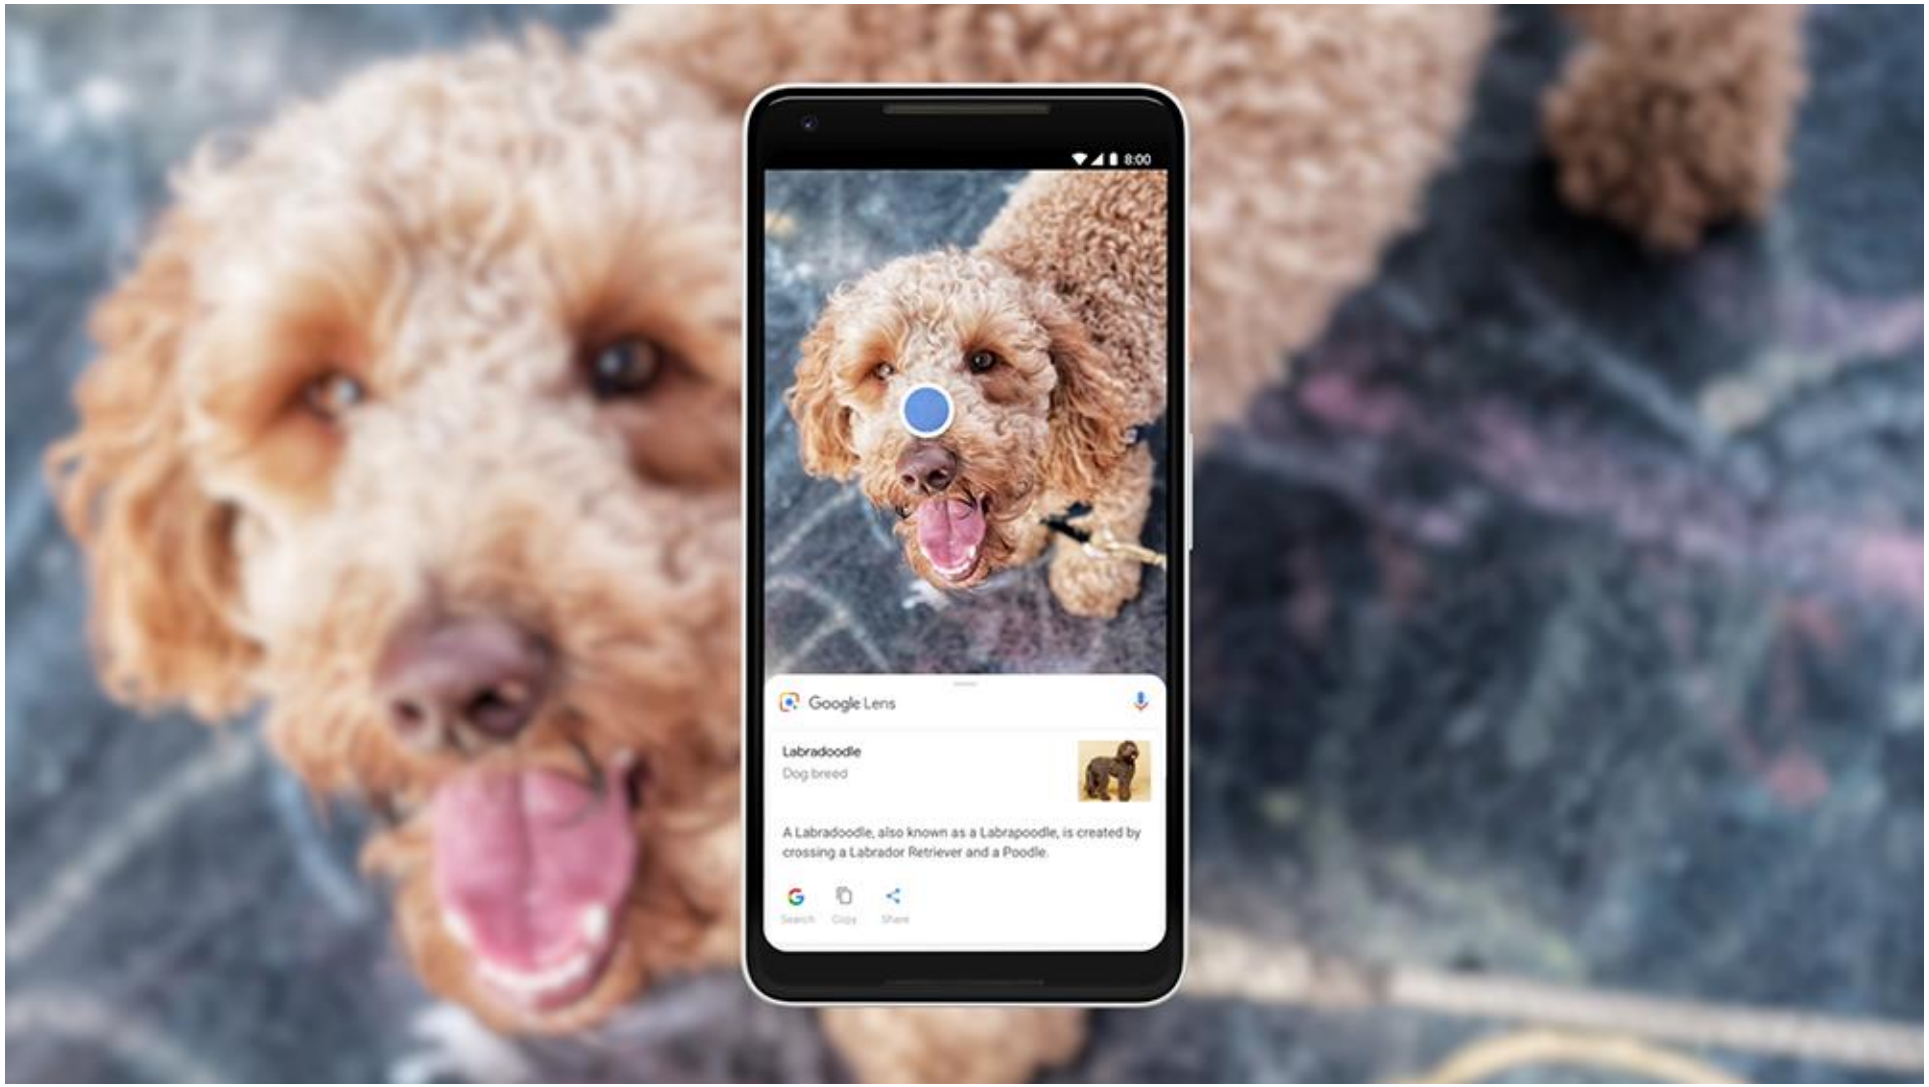


Figure 3. The **Triplet Loss** minimizes the distance between an *anchor* and a *positive*, both of which have the same identity, and maximizes the distance between the *anchor* and a *negative* of a different identity.

$$L = \sum_{i}^{N} \left[\|f(x_i^a) - f(x_i^p)\|_2^2 - \|f(x_i^a) - f(x_i^n)\|_2^2 + \alpha \right]_+ \quad (9)$$

Google Lens

TYCYP
TUSUR UNIVERSITY



Metric Learning в аутентификации по голосу

ТУСУР
TUSUR UNIVERSITY

- Loss-функции:
  - Triplet Loss
  - Prototypical Loss
  - Generalised end-to-end (GE2E) Loss
  - Angular Prototypical Loss
- Процедура обучения сети имитирует сценарий тестирования
- Архитектуры:
  - TDNN-архитектуры
  - ResNet-архитектуры

Objective	Hyperparameters	VGG-M-40	Thin ResNet-34	Fast ResNet-34
Triplet [26]	$m = 0.1$, CHNM	4.86 ± 0.15	$\mathbf{2.53 \pm 0.10}$	2.73 ± 0.03
	$m = 0.2$, CHNM	$\mathbf{4.67 \pm 0.06}$	2.60 ± 0.02	$\mathbf{2.71 \pm 0.06}$
	$m = 0.3$, CHNM	4.84 ± 0.13	2.66 ± 0.03	2.85 ± 0.04
	$m = 0.4$, CHNM	4.84 ± 0.08	2.76 ± 0.10	2.96 ± 0.07
GE2E [32]	$M = 2$	4.60 ± 0.04	2.56 ± 0.08	2.51 ± 0.07
	$M = 3$	$\mathbf{4.40 \pm 0.08}$	$\mathbf{2.52 \pm 0.07}$	$\mathbf{2.37 \pm 0.10}$
	$M = 4$	4.49 ± 0.05	2.59 ± 0.12	2.59 ± 0.08
	$M = 5$	4.69 ± 0.09	2.78 ± 0.09	2.66 ± 0.02
	$M = 10$	5.53 ± 0.04	3.68 ± 0.08	3.55 ± 0.05
Prototypical [29]	$M = 2$	$\mathbf{4.59 \pm 0.02}$	$\mathbf{2.34 \pm 0.08}$	$\mathbf{2.32 \pm 0.02}$
	$M = 3$	4.73 ± 0.11	2.54 ± 0.07	2.39 ± 0.05
	$M = 4$	4.99 ± 0.19	2.83 ± 0.04	2.89 ± 0.04
	$M = 5$	5.34 ± 0.03	3.33 ± 0.11	3.21 ± 0.01
Angular Prototypical	$M = 2$	$\mathbf{4.29 \pm 0.07}$	$\mathbf{2.21 \pm 0.03}$	$\mathbf{2.22 \pm 0.05}$
	$M = 3$	4.30 ± 0.05	2.45 ± 0.07	2.40 ± 0.04
	$M = 4$	4.53 ± 0.03	2.75 ± 0.06	2.60 ± 0.02
	$M = 5$	4.73 ± 0.01	3.00 ± 0.11	2.90 ± 0.11

Chung, J. S., Huh, J., Mun, S., Lee, M., Heo, H. S., Choe, S., ... & Han, I. (2020). In defence of metric learning for speaker recognition.

Рассмотрено

ТУСУР
TUSUR UNIVERSITY

- Задачи в области обработки аудио
- Извлечение признаков из аудиосигналов
- Методы предварительной обработки аудиосигналов
- Аугментация аудиосигналов
- Методы распознавания образов в аудиосигналах (задача верификации диктора)

ТУСУР
TUSUR UNIVERSITY

Спасибо за внимание!